基于偏振成像的

水下图像去散射技术研究

(申请清华大学电子信息硕士专业学位论文)

培 养 单 位： 深圳国际研究生院

专 业 领 域： 海洋科学与技术

申　请　人： 林　滢　舒

指 导 教 师： 周　　倩　教授

二○二六年五月

基于偏振成像的水下图像去散射技术

林滢舒

Research on Underwater Image Descattering Technology Based on Polarization Imaging

Thesis submitted to

Tsinghua University

in partial fulfillment of the requirement

for the professional degree of

Master of Electronic and Information Engineering

by

Lin Yingshu

(Marine Technology and Engineering)

Thesis Supervisor Professor Zhou Qian

May, 2026

学位论文公开评阅人和答辩委员会名单

公开评阅人名单

答辩委员会名单

关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：（1）已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；（2）为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容；（3）按照上级教育主管部门督导、抽查等要求，报送相应的学位论文。

本人保证遵守上述规定。

作者签名：_____ 导师签名：_____

日　　期：_____ 日　　期：_____

摘　要

水下视觉感知技术在海洋探测、无人潜航器导航、目标识别等领域具有重要应用价值。然而，水下成像受悬浮颗粒散射效应影响，出现对比度下降、细节模糊等问题。现有的传统物理模型方法参数估计鲁棒性差，且计算耗时；而监督的深度学习方法依赖成对的“清晰-浑浊”真值标签，易产生域偏移且缺乏物理可解释性。偏振成像能提供超越光强的额外物理维度，为水下成像恢复提供了补充线索，已成为近年来的研究热点之一。基于此，本文深入挖掘了水下偏振图像退化的底层物理机理，提出了一套物理与数据混合驱动的高效水下图像去散射解决方案。

首先，针对水下彩色偏振图像数据匮乏的问题，本文搭建了水下主动偏振成像采集平台，构建了覆盖 6 个浑浊度等级、包含多种目标材质特征的水下偏振图像数据集，总规模达 7000+张。该数据集为后续物理退化机理的验证与深度神经网络的训练提供了坚实的数据支撑。

针对传统物理模型参数估计不准的问题，本文提出了一种融合多偏振先验的水下图像去散射物理方法。在复平面上重构了水下偏振退化模型，引入了偏振线先验、偏振度衰减先验以及消色差先验。通过多先验的联合约束，实现了复杂场景下局部透射率与全局背景光的物理参数解耦，在 18.9 NTU 低浑浊度下，本文方法恢复图像的平均 PSNR 达到 22.25 dB，比第二名高出 2.08 dB，提升了模型在色彩保真与高频细节恢复方面的性能。

最后，为克服纯物理方法求解耗时较长以及深度学习缺乏真实标签的问题，本文创新性地提出了一种物理先验引导的自监督双分支去散射网络。该框架采用“同源提取、异构解耦”的架构设计，并行完成局部透射率与全局背景光参数的估计。将物理先验转化为可微的无参考损失函数，在无需真值标签的条件下实现了网络的端到端自监督训练。实验结果表明，该方法在不同场景下表现出良好的鲁棒性，在无参考客观评价中取得了最优的 UCIQE 得分 (0.5966) 与极具竞争力的 UIQM 得分（2.3931）。单幅图像推理时间约为 0.6 秒，较传统物理迭代优化方法（5.46 秒）提速近 9 倍，保证了良好的恢复质量与计算效率。

本文的工作涵盖了偏振彩色数据集构建、物理先验分析与自监督网络设计，为水下复杂环境中的视觉感知与目标探测提供了具有工程应用价值的创新思路。

关键词：偏振成像；水下图像去散射；物理先验；自监督学习；参数解耦

Abstract

Underwater visual perception technology plays an important role in applications such as ocean exploration, autonomous underwater vehicle navigation, and object recognition. However, underwater imaging is severely affected by the scattering of suspended particles, which leads to reduced contrast and blurred details. Existing traditional physics-based methods suffer from poor robustness in parameter estimation and high computational cost, while supervised deep learning approaches rely on paired “clean–turbid” ground truth data, making them prone to domain shift and lacking physical interpretability. Polarization imaging provides additional physical information beyond light intensity, offering complementary cues for underwater image restoration, and has thus become a research hot spot in recent years. Motivated by this, this paper investigates the underlying physical mechanisms of underwater polarization image degradation and proposes an efficient hybrid solution driven by both physical modeling and data learning.

First, to address the scarcity of underwater color polarization data, an active underwater polarization imaging acquisition platform is constructed. Based on this platform, a dataset containing more than 7,000 images is built, covering six turbidity levels and various target materials. This dataset provides solid support for validating physical degradation models and training deep neural networks.

To overcome the inaccuracy of parameter estimation in traditional physical models, a multi-polarization-prior-based underwater image descattering method is proposed. The underwater polarization degradation model is reformulated in the complex domain, incorporating polarization line prior,degree of polarization attenuation prior, and achromatic prior. By jointly constraining these priors, the proposed method achieves effective decoupling of local transmission and global background light in complex scenes. At a low turbidity level of 18.9 NTU, the restored images achieve an average PSNR of 22.25 dB, outperforming the second-best method by 2.08 dB, with improved performance in color fidelity

and high-frequency detail recovery.

Finally, to address the high computational cost of pure physical methods and the lack of real labels in deep learning approaches, a novel physics-guided self-supervised dual-branch descattering network is proposed. The framework adopts a “shared feature extraction with heterogeneous decoupling” architecture, enabling parallel estimation of local transmission and global background light. Physical priors are transformed into differentiable no-reference loss functions, allowing end-to-end self-supervised training without ground truth labels. Experimental results demonstrate that the proposed method achieves strong robustness across different scenarios, attaining the best UCIQE score (0.5966) and a highly competitive UIQM score (2.3931) in no-reference evaluation. The inference time for a single image is approximately 0.6 seconds, which is nearly 9 times faster than traditional iterative physical optimization methods (5.46 seconds), while maintaining high restoration quality and computational efficiency.

In summary, this work covers the construction of a polarization-based color dataset, the analysis of physical priors, and the design of a self-supervised network, providing a practical and effective solution for visual perception and object detection in complex underwater environments.

Keywords: Polarization imaging; underwater image descattering; physical priors; self-supervised learning; parameter decoupling

目 录

摘 要.....VI
Abstract.....VII
目 录.....IX
插图和附表清单.....XII
符号和缩略语说明.....XIV
第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 基于差分成像的水下偏振图像增强方法.....3
1.2.2 基于斯托克斯矢量的水下偏振图像增强方法.....5
1.2.3 基于深度学习的水下偏振图像增强方法.....6
1.3 论文研究内容.....7
1.4 论文章节安排.....9
第 2 章 水下偏振成像原理与数据集构建.....10
2.1 偏振成像基础.....10
2.1.1 偏振光的基本概念.....10
2.1.2 斯托克斯参量及其测量.....11
2.2 水下成像模型.....13
2.2.1 水体吸收与散射特性.....13
2.2.2 经典水下光强成像模型.....14
2.3 水下偏振数据集构建.....16
2.3.1 采集平台搭建与散射介质物理模拟.....16
2.3.2 不同浑浊度的水下偏振数据集构建.....17
2.3.3 不同目标物体的水下偏振数据集构建.....18
2.4 水下图像质量评估指标.....19
2.4.1 全参考指标.....19
2.4.2 无参考指标.....20
2.5 本章小结.....22

第 3 章　融合多偏振先验的水下图像去散射方法 23
3.1　引言 23
3.2　偏振先验的理论推导与物理机制分析 24
3.2.1　水下偏振态退化理论 24
3.2.2　偏振线先验 26
3.2.3　偏振度量化与线性衰减规律验证 27
3.2.4　偏振消色差先验 30
3.3　基于复平面偏振态的图像恢复 32
3.3.1　背景散射光偏振态估计 32
3.3.2　基于角度聚类的偏振线预测 33
3.3.3　基于偏振线约束的初始透射率估计 34
3.3.4　场景图像恢复 35
3.4　基于偏振度和消色差先验的图像恢复 37
3.4.1　基于消色差先验的强度估计 37
3.4.2　偏振传输图估计 38
3.4.3　场景 DoLP 与强度图像恢复 38
3.5　基于多尺度融合的图像增强 39
3.5.1　融合权重图计算 40
3.5.2　多尺度拉普拉斯金字塔融合 41
3.6　实验结果与分析 42
3.6.1　实验设置与条件 42
3.6.2　不同偏振特性物体的恢复能力对比 42
3.6.3　不同浑浊度下的恢复性能对比 44
3.6.4　消融实验与参数分析 46
3.7　本章小结 47
第 4 章　物理先验引导的自监督水下图像恢复方法 49
4.1　引言 49
4.2　双分支自监督网络架构 50
4.2.1　网络总体框架 50
4.2.2　共享特征编码器 51
4.2.3　局部透射率估计子网络 52
4.2.4　背景光估计与物理反演模块 53
4.3　多物理先验联合损失函数 54

4.4 实验结果与分析 57
4.4.1 实验设置与条件 57
4.4.2 模拟数据集的评估与比较 58
4.4.3 真实数据集的评估与比较 65
4.5 消融实验及运行时间分析 67
4.5.1 消融实验 67
4.5.2 运行时间分析 68
4.6 本章小结 69
第 5 章 总结与展望 71
5.1 论文工作总结 71
5.2 未来展望 72
参考文献 74
致 谢 81
声 明 82
个人简历、在学期间完成的相关学术成果 83
指导教师评语 84
答辩委员会决议书 85

插图和附表清单

图 1.1 水下图像对比度低、细节退化图 1
图 1.2 合成数据集（左：清晰图像；右：合成浑浊图像） 2
图 1.3 水下偏振差分成像系统 4
图 1.4 偏振差分成像方法（上）和基于斯托克斯矢量的方法（下）对比 5
图 1.5 极化密集网络 7
图 1.6 融合偏振先验的水下图像去散射网络流程图 8
图 2.1 偏振椭圆 11
图 2.2 水下波长衰减图 13
图 2.3 水下图像（左：色彩失真 右：对比度下降） 14
图 2.4 水下成像示意图 15
图 2.5 数据集收集实验装置 16
图 2.6 相机传感器的微阵列结构 17
图 2.7 数据集-不同浑浊度下的相同场景 18
图 2.8 相同浑浊度下的不同场景数据集（浊度 28.6 NTU） 19
图 2.9 相同浑浊度下的不同场景数据集（浊度 36.8 NTU） 19
图 3.1 极化状态、DoLP、AoLP 关系 25
图 3.2 偏振线先验几何分布 26
图 3.3 有雾图像颜色退化 27
图 3.4 聚类后的 DoP 图像变化 28
图 3.5 DoP 线性衰减 29
图 3.6 偏振消色差先验验证图 31
图 3.7 清晰图像与浑浊图像的偏振态分布 32
图 3.8 不同偏振特性物体的恢复 43
图 3.9 不同浑浊度的水下图像恢复 45
图 4.1 自监督去散射网络整体框架 50
图 4.2 ResNet-50 网络结构 51
图 4.3 U-Net 编码器与解码器网络结构 52
图 4.4 T-Net 的编码器与解码器网络结构 53
图 4.5 不同方法在低浑浊度场景的恢复对比 59
图 4.6 不同方法对于不同浑浊度场景的恢复对比 60

图 4.7 不同方法在高浑浊度场景的恢复对比 63
图 4.8 真实水下偏振数据集 65
图 4.9 不同方法的恢复情况 66
图 4.10 雾霾场景去雾效果 67

表 3.1 不同方法的图像恢复指标 44
表 3.2 四个浑浊度等级下各方法的 PSNR 和 SSIM 指标 45
表 3.3 消融实验的定量评估结果 46
表 3.4 不同偏振聚类数N_p对恢复质量和耗时的影响 46
表 4.1 实验硬件与软件配置 57
表 4.2 各方法的 UIQM，UCIQE 均值 64
表 4.3 损失函数消融实验的定量比较 68
表 4.4 不同方法的计算时间比较 68

符号和缩略语说明

I(x,y)	总光强（浑浊水下图像）
D(x,y)	直接分量
A(x,y)	后向散射分量
J(x,y)	物体反射光（清晰水下图像）
t(x,y)	透射率，表示信号光经水体衰减后剩余的比例
P	总光强的偏振度
A_∞/B_∞	无穷远处大气光
$\theta_{\parallel}$	代表最大光强的角度
m_I	观测图像的复偏振态
m_B	目标本征的复偏振态
m_D	背景散射光的复偏振态
r(x,y)	偏振透射率，描述偏振态退化的权重
ρ_I, ρ_D, ρ_B	观测、目标、背景光的线偏振度
$\varphi_I, \varphi_D, \varphi_B$	观测、目标、背景光的偏振角
N_p	聚类数
λ	正则化参数，在优化函数中平衡数据项与平滑项的权重
L	用于自监督网络训练的损失函数
DoP/DoLP	偏振度（Degree of Polarization）
AoLP	偏振角（Angle of Linear Polarization）
PSNR	峰值信噪比（Peak Signal-to-Noise Ratio）
SSIM	结构相似性指数（Structural Similarity Index）
UCIQE	水下彩色图像质量评价 (Underwater Color Image Quality Evaluation)
UIQM	水下图像质量度量 (Underwater Image Quality Measure)
NTU	散射浊度单位 (Nephelometric Turbidity Unit)
WLS	加权最小二乘 (Weighted Least Squares)

第 1 章　绪论

1.1　研究背景及意义

水下环境因其丰富的生物资源和矿物资源，对人类社会的可持续发展具有重要意义。随着陆地资源的日益紧缺，海洋资源的开发和利用逐渐成为全球关注的焦点。水下成像技术在海洋勘探、水下救援、生态监测、海洋生物跟踪和实时导航等领域具有广泛的应用前景。

然而，水下光传播受到水体中的悬浮粒子和溶解在水中的杂质吸收和散射的影响，降低了目标图像的清晰度[1][2]。散射效应主要表现为前向散射和后向散射：前向散射使反射光在传播过程中发生小角度偏移，导致图像模糊；后向散射则直接由水中粒子散射进入成像系统，产生“雾化”效果，使图像亮度变暗、对比度降低，给水下考古、无人潜航器导航等应用带来巨大挑战。



图 1.1 水下图像对比度低、细节退化图

为了克服水下散射对成像质量的严重影响，研究者们提出了多种水下图像复原与增强方法。传统方法主要分为两类：基于物理模型的方法和基于图像处理的方法。基于物理模型的方法通常根据水下成像模型，通过估计场景深度、背景光以及透射率等参数来反演退化过程，典型方法包括暗通道先验（DCP）及其改进算法。这类方法在特定场景下能够取得一定效果，但其依赖于强先验假设，容易失效，如暗通道假设在含有白色目标或人工光源的水下环境中常失效。且参数估计精度受水体不均匀性和光照条件变化的影响较大，在复杂真实水下环境中泛化能力较差。基于图像处理的方法则通过调整对比度、色彩均衡或直方图修正等手段改善视觉效果，如直方图均衡化、灰度世界假设等，这类方法计算效率较高，但由于缺乏对物理退化机制的建模，常常导致过增强、色彩失真或细节丢失，难以

实现物理意义上准确的复原。

近年来，基于深度学习的图像复原方法取得了显著进展，并在水下图像增强领域得到了广泛应用。研究者们设计了多种网络结构，通过大量成对数据进行端到端的训练，学习从退化图像到清晰图像的映射关系。然而，其性能高度依赖于训练数据的质量与分布。在真实水下环境中，获取严格对齐的“清晰-浑浊”图像对极其困难，因此现有方法大多依赖于物理模型合成的图像进行训练，如图 1.2 所示。合成数据与真实水下图像之间存在明显的域差异，导致模型在实际应用中出现伪影或复原不自然等问题。此外，纯数据驱动的方法往往缺乏对物理退化过程的显式建模，可解释性较弱，在面对复杂多变的水下环境时鲁棒性不足。



图 1.2 合成数据集（左：清晰图像；右：合成浑浊图像）

针对上述方法存在的局限性，研究者们开始探索利用更丰富的成像信息来突破仅依赖强度图像的瓶颈。偏振作为光波的一种基本属性，能够为成像提供超越光强的额外物理维度，从而在一定程度上缓解仅依赖强度信息的缺陷，为水下成像分析提供有价值的补充线索[6]，近年来已成为水下成像领域的研究热点。尽管偏振信息在水下环境中同样会受到散射作用的削弱和扭曲，偏振度（DoLP）、偏振角（AoLP）及其空间分布在散射和反射混合后仍保留一定规律性。通过对偏振退化机制进行合理建模，挖掘的退化规律可作为图像恢复过程中的物理约束，从而估

计散射分量、恢复色彩和结构细节。同时，由于偏振特性不仅受介质散射影响，也与物体表面的材质、粗糙度及几何结构密切相关，其物理可解释性使得偏振成像在复杂水下场景中具有潜在的鲁棒性。

近年来研究指出：仅依赖偏振度不足以准确恢复偏振信息，忽略偏振角会导致偏振重建偏差；同时，散射退化后的偏振状态在偏振空间内并非随机分布，而是呈现出具有一定聚集趋势和几何结构的变化模式，这为构建稳健的偏振约束提供了关键依据。此外，偏振信息也可以作为自监督学习中的物理先验，使网络在无需成对数据的条件下学习偏振退化规律与成像一致性，从而提高恢复的可靠性和精准性。这些分析共同表明，偏振成像为突破传统去散射方法的瓶颈提供了关键的发展方向。

因此，开展基于偏振成像的水下图像去散射研究，不仅能够克服传统方法在水体变化、光照条件和数据缺乏方面的普遍不足，还能充分利用偏振物理模型的可解释性与偏振空间的结构性特征，探索更鲁棒、更泛化、更符合水下成像机制的恢复策略。基于偏振信息构建自监督学习方法，有望在无需成对数据的前提下实现更高质量、更优速度的水下去散射，为水下探测、海洋机器人、生态监测与工程视觉系统提供更可靠的视觉基础，具有重要的学术价值和工程意义。

1.2　国内外研究现状

目前，基于偏振成像的水下图像增强方法主要可以分为三类：差分成像方法、斯托克斯矢量成像方法以及基于深度学习的偏振成像方法。每种方法都有其独特的优势和局限性，下面将根据这些分类逐一介绍国内外的研究现状及进展。

1.2.1　基于差分成像的水下偏振图像增强方法

偏振差分成像方法通过采集两幅同一场景下正交偏振态（通常为平行与垂直）的图像，利用后向散射光与目标反射光在偏振特性上的差异，对后向散射光进行有效抑制，是水下偏振成像领域最经典和基础的方法之一。

差分成像方法通过采集两幅同一场景下的最大光强和最小光强图像，利用偏振特性差异对后向散射光进行有效抑制，已被广泛应用于水下偏振图像增强。Schechner 等人[6][7]分析了水下目标可见度的退化的物理效应，他们发现这种退化与光的偏振有关，并建立了水下目标探测模型。他们认为在水中目标光会随距离增加而衰减，背景光则随着距离增加而增大，并且背景光有很强的偏振特性，为此他们设计了一种正交的偏振成像系统（如图 2.1 所示）用来估计背景光强，以实

现对目标反射光的复原，使水下成像的质量显著提高。在该方法的基础上，国内外很多学者[8][9][10][11][12]陆续开展了基于光偏振特性的水下图像去散射方法的研究。Tyo 团队[13]则提出使用偏振差分的方式来探测目标特征，并证明了与传统强度成像相比，偏振差分成像能将某些目标特征的探测距离增加 2-3 倍。

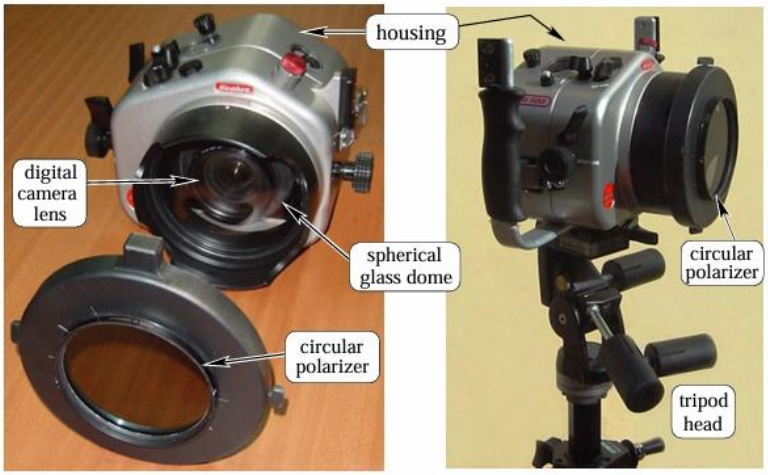


图 1.3 水下偏振差分成像系统

为了简化问题，最初的差分偏振成像模型通常假设目标物体的反射光为非偏光，从而估算透射率。然而，这一假设在目标本身具有较强偏振特性（如金属表面）时会引入误差。Huang 等人[15]针对此局限，考虑了目标的偏振效应，提出通过估计目标信号的偏振差分图像来恢复水下图像，通过精确估算后向散射光特征参数，有效改善了恢复图像的细节信息。Hu 等人[16]则进一步研究了物体退偏度与介质透射率之间的关系，通过阈值设置和曲线拟合来校正透射率函数，实现了更优的偏振图像增强效果。

此外，偏振差分成像方法常通过选择无目标的水下图像区域估算后向散射光强度，并将其输入成像模型进行反演，最终恢复清晰的水下图像。为解决此问题，Liang 等人[17]提出了一种自适应偏振图像恢复模型，该方法基于四叉树分解自动提取后向散射区域，进而估计背景光强和偏振度，有效抑制了后向散射光，减少了主观因素的影响。Shen 等人[14]则通过利用偏振物体和散射光之间的区别，并结合偏振信息，在光照较暗的区域也能实现对比度和细节的增强。

总体而言，偏振差分成像方法因其系统简单、计算高效，在水下图像增强领域取得了初步成果。然而，该方法仅利用两幅正交图像，信息维度有限，难以完整描述复杂的偏振信息[38]。当目标本身具有较强偏振特性时，基于目标光为非偏光的假设会导致估计误差[15]。此外，其在无明确背景区域或高度动态的复杂水下环境中，应用的稳定性和泛化能力仍面临挑战，因此其在动态和复杂水下环境中

的适用性和稳定性仍需要进一步提升。

1.2.2　基于斯托克斯矢量的水下偏振图像增强方法

相较于仅利用两幅正交图像的差分成像，基于斯托克斯矢量的成像方法通过采集三个或四个不同偏振态（如 0°、45°、90°、135°）下的图像，计算斯托克斯矢量（S0, S1, S2），从而精确估计图像的偏振度（DoP）和偏振角（AoLP）信息，为水下偏振图像的增强提供更丰富的数据。

早期的斯托克斯方法主要聚焦于参数估计精度的提升。Guan 等人[39]提出了一种基于斯托克斯矢量插值的偏振成像方法，有效克服了传统差分方法依赖固定偏振轴方向的局限，相较于偏振差分成像方法，该方法恢复的图像目标的对比度显著增强，背景噪声显著降低。Yang 和 Liang[37]则通过采用非偏振光源照明，避免了目标信号光自身偏振效应带来的复杂性，从而提高了后向散射光估计的精度，为后续的物理建模奠定了基础。

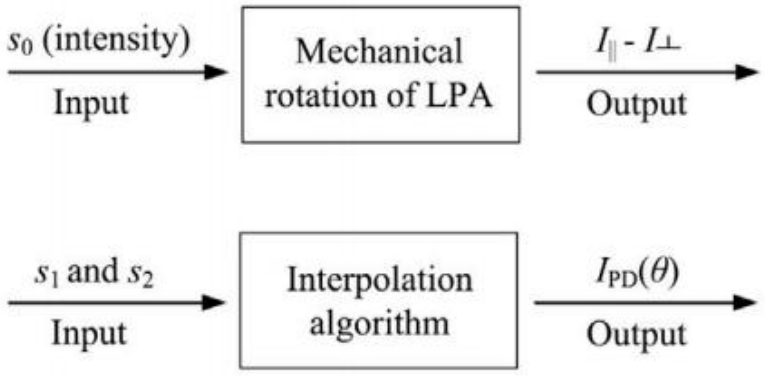


图 1.4 偏振差分成像方法（上）和基于斯托克斯矢量的方法（下）对比

针对传统方法依赖人工选择背景区域来估计后向散射偏振度（DoLP）所引入的主观误差问题，研究者们提出了一系列自适应方法。Zhang 等人[21]提出了一种基于大气光与入射光偏差的自适应估计方法，实现了光源偏振度的精确估算，显著提升了方法在不同水域条件下的适应性。Deng 等人[22]则融合斯托克斯矢量分析与低通滤波策略，无需依赖图像中的最亮或最暗区域，有效避免了背景区域选择的难题，并充分考虑了目标的偏振效应，使得不同 DoLP 值的目标得以更好地恢复。

近年来，随着对偏振信息理解的深入，研究者们开始探索如何从物理本质上挖掘 DoLP 与 AoLP 的联合规律，而非仅将其作为输入特征。Liang 等人[36]提出了一种基于三幅线偏振图像的去散射方法，其核心创新在于显式引入偏振角（AoLP）信息来约束去散射参数的估计，相较于仅依赖 DoLP 的方法，该方法在去除后向散

射的同时保留了更多场景的纹理细节。Su 等人[23]同时考虑了偏振度和偏振角信息，提出了一种新的复平面成像模型，有效利用了全偏振信息的几何约束，在恢复强度的同时也能恢复目标的偏振信息，达到了较优的水下图像恢复性能。Yang 等人[40]进一步发现，场景的偏振度在空间上并非随机分布，而是遵循偏振衰减先验，这一发现为准确重建场景的偏振信息提供了新的物理依据。

综上所述，斯托克斯矢量成像方法通过引入更高维度的偏振信息，有效降低了差分成像方法中主观因素的影响，并在提升图像复原精度方面展现出显著优势。然而，该方法仍面临若干挑战，例如，在高度浑浊的水下环境中，光的偏振信息会因多次散射而发生严重衰减与扭曲[23]，如何在这一条件下仍能稳健地提取有效的物理先验是提升复原效果的核心，也是该领域亟待突破的研究热点和难点。

1.2.3　基于深度学习的水下偏振图像增强方法

近年来，深度学习技术凭借其对复杂图像退化与恢复过程的建模能力，为水下偏振图像增强开辟了新的途径。这些方法主要分为有监督学习和无监督/自监督学习两大类。

在有监督学习方面，Hu 等人[26]首次将深度学习引入水下偏振成像，提出了基于密集连接的极化密集网络（PDN）（如图 1.5 所示）。该网络能够学习物体辐射度与多幅偏振图像之间的映射关系，表现出了良好的图像恢复能力。Zhou 等人[29]提出将物理模型嵌入网络设计，通过子网络分别估计关键参数，提升了方法的可解释性和泛化能力。Zhang 等人[27]则结合密集 U-Net 和信息流模型，采用加权均方误差和感知损失函数，有效提升了复杂水下环境中的图像恢复质量。Ding 等人[28]构建了多偏振融合生成对抗网络（GAN），用于学习偏振信息与物体辐射度之间的复杂关系，并为此建立了一个真实水下环境中的彩色偏振图像数据集。

虽然监督学习方法在图像复原上表现优异，但其性能高度依赖于大规模、高质量的成对训练数据。在真实水下环境中，获取严格对齐的“清晰-浑浊”偏振图像对极其困难，因此许多方法不得不依赖合成数据进行训练，这引入了领域迁移问题，导致模型在真实复杂场景中的泛化能力受限[29]。为了解决这一核心瓶颈，无监督/自监督学习范式逐渐成为研究热点。

Zhu 等人[41]提出了一种方法，将偏振物理模型与 U-Net 架构结合，网络本身无需在外部数据集上预训练，而是通过物理模型计算损失来优化网络参数，实现了无需成对数据的图像恢复。Shen 等人[35]提出了无监督的 U2PNet，该方法仅依赖一幅马赛克偏振图像，无需任何预训练数据集或特定的场景线索（如背景区域）。该方法设计了独特的无参考损失函数来引导网络训练，从而恢复出高质量的水下

图像。

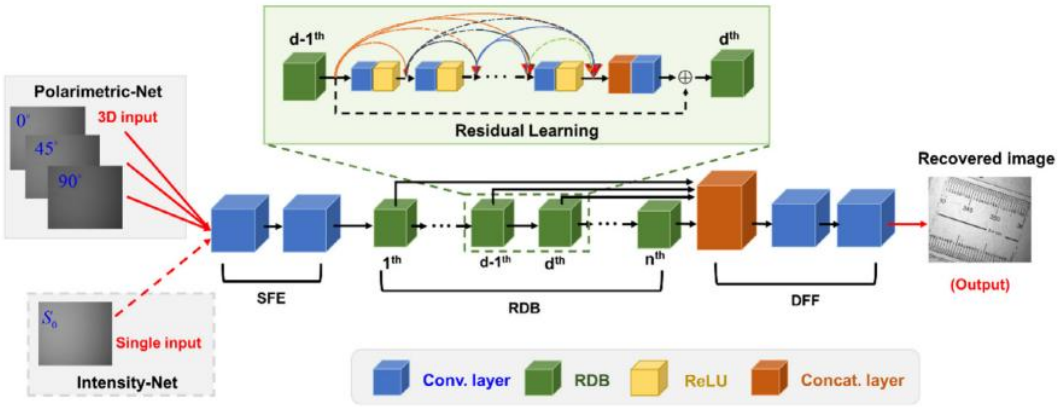


图 1.5 极化密集网络

综上所述，基于深度学习的水下偏振图像增强方法正从依赖大规模成对数据的有监督学习，转向更符合实际应用需求的无监督和自监督学习。这类方法虽然通过物理先验和精巧的网络设计绕过了数据获取的难题，但其性能高度依赖于损失函数的设计和网络结构的合理性。如何更有效地将偏振物理模型深度嵌入网络，引导其在无监督条件下更稳健、更快速地学习，同时提升恢复图像的色彩保真度和细节清晰度，是未来还需进一步探索的方向。

1.3　论文研究内容

现有的水下偏振去散射方法仍存在明显局限。一方面，传统的纯物理偏振去散射模型高度依赖环境参数的人工设定与繁杂的数值迭代求解，在面对水下动态变化的浑浊度与复杂场景时，参数估计的泛化性往往不足，且较高的计算开销严重限制了其在水下机器人等装备上的实时应用。另一方面，近年来兴起的深度学习方法虽然推理速度快，但其训练过程严重依赖“清晰-浑浊”水下图像对。在真实海洋环境中，获取此类成对参考真值几乎无法实现，而依赖人工合成数据训练的模型在应用于真实水域时容易产生域偏移和色彩失真。

因此，有必要进一步探索水下偏振信息的退化规律，并将其与深度学习的高效特征表达能力相结合，突破单一技术路径的局限。本文将深入探究偏振特征在复杂水体中的演化规律，并在此基础上构建一套从数据基础构建、物理模型优化到自监督网络学习的完整水下图像去散射技术体系。主要研究内容包括：

1. 多浑浊度、多场景真实水下偏振图像数据集的构建

针对现有水下偏振彩色数据集匮乏的问题，构建一套覆盖多浑浊度等级、包

含多种典型目标材质的真实水下偏振图像数据集。数据集包含两类图像：一类为不同浑浊度下的相同场景图像，每组数据包含对应的清晰参考图像作为恢复真值，可用于恢复效果的定量评估；另一类为相同浑浊度下的不同场景图像，分别在两个典型浑浊度条件下采集多个不同场景的四角度偏振图像，可用于研究不同场景对恢复算法的影响以及算法的泛化能力。该数据集将为偏振物理规律的验证、传统算法的评估以及深度学习模型的训练提供坚实的数据支撑，弥补当前领域内真实水下偏振数据匮乏的不足。

2. 融合多偏振先验的水下图像去散射物理方法研究

针对现有方法对偏振信息利用不充分等问题，深入挖掘水下环境中偏振信息的物理退化规律，建立一套无需人工标注的物理模型图像恢复方法。通过引入复平面偏振态的统一表征，揭示退化图像偏振态与目标本征偏振态、背景散射光偏振态之间的关系。在此基础上，设计背景光参数自动估计、偏振透射率优化求解等关键算法，最终实现场景颜色信息与全偏振信息的高保真恢复，提升方法在复杂水体中的鲁棒性与恢复精度。

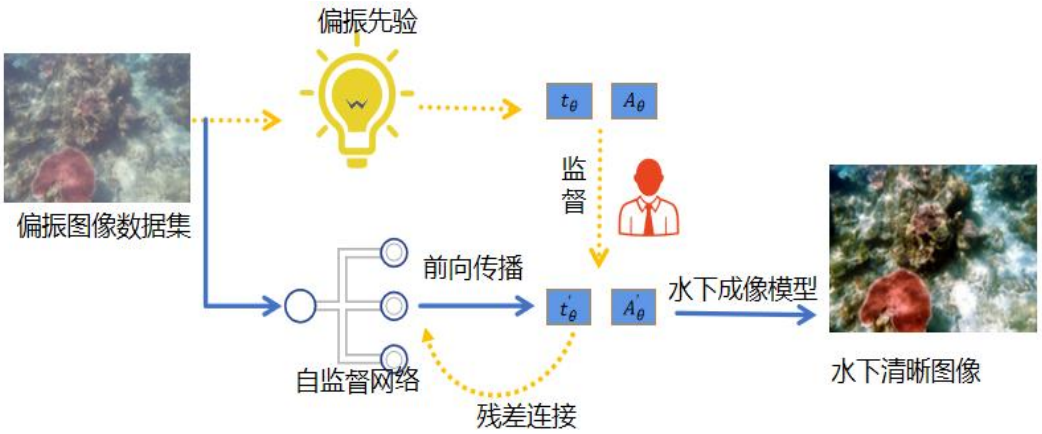


图 1.6 融合偏振先验的水下图像去散射网络流程图

3. 物理先验引导的自监督网络图像恢复方法

针对传统物理优化方法计算耗时长、参数鲁棒性不足，以及现有深度学习方法依赖成对训练数据的问题，本文旨在将挖掘得到的偏振物理先验与深度学习技术相结合，构建一种无需清晰标签的自监督图像恢复网络，技术框图如 1.6 所示。通过设计符合物理参数空间分布特性的双分支网络架构，实现局部透射率图与全局背景光参数的协同估计。并将偏振物理先验转化为可微分的无参考损失函数，引导网络在自监督优化过程中学习并遵循水下偏振退化规律。最终在保证恢复质量的同时，显著提升算法的计算效率，为水下机器人视觉感知等应用场景提供可行的技术方案。

1.4　论文章节安排

本论文共分为五个章节，各章节内容安排如下：

第一章是绪论部分，详细阐述了基于偏振成像的水下图像去散射技术的研究背景与意义。从偏振差分成像、斯托克斯矢量成像和深度学习三个角度系统综述国内外研究现状，总结现有方法的优势与不足，并在此基础上引出本文的主要研究内容和章节安排。

第二章介绍了水下偏振成像基础与数据集构建的内容，先介绍了偏振成像的基本理论，包括光的偏振态表示、斯托克斯矢量等核心概念，随后阐述经典的水下成像物理模型。同时详细介绍了本文水下数据集的构建方法，包括实验装置设计、不同浑浊度与不同场景的数据采集流程，并介绍本文采用的图像质量评估指标体系。

第三章是融合多偏振先验的水下图像去散射方法的介绍。本章深入研究水下环境中偏振信息的内在物理规律，首先推导了基于复平面的偏振态线性退化模型，详细阐述并实验验证偏振线先验、偏振衰减先验和偏振消色差先验。在此基础上，分别设计基于偏振线先验和基于 DoLP 衰减与消色差先验的图像恢复方法，并通过多尺度融合策略综合两者优势。通过不同偏振特性物体和不同浑浊度下的恢复实验，验证所提方法的有效性与优越性。

第四章介绍了物理先验引导的自监督水下图像恢复网络。针对物理优化方法的计算瓶颈，设计了一种双分支自监督网络架构。本章详细阐述了共享特征编码器、透射率估计子网络和背景光子网络的结构设计，重点介绍如何将偏振物理先验转化为可微分的无参考损失函数。通过在模拟数据集、真实水下数据集以及跨域雾霾数据集上的实验，对比主流方法，验证所提方法在恢复质量和计算效率上的综合优势，并通过消融实验分析各损失函数的作用。

第五章是总结与展望部分。对本文的研究工作和创新点进行了全面总结，分析当前方法可能存在的局限性，并对未来基于偏振成像的水下图像恢复技术的发展方向进行展望。

第 2 章　水下偏振成像原理与数据集构建

2.1　偏振成像基础

2.1.1　偏振光的基本概念

根据麦克斯韦（Maxwell）电磁场理论，光本质上是一种横向电磁波。在各向同性的均匀介质中，光波的电场矢量 **E** 和磁场矢量 **H** 相互垂直，且均垂直于光波的传播方向。由于在光电效应及人眼视觉响应中，电场矢量起绝对主导作用，因此光学界通常将电场矢量 **E** 定义为“光矢量”，其振动方向即代表光波的偏振方向。

设定光波沿 z 轴正方向传播，则电场矢量 **E** 位于垂直于传播方向的 x–y 坐标平面内。根据波的叠加原理，该电场矢量可分解为沿 x 轴和 y 轴方向的两个相互正交的简谐振动分量：

$$E_x(z,t)=E_{0x}\cos(kz-\omega t+\phi_x) \tag{2-1}$$

$$E_y(z,t)=E_{0y}\cos(kz-\omega t+\phi_y) \tag{2-2}$$

式中，E_{0x} 和 E_{0y} 分别表示电场矢量在 x 轴和 y 轴上的振幅；$k=2\pi/\lambda$ 为空间波数（λ 为波长）；ω 为角频率；ϕ_x 和 ϕ_y 为初始相位。

为了消去空间与时间变量 $(kz-\omega t)$，探讨电场矢量端点在空间中的运动轨迹，对上述两式进行联立推导，可得偏振光的轨迹方程：

$$\frac{E_x^2}{E_{0x}^2}+\frac{E_y^2}{E_{0y}^2}-2\frac{E_xE_y}{E_{0x}E_{0y}}\cos\delta=\sin^2\delta \tag{2-3}$$

式中，$\delta=\phi_y-\phi_x$ 表示两个正交分量之间的相位差，该方程在数学上是一个典型的椭圆方程，如图 2-1 所示。根据振幅比与相位差 δ 的不同组合，光波可呈现出线偏振光（$\delta=m\pi$）、圆偏振光（$E_{0x}=E_{0y}$ 且 $\delta=(m+1/2)\pi$）以及最一般的椭圆偏振光。

自然界中的光源（如太阳光、常规照明灯）由大量原子自发辐射产生，各波列相位无规则变化，是非偏振光。在水下成像场景中，自然光转化为部分偏振光，主要依赖于以下两种物理机制：

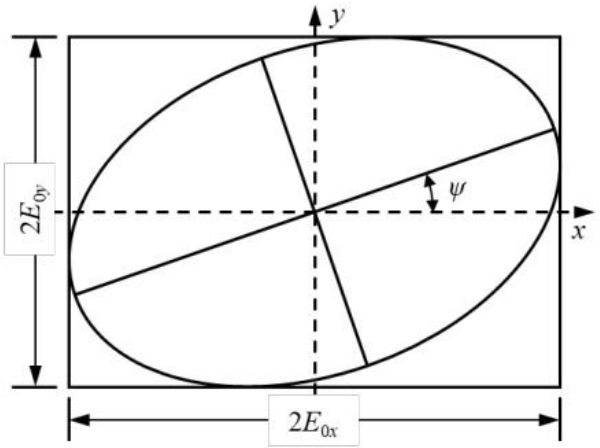


图 2.1 偏振椭圆

1. 表面反射偏振（菲涅尔定律）：当自然光入射到目标物体表面时，其反射光和折射光的偏振态会发生改变。根据菲涅尔（Fresnel）方程，垂直于入射面的 s 偏振分量和平行于入射面的 p 偏振分量具有不同的反射率。当入射角等于布儒斯特角时，反射光将变为完全的 s 线偏振光。

2. 微粒散射偏振（米氏散射）：当光波在水下传播时，会遇到大量悬浮颗粒。光波激发颗粒内部的偶极子发生受迫振动，进而向四周辐射出二次电磁波（即散射光）。在米氏散射框架下，不同角度的散射光具备不同的偏振度。这种由散射介质引起的偏振特性，为水下去散射模型中评估散射强度提供了重要依据。

2.1.2 斯托克斯参量及其测量

虽然电场矢量的振幅和相位能够完美描述偏振状态，但光波的振动频率极高（约 10^{14} Hz 量级），现有的光电探测器无法直接响应瞬时电场变化，只能测量时域平均光强。为了解决理论与工程测量之间的鸿沟，G. G. Stokes 提出了一种基于宏观光强可观测量的表征方法——斯托克斯参量。

斯托克斯矢量由四个具有相同量纲（光强）的实数元素组成，通常记为四维列向量 $\mathrm{S}=[\mathrm{S}_0,\mathrm{S}_1,\mathrm{S}_2,\mathrm{S}_3]^{\mathrm{T}}$。根据光矢量的时间平均理论，其数学定义为：

$$\mathbf{S}=\begin{bmatrix}S_0\\S_1\\S_2\\S_3\end{bmatrix}=\begin{bmatrix}\langle E_{0x}^2\rangle+\langle E_{0y}^2\rangle\\\langle E_{0x}^2\rangle-\langle E_{0y}^2\rangle\\2\langle E_{0x}E_{0y}\cos\delta\rangle\\2\langle E_{0x}E_{0y}\sin\delta\rangle\end{bmatrix} \tag{2-4}$$

其中，$\langle\cdot\rangle$ 表示时间平均。这四个参量中，S_0（即 I）代表总光强；S_1（即 Q）

代表 0° 与 90° 线偏振光强差；S_2（即 U）代表 45° 与 135° 线偏振光强差；S_3（即 V）代表右旋与左旋圆偏振光强差。由于自然水体对圆偏振光具有极强的吸收和退偏效应，水下到达探测器的圆偏振分量微乎其微。因此在水下视觉研究中通常作近似处理，假定 $S_3 \approx 0$。

在实际的偏振成像系统中，斯托克斯参量必须通过在探测器前放置透光轴角度为 θ 的线偏振片来间接测量。根据穆勒矩阵理论及马吕斯定律，当斯托克斯矢量为 $\mathbf{S}$ 的入射光穿过理想线偏振片后，探测器接收到的透射光强 $I(\theta)$ 与入射光斯托克斯参量之间存在极其严密的解析关系：

$$I(\theta)=\frac{1}{2}(S_0+S_1\cos 2\theta+S_2\sin 2\theta) \tag{2-5}$$

为了唯一确定 S_0, S_1, S_2 这三个未知参量，并抑制测量噪声，工程上通常选取 0°,45°,90°,135° 四个特定角度。将这四个角度分别代入光强透射公式，可得：

$$I(0^\circ)=I_0=\frac{1}{2}(S_0+S_1) \tag{2-6}$$

$$I(45^\circ)=I_{45}=\frac{1}{2}(S_0+S_2) \tag{2-7}$$

$$I(90^\circ)=I_{90}=\frac{1}{2}(S_0-S_1) \tag{2-8}$$

$$I(135^\circ)=I_{135}=\frac{1}{2}(S_0-S_2) \tag{2-9}$$

通过对上述方程组进行代数变换，即可得到斯托克斯参量与四角度探测光强之间的直接计算公式：

$$S_0=\frac{1}{2}(I_0+I_{45}+I_{90}+I_{135})\approx I_0+I_{90}=I_{45}+I_{135} \tag{2-10}$$

$$S_1=I_0-I_{90} \tag{2-11}$$

$$S_2=I_{45}-I_{135} \tag{2-12}$$

以上公式使得电磁波偏振参量（S_1, S_2）与探测器实际可捕获的四方向光强（$I_0, I_{45}, I_{90}, I_{135}$）建立了完备的数学映射。

基于解算出的前三个斯托克斯参量，可进一步推导出两个在水下去散射模型中重要的物理量：线偏振度（DoLP）和偏振角（AoLP）。

线偏振度（DoLP）表征完全线偏振光强度占总光强的比例。其与水下颗粒的散射强度及目标表面的粗糙度密切相关：

$$DoLP=\frac{\sqrt{S_1^2+S_2^2}}{S_0},\quad DoLP\in[0,1] \tag{2-13}$$

偏振角（AoLP）表征线偏振光最大强度方向与参考坐标轴的夹角，包含了目标的三维空间纹理信息：

$$AoLP=\frac{1}{2}\arctan\left(\frac{S_2}{S_1}\right),\quad AoLP\in\left[-\frac{\pi}{2},\frac{\pi}{2}\right] \tag{2-14}$$

2.2　水下成像模型

2.2.1　水体吸收与散射特性

光在水下传播过程中，其能量衰减主要由吸收与散射两种物理机制引起。吸收是指光在水体中传播时，部分光子能量被水分子及溶解物质（如黄色物质、叶绿素等）转化为热能或其他形式能量的过程。吸收效应具有显著的波长选择性：水分子对红光波段（600-700 nm）的吸收最强，对蓝绿光波段（450-550 nm）的吸收最弱。红光在传播很短距离后即被急剧衰减，而蓝绿光能够传播相对更远的距离，使得水下图像普遍呈现蓝绿色调。吸收效应主要导致目标信号光的整体能量衰减，但不改变光的传播方向。

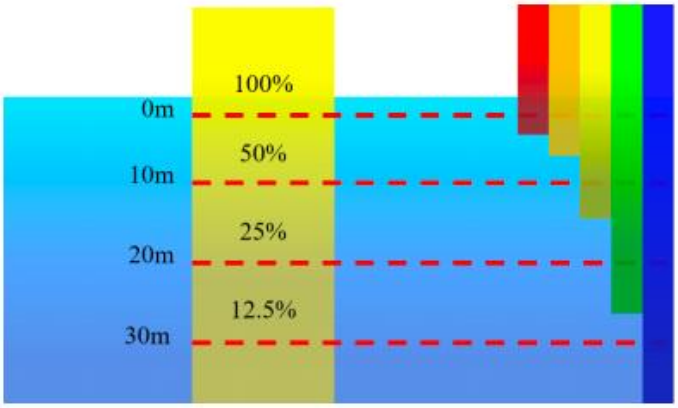


图 2.2 水下波长衰减图

散射是指光在传播过程中遇到悬浮颗粒（如泥沙、浮游生物、有机碎屑等）时，部分光子偏离原传播方向的现象。根据散射光相对于成像系统接收方向的不同，散射效应可分为前向散射和后向散射两类。

前向散射指光经过悬浮颗粒后仍保持大致前向传播，仅发生小角度偏折的现象。前向散射光仍携带目标物体的信息，但由于传播路径的微小差异导致相位发生畸

变，在图像上表现为高频细节的模糊和边缘锐度的下降，且前向散射的影响随成像距离增加而加剧。后向散射指光被悬浮颗粒反射后直接进入成像系统的现象。这部分光完全不携带目标物体的有效信息，却叠加在目标信号之上，在图像上形成类似“雾化”的效果，导致整体对比度严重下降，是水下图像质量退化的最主要因素。



图 2.3 水下图像（左：色彩失真 右：对比度下降）

2.2.2 经典水下光强成像模型

基于上述水体光学特性，Jaffe 和 McGlamery 等人于 20 世纪 90 年代提出了经典的水下光学成像模型。该模型将相机接收到的总辐照度分解为三个线性叠加的分量：前向散射分量、直接传输分量和后向散射分量。其数学表达形式为：

$$I(x,y)=E_d(x,y)+E_f(x,y)+E_b(x,y) \tag{2-15}$$

其中，(x,y)为像素坐标，水下成像示意图如图 2-4 所示。

$E_d(x,y)$表示直接传输分量，指目标反射光未经任何散射直接到达相机的部分。该分量严格服从几何光学定律，携带目标的本征结构信息，是图像复原期望恢复的理想信号。直接传输分量随传播距离呈指数衰减：

$$E_d(x,y)=J(x,y)\cdot e^{-\beta(\lambda)\cdot d(x,y)}=J(x,y)\cdot t(x,y) \tag{2-16}$$

式中，$J(x,y)$为目标本征辐射亮度，即待恢复的清晰图像；$\beta(\lambda)$为与波长λ相关的体积衰减系数；$d(x,y)$为场景深度；$t(x,y)=e^{-\beta d}$为透射率，表征信号光经水体衰减后剩余的比例。

$E_f(x,y)$表示前向散射分量，指目标反射光在传播路径中经悬浮颗粒小角度散射后进入相机的部分，可视为直接传输分量与点扩散函数的卷积。在浑浊度适中或成像距离不太远的条件下，前向散射的影响通常远小于后向散射，许多水下图像

复原研究为简化模型可忽略该分量。

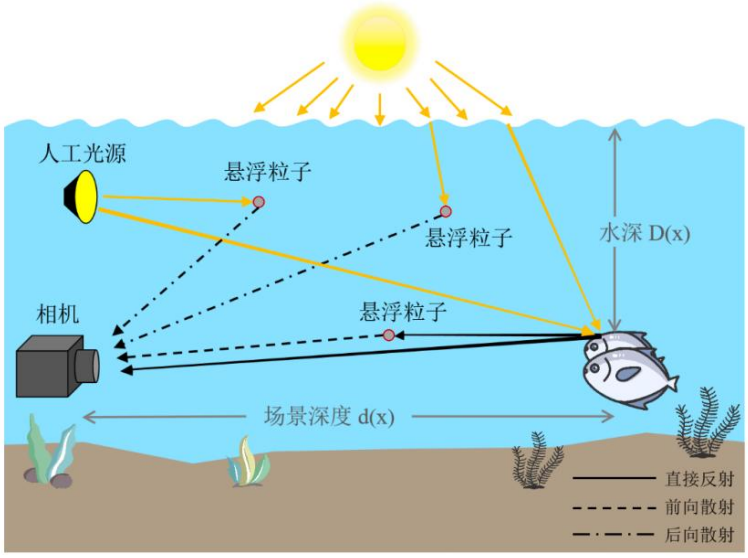


图 2.4 水下成像示意图

$E_b(x,y)$ 表示后向散射分量，指非目标路径上的环境光被水体中悬浮颗粒散射后直接进入相机的部分。这部分光完全不携带目标信息，但叠加在有效信号上，是导致水下图像对比度下降的主要因素。后向散射随成像距离增加而增大，可表示为：

$$E_b(x,y)=B_\infty(x,y)\cdot\ (1-e^{-\beta d(x,y)})=B_\infty(x,y)\cdot\ (1-t(x,y)) \tag{2-17}$$

式中，B_∞表示无穷远处背景光强度，即水体在无目标遮挡情况下的散射光强度。在均匀水体假设下，B_∞在全图范围内可视为常数。

忽略前向散射，经典水下光强成像模型可重写为：

$$I(x,y)=J(x,y)\cdot t(x,y)+B_\infty\cdot\ (1-t(x,y)) \tag{2-18}$$

该模型构成了几乎所有水下图像复原算法的理论基础。其物理意义表示为：观测图像 I 是目标本征信号 J 与背景散射光 B_∞ 的加权叠加，权重由透射率 t 决定。当 $t=1$ 时，对应纯净水体中的清晰成像；当 $t=0$ 时，观测图像完全被背景散射光淹没。

2.3　水下偏振数据集构建

2.3.1　采集平台搭建与散射介质物理模拟

为了精准控制环境变量并获取高质量的偏振数据，本文在暗室环境下搭建了专用的水下偏振成像采集平台，实验设置如图 2.5 所示。实验装置的核心组件包括光源系统、水下模拟容器与偏振接收系统。

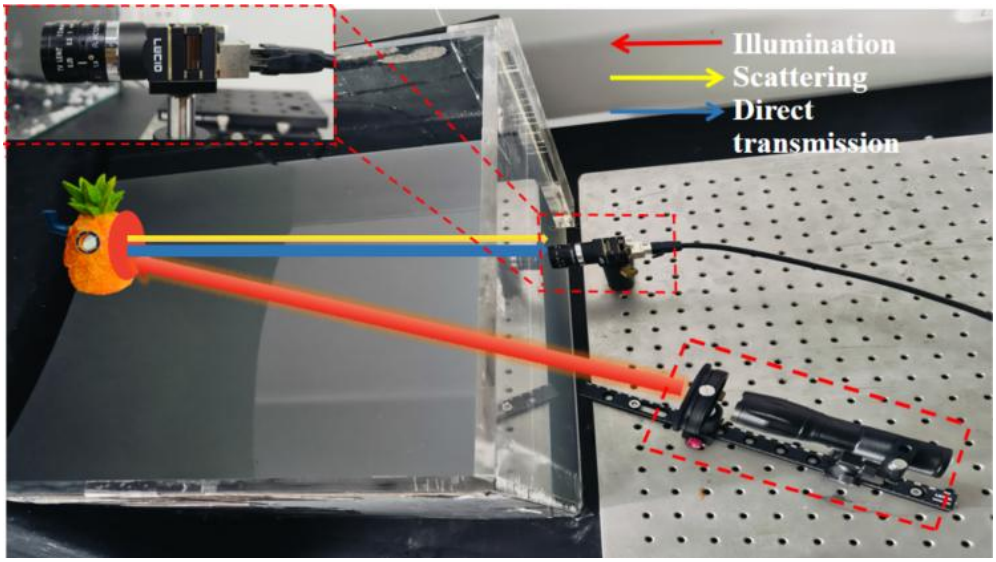


图 2.5 数据集收集实验装置

本文采用了主动偏振照明方案，在宽光谱白色 LED 面光源前方放置了一片高质量的线性偏振片，引入主动偏振光照射，使得捕获的图像包含更多明显的偏振信息，为后续的图像恢复算法提供更丰富的物理约束。

成像模块采用分焦平面偏振相机（LUCID, PHX050S-QC），该相机基于 Sony IMX250MZR 传感器，在全局快门 CMOS 芯片上集成了微偏振光栅阵列，如图 2.6 所示。阵列以 2×2 个像元为一个重复单元，分别覆盖透光轴方向为 0°、45°、90° 和 135° 的金属线栅微偏振片，因此能够在单次曝光内同步采集同一场景在四个偏振方向上分辨率为 2448×2048 的强度图像，避免了分时偏振成像中因水波微小扰动带来的空间不对齐问题。

水体模拟模块采用高透光率亚克力材质水槽，尺寸为 35 cm（宽）×60 cm（长）×40 cm（高），实验时液面高度保持为 25 cm。目标物体放置于水槽内，距离水槽前壁面约 50cm。为模拟真实水下环境的浑浊介质，本文选用脱脂牛奶与清水混合的方式来制备不同浊度的水体。

基于米氏散射理论，脱脂牛奶能够有效模拟水下悬浮颗粒的散射特性。自然

水域中的浑浊主要由悬浮颗粒物引起，这些颗粒的粒径分布广泛，其中大部分颗粒直径与可见光波长处于同一量级（0.1~10 μm），其散射行为符合米氏散射的描述。脱脂牛奶中含有大量酪蛋白分子（粒径约 0.04~0.3 μm）和脂肪球颗粒（粒径约 1~20 μm）[47][48][49]，这些颗粒的尺寸分布恰好覆盖了从瑞利散射区（粒径远小于波长）到米氏散射区（粒径与波长相近）的完整范围，与海水中的浮游植物、碎屑及矿物颗粒的尺寸分布高度相似[51]。

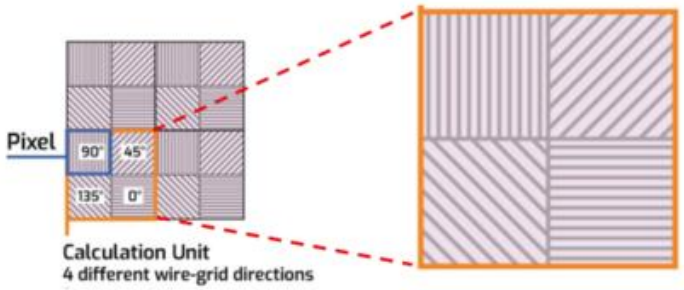


图 2.6 相机传感器的微阵列结构

当线偏振光入射至牛奶混合溶液时，光子与这些悬浮颗粒发生碰撞，部分光子改变传播方向形成后向散射光，同时其偏振态发生退偏，由完全偏振光退化为部分偏振光。这一物理过程与光在真实海水中的传播机制完全一致。此外，脱脂牛奶的散射系数适中（约为 $0.42cm^{-1}$每百分含量[47][52]），便于通过控制加入量来精细调节水体浊度，且混合溶液性质稳定，能够在实验期间保持浊度基本不变。基于上述原因，脱脂牛奶被广泛用于水下光学成像的模拟实验研究中，并被证明是模拟自然水体散射特性的有效介质[47][50][49]。

实验中采用浊度计测量混合水体的浊度值，单位为散射浊度单位（NTU）。浊度计基于散射法原理，通过测量 90° 方向散射光强度来定量表征水体的浑浊程度。

2.3.2　不同浑浊度的水下偏振数据集构建

为研究不同水体浑浊度对成像质量的影响以及验证算法在不同散射强度下的恢复性能，本文构建了多浑浊度等级的模拟水下偏振图像序列。通过向清水中逐次加入定量的脱脂牛奶，并充分搅拌使其均匀混合，获得从清澈到高度浑浊的系列水体环境。每次加入牛奶后，使用浊度计测量当前水体浊度，并利用分焦平面偏振相机同步采集同一场景的 0°、45°、90° 和 135°四角度偏振图像。

实验共设置了 6 个典型浊度等级，依次为 11.6 NTU、18.9 NTU、28.6 NTU、36.8 NTU、43.6 NTU 和 52.7 NTU，覆盖了从轻度浑浊到高度浑浊的常见水下环境范围。在每个浊度等级下，均采集了同一场景的四角度偏振图像，并同时采集纯净水体中相同场景的清晰图像作为恢复真值（Ground Truth）。图 2.7 展示了不同浊度下采集的原始强度图像（由 S0 = I0°+I90°合成）及其对应的真值图像示例。



图 2.7 数据集-不同浑浊度下的相同场景

该部分数据集的核心特点在于：同一场景、不同浊度、包含真值。这为后续算法计算复原图像与真值图像之间的结构相似性指数 (SSIM) 和峰值信噪比 (PSNR) 和定量评估提供了基础，可以客观、准确地衡量不同方法在不同散射强度下的恢复性能。

2.3.3 不同目标物体的水下偏振数据集构建

真实水下场景中目标物体的材质多种多样，不同材质物体的偏振特性差异显著。为验证算法对不同偏振特性物体的恢复能力以及评估其泛化性能，本文进一步构建了相同浑浊度下的多场景偏振图像数据集。

实验选取了两个典型浊度等级：28.6 NTU（中等浑浊）和 36.8 NTU（较高浑浊）。在每个固定浊度下，更换水槽中的目标物体组合，采集多个不同场景的四角度偏振图像。目标物体涵盖了具有不同偏振特性的典型材质，包括：金属材质（高偏振特性，如金属刀片、金属玩具）、塑料材质（中等偏振特性，如塑料玩具、塑料管件）、木质材质（中低偏振特性，如木制卡通图案）、纸质材质（低偏振特性，如油漆纸、纸盒）以及仿真礁石、布料等。每个场景均采集 0°、45°、90° 和 135° 四个方向的偏振图像。图 2.8 和图 2.9 分别展示了浊度为 28.6 NTU 和 36.8 NTU 时采集的部分场景示例。该部分数据集共包含 7680 张四角度偏振图像，

是目前规模最大的真实水下偏振图像数据集。



图 2.8 相同浑浊度下的不同场景数据集（浊度 28.6 NTU）



图 2.9 相同浑浊度下的不同场景数据集（浊度 36.8 NTU）

该部分数据为验证算法的泛化性能提供了理想测试平台，可以通过无参考图像质量评价指标（如 UIQM、UCIQE）评估算法在不同目标材质、不同场景结构下的恢复效果稳定性。

2.4　水下图像质量评估指标

为全面、客观地量化水下图像去散射算法的性能，本节构建了由两类评价指标组成的综合量化评估体系：包括针对成对数据的全参考指标、针对无标签水下图像的无参考指标。

2.4.1　全参考指标

对于包含清晰参考图的数据集，本文采用结构相似性指数（SSIM）和峰值信噪比（PSNR）两项经典的全参考客观指标。

峰值信噪比（PSNR）主要从像素级维度衡量复原图像与参考图像之间的绝对误差，其基础是均方误差（MSE）。PSNR 值越高，表明复原图像在像素层面的

失真程度越低。其数学定义为：

$$\mathrm{PSNR}=10\cdot\log_{10}\left(\frac{MAX_I^2}{\mathrm{MSE}}\right) \tag{2-19}$$

其中，MAX_I 表示图像像素的最大可能取值，对于常规 8 位图像，该值为 255。MSE 的计算公式为：

$$\mathrm{MSE}=\frac{1}{H\times W}\sum_{i=0}^{H-1}\sum_{j=0}^{W-1}[X(i,j)-Y(i,j)]^2 \tag{2-20}$$

式中，H 和 W 分别代表图像的高度和宽度；$X(i,j)$与 $Y(i,j)$ 分别表示参考图像与复原图像在空间坐标 (i,j) 处的像素强度。

结构相似性指数（SSIM）与像素级绝对误差不同，它更贴近人类视觉系统的感知特性。它从亮度、对比度与结构信息三个独立维度综合评估图像间的相似程度。SSIM 的取值区间为 [0,1]，若两幅图像的结构相似度越高，得分将越趋近于 1，其定义如下：

$$\mathrm{SSIM}(X,Y)=\frac{(2\mu_X\mu_Y+C_1)(2\sigma_{XY}+C_2)}{(\mu_X^2+\mu_Y^2+C_1)(\sigma_X^2+\sigma_Y^2+C_2)} \tag{2-21}$$

其中，σ_X^2 与 σ_Y^2 表示的是对应的局部方差，图像 X 和 Y 的局部像素均值用 μ_X 与 μ_Y 分别表示；σ_{XY} 为两者的协方差；C_1 和 C_2 则是为防止分母趋零而引入的稳定常数。

2.4.2　无参考指标

考虑到真实水下环境中获取绝对清晰参考图像的极端困难性，无参考图像质量指标在此类任务中具有不可替代的工程实用价值。本文选取了两种专为水下视觉特性设计的无参考度量标准。

水下彩色图像质量评价（UCIQE[53]）基于 CIELab 色彩空间的统计特征构建。UCIQE 通过线性组合亮度对比度、色度标准差与饱和度均值，有效量化了水下图像典型的非均匀色偏、细节模糊及对比度衰减等退化现象：

$$\mathrm{UIQE}=c_1\cdot\sigma_c+c_2\cdot\mathrm{con}_l+c_3\cdot\mu_s \tag{2-22}$$

其中，σ_c 为色度标准差，用于表征图像色彩的丰富度，该项能有效抵御人工光源高光斑带来的干扰，并刻画水体选择性吸收造成的色偏；con_l 为亮度对比度，由亮度通道中最高 1% 与最低 1% 像素值的差值界定，反映水体浑浊导致的灰度

压缩；μ_s 为饱和度均值，直接衡量色彩信息的留存率。经验证的主观实验多元线性回归权重分别为 c_1=0.4680，c_2=0.2745，c_3=0.2576。

水下图像质量度量（UIQM[54]）受到人类视觉系统启发，从色彩、清晰度与局部对比度三个维度对水下图像进行综合打分，它由三个子度量模块线性组合而成：

$$\mathrm{UIQM}=c_1\cdot \mathrm{UICM}+c_2\cdot \mathrm{UISM}+c_3\cdot \mathrm{UIConM} \tag{2-23}$$

水下图像色彩度量（UICM）依据对立色理论，在红-绿（RG）与黄-蓝（YB）颜色空间内进行评估。为滤除人工光源过曝及悬浮物颗粒（椒盐噪声）的干扰，采用非对称阿尔法截尾均值与方差：

$$\mathrm{RG}=R-G,\quad \mathrm{YB}=\frac{R+G}{2}-B \tag{2-24}$$

$$\mu_{\mathrm{RG}}=\frac{1}{N-\alpha_{\min}-\alpha_{\max}}\sum_{i=\alpha_{\min}+1}^{N-\alpha_{\max}}\mathrm{RG_i} \tag{2-25}$$

$$\sigma^2_{\mathrm{RG}}=\frac{1}{N-\alpha_{\min}-\alpha_{\max}-1}\sum_{i=\alpha_{\min}+1}^{N-\alpha_{\max}}(\mathrm{RG}_i-\mu_{\mathrm{RG}})^2 \tag{2-26}$$

设定截尾比例 $\alpha_{\min}=\alpha_{\max}=0.1$，即剔除两端极值像素的 10%。$\mu_{\mathrm{YB}}$ 与 σ^2_{YB} 的计算同理。最终色彩度量公式为：

$$\mathrm{UICM}=-0.0268\sqrt{\mu^2_{\mathrm{RG}}+\mu^2_{\mathrm{YB}}}+0.1586\sqrt{\sigma^2_{\mathrm{RG}}+\sigma^2_{\mathrm{YB}}} \tag{2-27}$$

式中，负系数均值项用于评估白平衡（越趋近零色彩平衡越佳），正系数方差项用于评估色彩动态范围。

水下图像清晰度度量（UISM）基于增强度量估计。对 RGB 各通道进行 Sobel 边缘检测，提取灰度边缘图后分块（$k_1\times k_2$）计算 EME：

$$\mathrm{EME}=\frac{2}{k_1k_2}\sum_{l=1}^{k_1}\sum_{k=1}^{k_2}\log\left(\frac{I_{\max,k,l}}{I_{\min,k,l}}\right) \tag{2-28}$$

结合人眼对不同波段光敏感度的差异，按权重（λ_R=0.299，λ_G=0.587，λ_B=0.114）组合各通道得分：

$$\mathrm{UISM}=\sum_{c\in\{R,G,B\}}\lambda_c\cdot \mathrm{EME}(\text{灰度边缘图}_c) \tag{2-29}$$

水下图像对比度量（UIConM）引入参数化对数图像处理模型计算分块

logAMEE 值：

$$\mathrm{UIConM}=\frac{1}{k_1k_2}\otimes\sum_{l=1}^{k_1}\sum_{k=1}^{k_2}\left[\frac{I_{\max,k,l}\Theta I_{\min,k,l}}{I_{\max,k,l}\oplus I_{\min,k,l}}\times\log\left(\frac{I_{\max,k,l}\Theta I_{\min,k,l}}{I_{\max,k,l}\oplus I_{\min,k,l}}\right)\right] \tag{2-30}$$

其中 $\oplus$、Θ 与 $\otimes$ 均代表 PLIP 算子，该非线性运算模型高度契合人眼在弱光、低对比度水下环境中的视觉响应规律。

2.5　本章小结

本章系统阐述了水下偏振成像的理论基础与实验准备，为后续偏振先验挖掘与自监督网络设计提供了理论支撑与数据保障。

在理论层面，从光的电磁波本质出发，阐述了偏振光的基本概念与斯托克斯参量表征方法，推导了线偏振度（DoLP）与偏振角（AoLP）的计算公式。同时，分析了水体吸收与散射的物理机制，介绍了经典水下光强成像模型 (Jaffe-McGlamery 模型），为第 3 章偏振退化模型的建立奠定了理论基础。

在数据层面，搭建了主动偏振照明与分焦平面偏振相机相结合的采集平台。基于米氏散射理论，论证了脱脂牛奶模拟水下悬浮颗粒散射特性的物理可行性，并构建了包含两类子集的水下偏振图像数据集：一是不同浑浊度下的相同场景数据集（6 个浊度等级，含真值），用于算法定量评估；二是相同浊度下的不同材质目标物体的数据集（7680 张图像），用于泛化性能测试。

在评估层面，建立了综合质量评价体系，针对有真值数据采用 PSNR 与 SSIM 指标，针对无真值真实场景采用 UCIQE 与 UIQM 两种水下专用无参考指标，从色彩、清晰度、对比度等多维度量化复原效果。

本章工作为后续研究提供了物理理论、实验数据与量化评估三方面支撑。第 3 章将在本章基础上，进一步挖掘水下偏振信息的内在物理规律，建立基于多偏振先验的图像恢复方法；第 4 章则将本章构建的数据集作为支撑，发展物理先验引导的自监督网络，实现高效鲁棒的水下去散射。

第 3 章　融合多偏振先验的水下图像去散射方法

3.1　引言

水下光学成像作为海洋探测与水下机器人视觉感知的重要手段，其图像质量直接决定了后续目标识别、三维重建等高级视觉任务的性能上限。然而，水体中溶解物与悬浮颗粒对光传播路径的强烈吸收与散射作用，导致捕获的图像普遍存在对比度骤降、细节湮没以及严重的色彩偏移现象，这一问题在浑浊水域中尤为凸显。从物理成像机制来看，水下图像降质本质上是一个高度欠定的逆问题：观测到的退化光强是包含目标本征信息的直接透射光与后向散射光的非相干叠加。理论上，若能精确估计透射率和全局背景光，即可依据 Jaffe-McGlamery 水下成像模型逆推恢复出清晰图像。然而，单张 RGB 图像仅提供有限的强度和光谱信息，难以支撑复杂介质参数的鲁棒求解。传统的基于先验的方法，如暗通道先验、颜色线先验等，虽在常规水体中取得了一定成效，但在浓雾或高浑浊水体中极易被破坏，导致透射率过估或背景光选取偏差，最终使复原结果伴随顽固的光晕伪影和色彩失真。

偏振成像技术的引入为突破上述瓶颈提供了全新的高维信息维度。与仅记录光强的 RGB 成像不同，偏振成像能够捕获光波的矢量场信息，包括线偏振度 (DoLP) 与偏振角（AoLP）。光在介质中传播时，直接透射光往往保留着目标材质的本征偏振特征，而后向散射光则因水体颗粒的多次散射呈现出高度稳定的介质偏振态。这种物理属性的本质差异，为在物理层面分离信号与噪声提供了坚实的理论基石。然而，现有的偏振去散射方法大多存在局限性：早期研究假设场景辐射光为非偏振光，忽略了其本身携带的偏振信息；后续方法虽考虑了 DoLP，但通常忽略 AoLP 的作用，将问题简化为标量求解，这不仅限制了恢复精度的上限，也无法在去散射后恢复场景的真实偏振状态。少数利用全偏振信息的方法往往需要人工选取天空区域或依赖特定线索估计背景光参数，且对空间变化的背景光偏振态处理不足。

针对上述问题，本章旨在建立一个更为完备、能同时描述 DoLP 与 AoLP 退化的物理模型，并深入挖掘水下散射环境中偏振信息固有的物理规律。核心思想在于：清晰图像的偏振信息在空间上是稀疏且可聚类的，而散射过程则使这些信息在复数域上呈现出特定的几何约束（如直线）和统计特性（如线性衰减）。基于此，本章首先构建一个基于复平面的全偏振成像模型，将偏振信息的退化过程简化为直线方程。随后，通过分析大量数据，提炼出“偏振线先验”、“偏振消色差先

验”和“偏振衰减先验”等多个物理先验。在此基础上，设计系统性的参数估计方法，包括背景散射光偏振态的估计、基于角度聚类的偏振线检测、偏振透射率的求解与优化，进而实现场景颜色与全偏振信息的高保真恢复。为进一步提升恢复图像的视觉质量，本章还引入多尺度拉普拉斯金字塔融合策略，将基于复平面偏振态和基于 DoLP 与消色差先验的两种恢复结果进行自适应融合，综合两者的优势。最后，通过不同浑浊度和不同偏振特性物体的真实水下图像实验，验证本章方法的有效性和优越性。

本章的结构安排如下：3.2 节从 Jaffe-McGlamery 水下成像模型出发，推导包含全偏振信息的复平面成像模型，并详细介绍偏振线先验、偏振衰减先验和偏振消色差先验的理论推导与物理验证; 3.3 节阐述基于复平面偏振态的图像恢复方法，包括背景散射光估计、角度聚类、偏振透射率估计与优化以及场景图像恢复的具体步骤；3.4 节介绍基于 DoLP 与消色差先验的图像恢复方法，涵盖背景光参数估计、偏振传输图估计、场景 DoLP 与强度图像恢复的详细过程；3.5 节给出多尺度拉普拉斯金字塔融合策略的设计与实现；3.6 节通过实验验证本章方法在不同浑浊度和不同偏振特性物体上的恢复性能，并进行消融实验与参数分析；3.7 节对本章内容进行总结。

3.2 偏振先验的理论推导与物理机制分析

3.2.1 水下偏振态退化理论

回顾第 2 章所述的斯托克斯（Stokes）矢量，完全线偏振光的状态可由前三个 Stokes 参数S_0,S_1,S_2完备描述。对于自然界中常见的线偏振场景，圆偏振分量S_3极弱，可近似为零。在实际成像系统中，通过分焦平面偏振相机可同步捕获0°,45°,90°,135°四个角度的强度图像，进而计算出相应的 Stokes 参数。

为简化高维矢量的分析，Su 等提出将二维偏振信息压缩至一个复数变量，定义复偏振态如下：

$$m(x,y) = \frac{S_1(x,y)+iS_2(x,y)}{S_0(x,y)} \tag{3-1}$$

其中 $i=\sqrt{-1}$为虚数单位。由 Stokes 参数的定义可知，$S_0>0$ 恒成立，因此该定义在图像所有像素点上均有良好定义。复偏振态 m 的物理意义可通过其极坐标形式直观揭示：

$$m=\rho e^{2i\phi}=\rho(\cos 2\phi+i\sin 2\phi) \tag{3-2}$$

其中，复数的模长 $\rho=|m|\in[0,1]$即为线偏振度，辐角的一半为线偏振角。

图 3.1 显示了复偏振态的几何意义示意图。复平面上一点到原点的径向距离代表 DoLP，与正实轴的夹角代表 2 倍的 AoLP，该表示将两个偏振物理量统一为了一个复数。

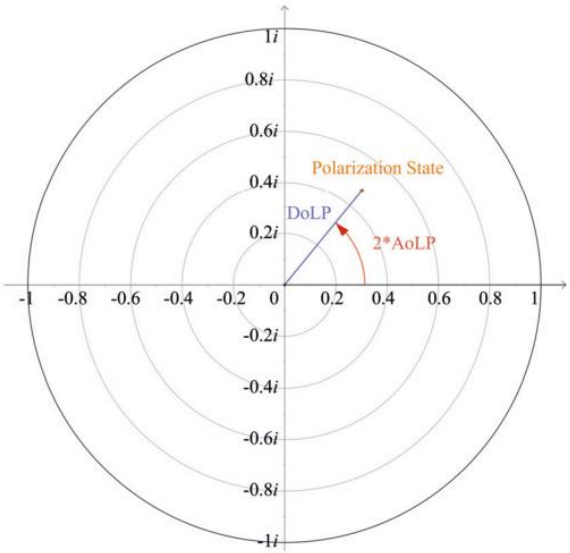


图 3.1 极化状态、DoLP、AoLP 关系

根据水下成像模型，忽略极其微弱的前向散射后，成像系统接收的总光强可表示为直接透射光与后向散射光的线性叠加：

$$I(x)=D(x)+B(x) \tag{3-3}$$

其中 x = (x,y) 为像素空间坐标, D(x) = J(x)t(x) 为携带目标本征信息的直接透射光，$B(x)=A_{\infty}(1-t(x))$ 为介质散射产生的纯噪声背景光。$t(x)\in[0,1]$ 为透射率，A_{∞} 为无穷远处背景光强。

光波在介质中传输时，其偏振态的幅度虽受介质散射影响而衰减，但在单次散射近似下，偏振态的方向信息（即偏振角）得以保持，即直接透射光与目标本征光的偏振态相同，而背景光与无穷远处全局背景光的偏振态相同。数学上可表述为：

$$m_D(x)=m_J(x),\quad m_B(x)=m_{A_{\infty}} \tag{3-4}$$

将 Stokes 参数的线性叠加性质应用于式(3-3)的两端，并结合式(3-1)，可进行如下推导：

$$m_I=\frac{S_1^I+iS_2^I}{S_0^I}=\frac{(S_1^D+S_1^B)+i(S_2^D+S_2^B)}{S_0^D+S_0^B}=\frac{S_0^D}{S_0^I}\cdot\frac{S_1^D+iS_2^D}{S_0^D}+\frac{S_0^B}{S_0^I}\cdot\frac{S_1^B+iS_2^B}{S_0^B} \tag{3-5}$$

利用强度关系 $S_0^D=D(x)$、$S_0^B=B(x)$，定义偏振透射率 $r(x)=D(x)/I(x)\in[0,1]$，则 $B(x)/I(x)=1-r(x)$。代入上式，得到偏振特征域的散射成像叠加公式：

$$m_I(x)=r(x)\cdot m_D(x)+(1-r(x))\cdot m_B(x) \tag{3-6}$$

式(3-6)表明退化图像的偏振态是目标本征偏振态与背景光偏振态的组合，在形式上与经典的强度域模型完全对称。该公式在不施加“目标无偏振”等经验假设的前提下，保证了偏振退化模型在自然场景中的一般性与准确性。

3.2.2 偏振线先验

由式(3-6)可知，对于任意固定像素 x，三个复变量 $m_I(x)$、$m_D(x)$和 $m_B(x)$ 在复平面上必然共线，且偏振态 $m_I(x)$ 落在连接 $m_D(x)$ 与 $m_B(x)$ 的线段上。

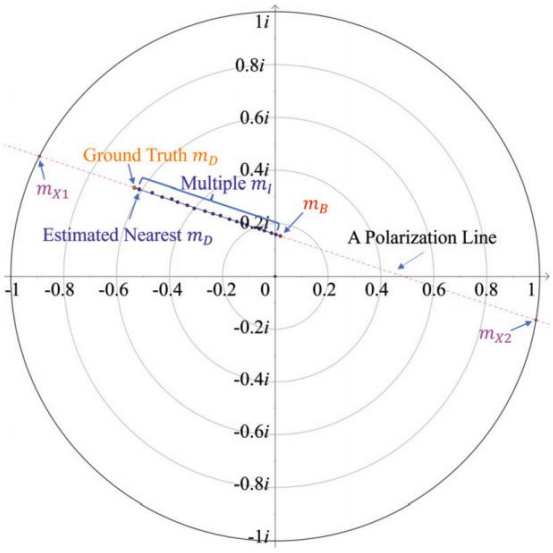


图 3.2 偏振线先验几何分布

不同于传统暗通道先验(DCP)依赖于局部空间滑窗，本文在偏振特征空间中引入以下两个全局假设：

1.目标偏振聚类一致性假设：自然场景中具有相似材质或微观表面粗糙度的物体，其本征偏振属性具有高度一致性。因此，我们将图像划分为若干个聚类簇Ω_k。在同一个聚类簇内，所有像素偏振态相似，即 $m_D(x)\approx m_D^{(k)},\forall x\in\Omega_k$。

2.背景光全局偏振一致性假设：背景光源于水体介质对光线的多次散射，其分布受水体光学特性主导。在同一水下场景中，由于介质的均匀性，全局背景光的偏振态在空间上可以视为常数。同时，背景光源于水体介质的多次散射，在局部小区域内空间分布均匀，其偏振态可视为常数，即 $m_B(x)\approx m_B^{\Omega},\forall x\in\Omega$。

在此假设下，式(3-6)在同一偏振簇内退化为关于偏振透射率 $r(x)$ 的线性函数：

$$m_I(x)=m_B^{\Omega}+(m_D^{\Omega}-m_B^{\Omega})\cdot r(x),\quad \forall x\in\Omega_k \tag{3-7}$$

由（3-7）可知，在满足目标与背景光偏振一致性假设的局部图像块 Ω_k 内，所有像素的观测偏振态 $m_I(x)$ 在复平面上精确地位于同一条直线上。该直线由目标偏振态 $m_D^{(k)}$ 与背景光偏振态 m_B 唯一确定，且必经过背景光偏振点。

图 3.2 显示了偏振线先验在复平面上的几何分布示意图。红色点表示背景光偏振态 m_B^{Ω}，蓝色点表示目标本征偏振态 m_D^{Ω}，黑色散点为不同像素的观测偏振态 $m_I(x)$。所有观测点均落在连接两者的直线上，其位置反映了透射率 $r(x)$ 的差异。

偏振线先验突破了传统 RGB 颜色空间（如雾线先验）的局限，直接在底层偏振复平面上刻画了介质散射过程中的共线分布规律，为神经网络提供了无需清晰标签的强有力几何约束。

3.2.3 偏振度量化与线性衰减规律验证

对式(3-6)两端取模，可得总偏振度ρ_I的展开式：

$$\rho_I^2=r^2\rho_D^2+(1-r)^2\rho_B^2+2r(1-r)\rho_D\rho_B\cos(2\Delta\phi) \tag{3-8}$$

其中 $\rho_D=|m_D|$、$\rho_B=|m_B|$ 分别为目标和背景光的 DoLP，$\Delta\phi=\phi_D-\phi_B$为两者偏振角之差，式（3-8）表明透射率 r 与观测 DoLP 之间存在一一对应关系。

先前的研究[55]表明，图像中不同颜色的数量远少于像素的数量[56]，且清晰图像的聚类像素经过雾的退化后，在 RGB 三维空间中的聚类点会往大气光方向呈线性退化，如图 3.3[55]所示。

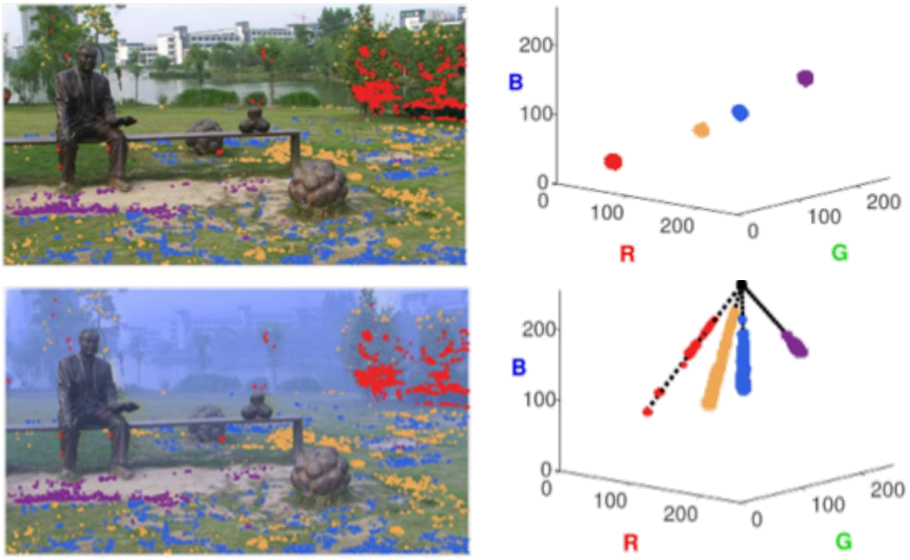


图 3.3 有雾图像颜色退化

我们推测类似的现象也适用于偏振度 (DoLP) 图像, 即仅用几百个不同的 DoLP 值就能很好地近似表示整个 DoLP 图像。为从真实物理统计角度验证这一单调衰减关系，本文结合第 2 章中利用光学水槽与牛奶散射介质构建的水下偏振数据集进行了验证。

实验通过 K-means 聚类算法，将不同浑浊度下的偏振特征划分为 K=400 个聚类簇。每个聚类簇代表具有相似本征材质或深度的像素集合。本文用相应的聚类中心替换每个 DoLP 值。随后计算量化前后 DoLP 图的相似度指标——信噪比（PSNR），实验表明处理后的聚类 DoLP 图像与原始图像相比，保持了较高的信噪比（PSNR），均值为 38.41 dB。图 3.4(a)展示了原始 DoLP 图像，图 3.4(b)为其量化后的版本，图 3.4(c)为差值。



(a) 原始 DoLP 图像　　(b) 量化后的 DoLP 图像



(c) DoLP 差值

图 3.4 聚类后的 DoP 图像变化

为从统计角度验证偏振度随透射率退化这一关系, 本文利用第 2 章构建的水下偏振数据集进行系统分析。实验步骤如下：

1. 对同一场景采集的清晰图像（Ground Truth），计算其 DoLP 图，并采用

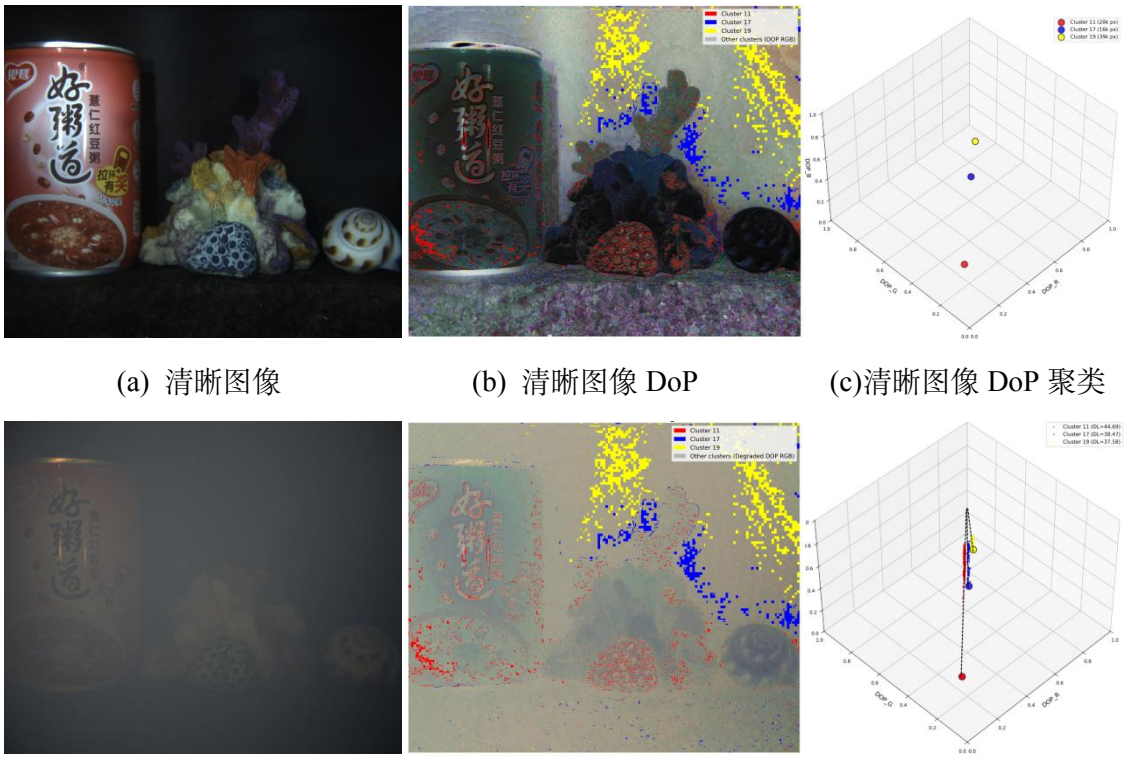
K-means 聚类算法将其划分为 K=400 个聚类簇。每个簇代表具有相似本征偏振度的像素集合，这些像素往往具有相似材质属性。

2. 对于每个聚类簇，追踪其对应的退化图像 DoLP 值的变化。以簇内像素的观测 DoLP 均值作为该簇的演化轨迹。

3. 以背景光区域估计的偏振度ρ_B为参考，将各簇 DoLP 值归一化后绘制随浑浊度变化的散点图。

图 3.5 展示了其中三个代表性聚类簇的统计结果，对于任意固定的目标偏振度，由于同一 DoLP 聚类中的像素在图像不同区域经历了不同的偏振传输值，退化后，属于同一聚类的 DoLP 值最终会变得不同，但 DoLP 的衰减直线均经过同一背景光偏振度点ρ_B。

图 3.5(a)显示了无雾图像。在图 3.5(b)中，属于其中三个 DoLP 聚类的像素用不同颜色标记，它们的 DoLP 值绘制在图 3.5(c)中。图 3.5(d)展示了拍摄的真实水下图像数据。图 3.5(e)中标记了与图 3.5(b)中相同的像素。



(a) 清晰图像　(b) 清晰图像 DoP　(c)清晰图像 DoP 聚类

(d) 浑浊图像　(e) 浑浊图像 DoP　(f)浑浊图像 DoP 聚类

图 3.5　DoP 线性衰减

图 3.5(f)不同颜色的直线代表不同本征材质的偏振簇，属于同一 DoLP 聚类的像素值不再一致，其斜率各异但最终均交于纯背景散射点。

基于偏振成像模型，这一线性关系在数学上可表达为：

$$\rho_I^{(k)}(s)=\rho_D^{(k)}\cdot(1-s)+\rho_B\cdot s,\quad s\in[0,1] \tag{3-9}$$

式 3-8 可改写为

$$\rho_I^{(k)}(s)=(\rho_B-\rho_D^{(k)})\cdot s+\rho_D^{(k)},\quad s\in[0,1] \tag{3-10}$$

其中 s 为归一化的散射强度指标 $s=0$ 对应纯净水体，$s=1$ 对应完全被背景光淹没）；$\rho_D^{(k)}$为第 k 簇清晰态的 DoLP；ρ_B 为背景光 DoLP。这一物理规律不仅验证了理论模型的正确性，更为网络自适应感知水体深度与浑浊度提供了的数值演化约束。

3.2.4 偏振消色差先验

在自然场景中，存在一类特殊的像素——消色差像素（achromatic pixels），它们对应于物体表面呈白色、灰色或黑色的区域，其光谱反射率在可见光波段内近似平坦，因此在 RGB 图像中三个通道的强度值相等或接近。Taishi 等人[70]的研究表明，在任意光照条件下，消色差像素在清晰图像中的线偏振度（DoLP）同样保持其消色差特性，即红、绿、蓝三个通道的 DoLP 值相等。这一性质可形式化表述为：

$$P_R^r(\mathbf{u})=P_R^g(\mathbf{u})=P_R^b(\mathbf{u}) \tag{3-11}$$

其中 P_R^r, P_R^g, P_R^b 分别表示清晰图像中消色差像素点 u 在三个颜色通道的 DoLP 值。

将这一先验推广至含雾/浑浊图像时，需要考虑散射介质对偏振信息的影响。根据大气散射理论，雾、霾以及水体中的悬浮颗粒对光的散射以 Mie 散射为主，其散射强度随波长的变化较小，因此导致天空或背景区域呈现近似白色，即大气光或背景散射光在三个通道上的强度分量相近。进一步地，当光线经过介质散射进入成像系统时，其偏振状态的改变可由穆勒矩阵描述。设入射大气光的斯托克斯矢量为 $[\dot{A}_0, \dot{A}_1, \dot{A}_2]^T$，经穆勒矩阵 M 作用后出射光的斯托克斯矢量为 $[A_0, A_1, A_2]^T$，则出射光的 DoLP 为：

$$P_A=\frac{\sqrt{A_1^2+A_2^2}}{A_0}=\frac{\sqrt{\dot{A}_1^2+\dot{A}_2^2}}{\dot{A}_0} \tag{3-12}$$

式(3-17)表明，在穆勒矩阵与波长无关（即散射过程非色散）的近似下，出射

光的 DoLP 与入射光本身的 DoLP 相同。因此，当大气光本身为消色差光（其三个通道强度相等）时，其 DoLP 在三个通道上也必然相等，且这一性质不随雾浓度变化而改变。

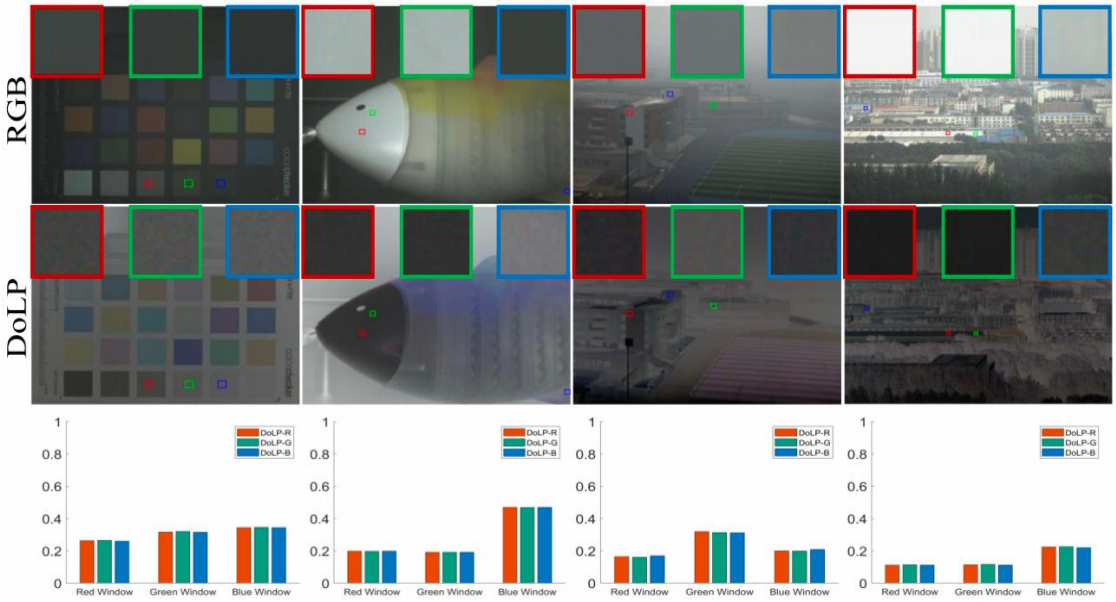


图 3.6 偏振消色差先验验证图

基于上述分析，可以推断：在含雾或浑浊图像中，对应于消色差物体（如白色墙体、灰色路面）的像素，其三通道的 DoLP 值也应保持相等。图 3.6 展示了这一现象的直观验证。图中第一行为不同场景下拍摄的含雾图像，红色、绿色和蓝色方框分别标记了三组不同的消色差像素区域；第二行是对应的 DoLP 图像（为便于观察进行了伪彩色拉伸）；第三行统计了各矩形框内像素的三通道 DoLP 值分布。从统计结果可以看出，尽管不同场景的雾浓度和光照条件各异，但同一矩形框内红、绿、蓝三通道的 DoLP 值均高度接近，其差异主要由 DoLP 图像中的不可避免的噪声引起。这种噪声可近似为零均值的高斯噪声，对整体统计估计的影响可忽略不计。

偏振消色差先验的建立为背景光参数的估计提供了重要依据。由于背景光（大气光）本身来源于介质的散射，其对应像素通常具有亮度高、颜色接近白色且 DoLP 三通道一致的特点。因此，可以利用该先验设计加权机制，从图像中自动筛选出最可能属于背景光的像素候选，从而实现对背景光 DoLP P_A 和强度 B_∞ 的鲁棒估计，避免了传统方法中需要人工选取天空区域或依赖特定先验的局限。这一应用将在 3.4 节中详细展开。

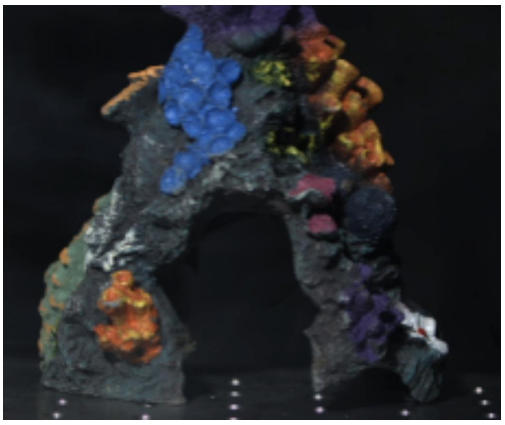
3.3 基于复平面偏振态的图像恢复

3.3.1 背景散射光偏振态估计

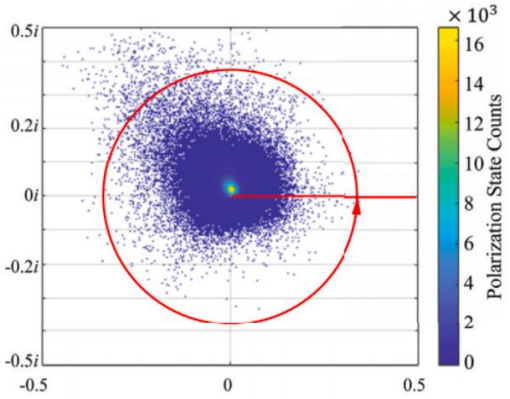
该方法的理论基础源于对清晰与浑浊图像偏振态分布特性的观察。如本章图 3.7 所示，清晰图像的偏振态在复平面上集中于原点附近，其分布模态点（即出现频率最高的偏振态）位于原点；而在浑浊图像中，由于背景散射光的叠加，分布模态点会偏离原点，且偏移量由 m_B 主导。基于此，可以对 m_B进行估计：

$$m_B^{mode}=\eta\cdot mode(m_I) \tag{3-13}$$

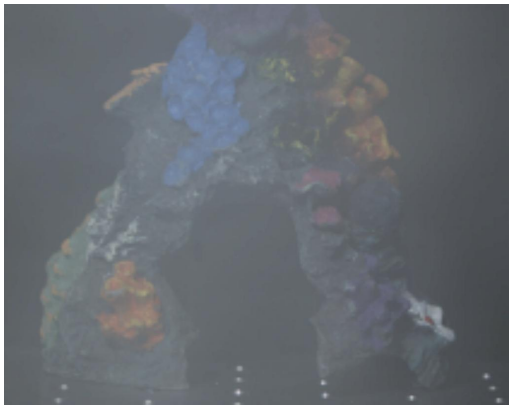
其中 mode(·) 表示对复平面上所有像素的偏振态取众数（即统计密度最高的点），η 为经验缩放因子。根据 Shwartz 等人[68]的研究，背景散射光的 DoLP 通常略大于观测图像 DoLP 的众数，因此在中低浑浊度条件下可取 η=1.25。该方法完全基于图像全局统计，无需任何人工干预，适用于各类场景。然而，当图像中不存在明显的背景区域或浑浊度过高导致众数偏移不明显时，其精度可能下降。



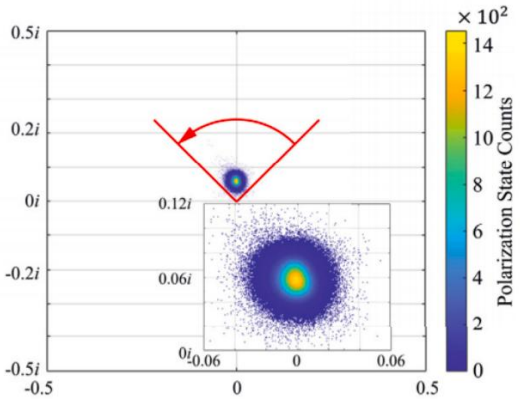
(a)清晰图像



(b)清晰图像的偏振态分布



(c)浑浊图像



(d)浑浊图像的偏振态分布

图 3.7 清晰图像与浑浊图像的偏振态分布

3.3.2 基于角度聚类的偏振线预测

在获得背景散射光偏振态 m_B 后，下一步是估计每个像素的偏振透射率 r(u)。根据复平面偏振成像模型（式 3-6），对于同一条偏振线内的像素，其场景辐射偏振态 m_D 固定，而观测偏振态 m_I 位于 m_B与 m_D 的连线上。因此，估计透射率的关键在于确定每条偏振线的方向以及线上像素到 m_B 的距离关系。本节首先介绍如何通过角度聚类检测偏振线，下小节阐述基于偏振线约束的透射率估计方法。

根据式 3-6，对于固定的 m_B 和 m_D，不同像素的观测偏振态 m_I 在复平面上位于同一条从m_B 出发的射线上。因此，像素所属的偏振线由其相对于 m_B 的方向唯一确定。将观测偏振态平移到以m_B为原点的复平面：

$$m_{IB}(u)=m_I(u)-m_B \tag{3-14}$$

采用极坐标表示 m_{IB} 的方向：

$$m_{IB}(u)=r(u)e^{i\theta(u)} \tag{3-15}$$

其中 $r(\mathbf{u})=|m_{IB}(\mathbf{u})|$ 为像素到 m_B 的距离，$\theta(\mathbf{u})=arg(m_{IB}(\mathbf{u}))$ 为方向角，取值范围为 $[0,2\pi)$。

为将具有相似方向角 θ 的像素聚为一类（即同一条偏振线），本文借鉴非局部图像去雾[55]中基于球面均匀采样的聚类策略。本策略的核心思想是在单位圆上均匀采样若干个方向中心，然后将每个像素分配给与其方向最接近的中心点。具体步骤如下：

1. 方向单位向量计算：将每个像素的平移向量 $m_{IB}(\mathbf{u})$ 归一化为单位向量 $[\cos\theta(\mathbf{u}),\sin\theta(\mathbf{u})]$，该单位向量位于二维单位圆上。

2. 均匀采样方向中心：在单位圆上均匀采样 N_p 个点，每个采样点代表一条偏振线的方向中心。采样点数量 N_p 的选择至关重要：过少会丢失细节，导致不同方向的像素被错误合并；过多则增加计算负担，且易受噪声干扰。根据的实验，N_p=1000 可在恢复质量和计算效率之间取得良好平衡。

3. KD 树最近邻搜索：构建以 N_p 个采样点为节点的 KD 树，对每个像素的单位方向向量进行最近邻查询，将其分配给距离最近（即方向最接近）的采样点。查询结果将图像像素划分为 N_p 个偏振线簇H_j，每个簇内的像素具有近似相同的方向角 θ。

该聚类过程与颜色线方法[55]中对 RGB 空间方向的聚类思想类似，但本文将其应用于复平面上的偏振态空间，从而直接利用偏振信息的几何特性。

3.3.3 基于偏振线约束的初始透射率估计

对于每条偏振线 H_j，定义其最大距离为：

$$\hat{d}_{\max}(H_j)=\max_{\mathbf{v}\in H_j}|m_I(\mathbf{v})-m_B| \tag{3-16}$$

该最大值对应于线上最接近清晰状态的像素（即受散射影响最小的点）。基于此，每个像素 $\mathbf{u}\in H_j$ 的偏振透射率初始估计可表示为：

$$\tilde{r}(\mathbf{u})=\frac{|m_I(\mathbf{u})-m_B|}{\hat{d}_{\max}(H_j)} \tag{3-17}$$

式子 (3-17) 表示像素到背景光偏振态的距离越近，说明其受散射影响越严重，透射率越低；反之，距离越远则透射率越高。当像素恰好是线上距离最远的点时，其透射率被估计为 1，代表该像素近似无散射影响。

然而，该估计依赖于每条偏振线中存在一个完全无散射的像素这一假设。在实际场景中，这一假设可能不成立，尤其当整条线所对应的物体区域均处于较深位置时，最大距离仍可能小于真实的 $|m_D-m_B|$。此外，噪声和聚类误差也会影响估计精度，因此，需要对初始估计进行进一步优化。

根据强度域成像模型（式 2-18），透射率 $t(\mathbf{u})$ 与偏振透射率 $r(\mathbf{u})$ 之间存在关系:

$$\mathrm{r}=1-(1-\mathrm{t})\frac{B_\infty}{I} \tag{3-18}$$

结合式（3-17）中 r 与 t 的关系，可导出 r 的下界：

$$r_{\min}(\mathbf{u})=1-\frac{B_\infty}{I(\mathbf{u})} \tag{3-19}$$

将初始估计与下界结合，得到修正后的初始透射率：

$$\tilde{r}_{lb}(\mathbf{u})=\max\{\tilde{r}(\mathbf{u}),r_{\min}(\mathbf{u})\} \tag{3-20}$$

初始透射率图 $\tilde{r}_{lb}$ 是基于逐像素独立估计得到的，缺乏空间连续性，且易受噪声影响。根据非局部图像去雾[55]的思想，透射率图应具备局部平滑性（在深度连续区域）的同时保持边缘（在深度跳变处）。为此，本文采用加权最小二乘优化框架[57]对透射率进行正则化，目标函数如下：

$$\hat{r}=\arg\min_r\sum_{\mathbf{u}}\frac{(r(\mathbf{u})-\tilde{r}_{lb}(\mathbf{u}))^2}{\sigma^2(\mathbf{u})}+\lambda\sum_{\mathbf{u}}\sum_{\mathbf{v}\in N_4(\mathbf{u})}\frac{(r(\mathbf{u})-r(\mathbf{v}))^2}{\|I(\mathbf{u})-I(\mathbf{v})\|^2} \tag{3-21}$$

其中 $\sigma^2(\mathbf{u})$为 $\tilde{r}_{lb}$ 在像素 $\mathbf{u}$ 所属偏振线内的方差，反映了该线内距离分布的集

中程度。若方差较大，说明该线内像素距离分散，最大距离估计可能不可靠，因此数据项权重降低；反之，方差较小时数据项权重增加。λ 为平衡数据项与平滑项的正则化参数，本文取 λ=0.1。$N_4(\mathbf{u})$ 表示像素 $\mathbf{u}$ 的四邻域。第二项平滑约束引导透射率在原始图像强度相似的区域保持连续（即 $\|I(\mathbf{u})-I(\mathbf{v})\|^2$ 较小时惩罚更大），从而在抑制噪声的同时保留深度边缘。

该优化问题可转化为求解一个大型稀疏线性方程组，其形式为 $(A+\lambda L)\hat{r}=A\tilde{r}_{lb}$，其中 A 是以 $1/\sigma^2(\mathbf{u})$ 为对角元素的对角矩阵，L 为拉普拉斯平滑矩阵。求解该方程组即可得到优化后的偏振透射率图 $\hat{r}$。

在代码实现中，该函数首先根据引导图像 I 计算水平与垂直方向的梯度权重，构建平滑约束矩阵；然后结合数据项权重求解线性系统，并特别处理了低置信度区域（如天空或过暗区域）以避免奇异矩阵。最终输出的 $\hat{r}$ 被截断至 [0,1] 范围内，确保物理有效性。

3.3.4 场景图像恢复

在完成偏振透射率 $\hat{r}$ 的优化估计后，本小节将阐述如何利用该参数从退化图像中恢复场景的清晰图像及其完整偏振信息，复原包括包括两个关键步骤：场景偏振态的重建和强度图像的复原。

由式 3-6 可知，观测偏振态 m_I 是场景辐射偏振态 m_D 与背景散射光偏振态 m_B 的线性组合。对该式进行逆变换，可直接求解场景辐射的偏振态，场景图像偏振态可表示如下：

$$\widehat{m}_D(\mathbf{u})=\frac{m_I(\mathbf{u})-\widehat{m}_B}{\hat{r}(\mathbf{u})}+\widehat{m}_B \tag{3-22}$$

该式的物理意义可理解为：通过减去背景散射光的影响并补偿透射率的衰减，即可恢复出场景本身的偏振特征。根据复偏振态的定义（式 3-1 和 3-2），可进一步分解得到场景的线偏振度 DoLP 和线偏振角 AoLP：

$$\hat{\rho}_D(\mathbf{u})=|\widehat{m}_D(\mathbf{u})|,\quad \hat{\phi}_D(\mathbf{u})=\frac{1}{2}arg\left(\widehat{m}_D(\mathbf{u})\right) \tag{3-23}$$

值得注意的是，式(3-22)中的分母 $\hat{r}(\mathbf{u})$ 可能接近于零，导致数值不稳定。为避免这一问题，在实际计算中引入一个安全下界 r_0=0.05，将分母替换为 $\max(\hat{r}(\mathbf{u}),r_0)$。这一处理在保证数值稳定性的同时，不会对恢复结果产生显著影响，因为透射率极低的区域通常对应于背景散射光主导的区域，这些区域的偏振信息本身已极度退化。

根据偏振透射率 r 的定义 $r=D/I$，并结合强度域成像模型（式 2-18），可以建

立 r 与场景辐射光强 J 之间的联系。

$$I(\mathbf{u})=D(\mathbf{u})+B(\mathbf{u})=r(\mathbf{u})I(\mathbf{u})+[1-t(\mathbf{u})]B_{\infty} \tag{3-24}$$

从中解出透射率 t 与 r 的关系：

$$t(\mathbf{u})=1-\frac{(1-r(\mathbf{u}))I(\mathbf{u})}{B_{\infty}} \tag{3-25}$$

代入强度域成像模型 $I=Jt+(1-t)B_{\infty}$，可得场景辐射光强 J 的恢复公式，其代表的就是清晰图像：

$$\hat{J}(\mathbf{u})=\frac{\hat{r}(\mathbf{u})I(\mathbf{u})}{\hat{r}(\mathbf{u})\cdot a+t_0} \tag{3-26}$$

其中 a 为与水体类型相关的经验参数，用于描述场景辐射光与背景散射光之间透射率的差异。根据 Akkaynak 等人[58]的研究，在不同水质条件下 a 的取值略有差异，本文在所有实验中统一取 a=0.95，其中 t_0=0.0001 是为防止除零引入的小量常数。

式(3-26)的推导过程体现了偏振信息与强度信息的统一：偏振透射率 $\hat{r}$ 不仅描述了偏振态的退化，同时也隐含了强度域的透射信息。这一特性使得本文方法能够仅通过偏振信息估计出所有必要参数，无需额外估计透射率 t。

恢复得到的图像 $\hat{J}$ 可能因水体选择性吸收而存在色彩偏差，为校正这一偏差，本文采用灰度世界假设[59]对 $\hat{J}$ 进行白平衡处理。灰度世界假设认为，在自然场景中，三个颜色通道的平均值应趋于相等。因此，先计算各通道的增益因子如下式所示：

$$g_c=\frac{\max\limits_{c'\in\{R,G,B\}} mean(\hat{J}_{c'})}{mean(\hat{J}_c)},\quad c\in\{R,G,B\} \tag{3-27}$$

然后将增益因子应用于对应通道：

$$\hat{J}_{WB,c}(\mathbf{u})=\min(1, g_c\cdot\hat{J}_c(\mathbf{u})) \tag{3-28}$$

值得注意的是，根据复偏振态的定义式 $m=(S_1+iS_2)/S_0$，白平衡操作仅调整 S_0（强度）的幅度，而 S_1 和 S_2 与 S_0 成比例缩放，因此白平衡不会改变 m 的值。换言之，色彩校正不影响偏振信息的准确性，这一特性使得本文方法能够独立处理颜色恢复和偏振恢复，互不干扰。

最终，经过白平衡处理的图像 $\hat{J}_{WB}$ 即为本文方法输出的清晰水下图像。同时，由式(3-22)恢复的 $\hat{\rho}_D$ 和 $\hat{\phi}_D$构成了场景的完整偏振信息，可用于后续的偏振视觉应用。

3.4 基于偏振度和消色差先验的图像恢复

3.4.1 基于消色差先验的强度估计

消色差先验指出，在含雾/浑浊图像中，对应于消色差物体的像素，其三通道 DoLP 值应保持相等，且这些像素往往来源于背景散射光区域。基于这一性质，本文设计了一套加权筛选机制，从图像中自动识别最可能属于背景光的像素，并加权估计 P_A 和 B_∞。该方法的实现步骤如下：

1. 消色差置信度权重计算：对于每个像素 $\mathbf{u}$，定义其消色差置信度权重 $\omega_{ach}(\mathbf{u})$，由 DoLP 三通道差异和亮度共同决定：

$$\omega_{ach}=\exp\left(-\frac{|P^r-P^g|+|P^g-P^b|}{\bar{P}+\epsilon}\right)\cdot\left(1-\frac{1}{1+e^{-a(V-b)}}\right) \tag{3-29}$$

其中 $\bar{P}=(P^r+P^g+P^b)/3$ 为三通道 DoLP 均值，V 为 HSV 色彩空间中的亮度分量，ϵ 和 a,b 为控制参数（代码中取 a=50,b=0.95）。第一项惩罚三通道 DoLP 差异大的像素，第二项通过 sigmoid 函数增强低亮度像素的权重（因为背景光区域通常较暗）。

2. 背景光 DoLP 估计：选取 ω_{ach} 最高的前 0.1%像素作为候选集 $\mathscr{B}$，其权重归一化后加权平均得到 P_A：

$$P_A=\frac{\sum_{\mathbf{u}\in\mathscr{B}}\omega_{ach}(\mathbf{u})P(\mathbf{u})}{\sum_{\mathbf{u}\in\mathscr{B}}\omega_{ach}(\mathbf{u})} \tag{3-30}$$

3. 大气光强度候选权重计算：为估计全局背景光强度 B_∞，需寻找亮度高且 DoLP 接近 P_A 的像素。定义权重 ω_A：

$$\omega_A=\exp\left(-\frac{\|P-P_A\|^2}{2\sigma_P^2}\right)\cdot\frac{1}{1+e^{-a(V-b)}} \tag{3-31}$$

其中第一项衡量 DoLP 与 P_A 的接近程度，第二项增强高亮度像素的权重。σ_P 为带宽参数，代码中取 σ_P=0.1。

4. 大气光强度估计：选取 ω_A 最高的前 0.1%像素，加权平均得到 B_∞：

$$B_\infty=\frac{\sum_{\mathbf{u}\in A}\omega_A(\mathbf{u})I(\mathbf{u})}{\sum_{\mathbf{u}\in A}\omega_A(\mathbf{u})} \tag{3-32}$$

其中 $I(\mathbf{u})$ 为像素强度（可由 Stokes 参数 S_0 获得）。该方法充分利用了偏振

消色差先验，在存在消色差区域的场景中能够获得极高精度的估计。但当场景中缺乏消色差像素或消色差区域被遮挡时，其可靠性可能下降。

3.4.2 偏振传输图估计

首先，将每个像素的 DoLP 值投影到以背景光 DoLP P_A为原点的空间中，计算距离向量：

$$\mathbf{d}(\mathbf{u})=P(\mathbf{u})-P_A \tag{3-33}$$

将距离向量归一化为单位方向$\mathbf{d}_{unit}(\mathbf{u})=\mathbf{d}(\mathbf{u})/\|\mathbf{d}(\mathbf{u})$。通过对单位球面进行均匀采样（取$N_p$=1000 个采样点）并构建 KD 树进行最近邻搜索，将具有相似方向的像素聚为同一偏振衰减线 L。

对于每条衰减线 L，取线上像素到P_A的最大距离作为该簇的“最大衰减”：

$$d_{\max}(L)=\max_{\mathbf{v}\in L}\|\mathbf{d}(\mathbf{v})\| \tag{3-34}$$

偏振传输图 K 的初始估计由当前距离与簇最大距离的比值确定：

$$\tilde{K}(\mathbf{u})=\frac{\|\mathbf{d}(\mathbf{u})\|}{d_{\max}(L)+\epsilon} \tag{3-35}$$

根据物理约束，K 应满足 $0\le K\le 1$，且可由大气光强度导出下界：

$$K_{\min}(\mathbf{u})=1-\min_{c\in\{R,G,B\}}\frac{I_c(\mathbf{u})}{B_{\infty,c}} \tag{3-36}$$

初始估计被截断至$[\max(\tilde{K},K_{\min}),1]$范围内。

与偏振透射率 r 类似，初始估计$\tilde{K}$ 同样需要正则化处理。采用与式(3-21)相同的加权最小二乘优化框架：

$$\hat{K}=\arg\min_K\sum_{\mathbf{u}}\frac{(K(\mathbf{u})-\tilde{K}(\mathbf{u}))^2}{\sigma_K^2(\mathbf{u})}+\lambda_K\sum_{\mathbf{u}}\sum_{\mathbf{v}\in N_4(\mathbf{u})}\frac{(K(\mathbf{u})-K(\mathbf{v}))^2}{\|I(\mathbf{u})-I(\mathbf{v})\|^2} \tag{3-37}$$

其中$\sigma_K^2(\mathbf{u})$为$\tilde{K}$在对应衰减线内的方差，λ_K为平滑参数。

3.4.3 场景 DoLP 与强度图像恢复

根据偏振退化模型（式 3-10）的逆变换，场景 DoLP 可由下式恢复：

$$\hat{P}_D(\mathbf{u})=\frac{P(\mathbf{u})-(1-\hat{K}(\mathbf{u}))\cdot P_A}{\hat{K}(\mathbf{u})}\cdot\omega \tag{3-38}$$

其中ω=0.8 为松弛因子，用于抑制噪声放大；分母采用$\hat{K}_{safe}=\max(\hat{K},0.05)$ 防止除零。恢复结果被截断至[0,1]范围内。

在获得偏振传输图 $\hat{K}$ 和场景 DoLP $\hat{P}_D$后，需要进一步恢复强度图像。根据增

强型偏振去雾模型，观测强度 I 与场景辐射 J、大气光A_∞以及偏振参数之间存在如下关系：

$$J(\mathbf{u})=\frac{(\epsilon P_A-P(\mathbf{u}))I(\mathbf{u})A_\infty}{(\epsilon P_A-\hat{P}_D(\mathbf{u}))A_\infty+(\hat{P}_D(\mathbf{u})-P(\mathbf{u}))I(\mathbf{u})} \tag{3-39}$$

其中ϵ为调节系数，用于平衡去散射强度与色彩保真度。该式的物理意义在于：通过引入ϵ对背景光 DoLP 进行微调，可以避免因P_A估计误差导致的过度去雾或色彩失真问题。

对于ϵ的取值，需满足$\epsilon P_A\le 1$ 以保证数值稳定性，因此ϵ的取值范围为$[1,1/P_A]$。当ϵ接近下限时，去雾效果较弱但色彩保真度高；当ϵ接近上限时，去雾效果强但可能引入色彩偏差。为充分利用不同ϵ值的优势，本文采用多组ϵ生成多个候选恢复结果，再通过融合策略综合各结果的优势。

根据图像的平均 DoLP 值，自适应选择不同的参数范围生成多组恢复图像：

1. 低 DoLP 情况（$\bar{P}<0.2$，浓雾场景）：

ϵ取值范围为[1.4,1.6]，生成 N=3 组恢复图像R_k，ϵ值在范围内线性采样，同时额外加入亮度增强图像$J_0=CLAHE(I)$作为第 4 组输入，以补偿浓雾场景下的细节损失

2. 一般情况（$\bar{P}\ge 0.2$）：

ϵ取值范围为[1.05,1.25]，生成 N=3 组恢复图像，额外加入基于$\hat{K}$直接恢复的图像作为第 4 组输入，该方法由式(3-40)计算：

$$J_{direct}(\mathbf{u})=\hat{K}(\mathbf{u})\cdot I(\mathbf{u}) \tag{3-40}$$

每组恢复图像 J_k 的计算公式统一为式(3-39)，其中ϵ_k取对应的采样值。

恢复得到的多组图像J_k可能存在色彩偏差，需要进行白平衡处理。采用与 3.3.4 节相同的灰度世界假设，对各组图像分别进行色彩校正：

$$R_{k,WB,c}(\mathbf{u})=\min\left(1,\frac{\max_{c'} mean\,(R_{k,c'})}{mean(R_{k,c})}\cdot R_{k,c}(\mathbf{u})\right) \tag{3-41}$$

由于 DoLP 方法仅处理偏振度信息，其恢复结果不包含完整的偏振态（AoLP 缺失），因此无法像复平面方法那样恢复场景的完整偏振信息。然而，在强度图像恢复方面，DoLP 方法通过偏振衰减先验提供了与复平面方法互补的视角，两者的融合有望取得更优效果，这正是 3.5 节将阐述的多尺度融合策略的核心动机。

3.5 基于多尺度融合的图像增强

基于复平面偏振态的方法和基于 DoLP 与消色差先验的方法）各有侧重：复平

面方法充分利用了全偏振信息（DoLP 和 AoLP），在几何约束下实现全局恢复，能够准确重建场景的偏振态；DoLP 方法则聚焦于偏振度的线性衰减规律，在局部统计意义上进行恢复，对色彩饱和度和局部对比度有更好的保持能力。为综合两者优势，本文采用多尺度拉普拉斯金字塔融合策略，将两种方法生成的多组恢复结果进行自适应融合，进一步提升图像质量。

3.5.1 融合权重图计算

为评估每组候选图像中各像素的质量，本文计算三种互补的权重图，分别衡量图像的色彩丰富度、色彩自然度和局部显著性[60][61]。

亮度权重W_m^L衡量像素的色彩丰富度，其定义为像素值与亮度分量的差异：

$$W_m^L(\mathbf{u})=\sqrt{\frac{(R_m^r(\mathbf{u})-L_m(\mathbf{u}))^2+(R_m^g(\mathbf{u})-L_m(\mathbf{u}))^2+(R_m^b(\mathbf{u})-L_m(\mathbf{u}))^2}{3}} \tag{3-42}$$

其中$L_m(\mathbf{u})=(R_m^r+R_m^g+R_m^b)/3$ 为亮度分量。该权重越大，表示像素色彩越丰富，越可能是高质量的恢复结果。

色度权重W_m^C基于饱和度的高斯分布，优先选择饱和度适中的像素以避免过饱和或欠饱和：

$$W_m^C(\mathbf{u})=\exp\left(-\frac{(S_m(\mathbf{u})-S_{\max})^2}{2\sigma^2}\right) \tag{3-43}$$

其中$S_m(\mathbf{u})$为像素的饱和度（由 RGB 转换至 HSV 空间获取），$S_{\max}$=0.5 为期望的最大饱和度，σ=0.3 为高斯核宽度。

显著性权重 W_m^S 衡量像素的局部对比度，通过高斯滤波后的图像与原图的差异计算：

$$W_m^S(\mathbf{u})=\|Gauss(R_m(\mathbf{u}))-\mu_m\| \tag{3-44}$$

其中 $Gauss(\cdot)$为高斯滤波操作（代码中取高斯核标准差为 0.1），μ_m为滤波后图像的全局均值。该权重突出图像中具有高对比度的显著区域。

三种权重相乘得到组合权重：

$$\widetilde{W}_m(\mathbf{u})=W_m^L(\mathbf{u})\cdot W_m^C(\mathbf{u})\cdot W_m^S(\mathbf{u}) \tag{3-45}$$

为确保所有权重之和为 1，进行归一化处理：

$$W_m(\mathbf{u})=\frac{\widetilde{W}_m(\mathbf{u})}{\sum_{m=1}^{M}\widetilde{W}_m(\mathbf{u})+\epsilon} \tag{3-46}$$

该归一化权重图W_m表示第 m 组候选图像在像素 $\mathbf{u}$ 处的融合贡献度。

3.5.2 多尺度拉普拉斯金字塔融合

直接对图像进行加权平均（即$\sum_m W_m \cdot R_m$）会在权重突变的边缘处产生伪影。为避免这一问题，本文采用多尺度拉普拉斯金字塔融合算法[62]，在多个尺度上逐步融合图像，有效抑制拼接伪影。

首先进行金字塔分解，对每组候选图像 J_m 构建拉普拉斯金字塔$\mathscr{L}\{R_m\}$，对对应的权重图W_m构建高斯金字塔 $G\{W_m\}$。金字塔层数 L 由图像尺寸决定：

$$L=\lfloor \log_2 \min(H,W) \rfloor -2 \tag{3-47}$$

其中 H 和 W 分别为图像的高度和宽度。对于 2048×2448 的原始图像，$L\approx 9$ 层。

拉普拉斯金字塔的构建过程如下：

第 1 层为原始图像：$\mathscr{L}_1\{R_m\}=R_m$，对第 l 层图像进行下采样和高斯滤波，得到第 l+1 层的高斯金字塔$G_{l+1}\{R_m\}$，将$G_{l+1}\{R_m\}$上采样至第 l 层尺寸，并与第 l 层图像相减，得到第 l 层的拉普拉斯金字塔：

$$\mathscr{L}_l\{R_m\}=G_l\{R_m\}-upsample(G_{l+1}\{R_m\}) \tag{3-48}$$

最高层 L 的拉普拉斯金字塔即为该层的高斯金字塔：$\mathscr{L}_L\{R_m\}=G_L\{R_m\}$，高斯金字塔的构建则仅通过高斯滤波和下采样逐层得到。

完成金字塔分解后再进行逐层融合，在每个金字塔层级 l，利用权重图的高斯金字塔对图像的拉普拉斯金字塔进行加权融合：

$$F_l(\mathbf{u})=\sum_{m=1}^{M} G_l\{W_m(\mathbf{u})\}\cdot \mathscr{L}_l\{R_m(\mathbf{u})\} \tag{3-49}$$

由于$G_l\{W_m\}$已在上采样和下采样过程中自然平滑，因此F_l在各尺度上均能保持平滑过渡，有效避免了直接空间域加权带来的伪影。

最后进行金字塔重建，从最高层开始，逐层上采样并叠加，重建融合图像：

$$R_{fused}(\mathbf{u})=\sum_{l=1}^{L} upsample(F_l(\mathbf{u})) \tag{3-50}$$

具体地，从最高层 L 开始，将当前层图像上采样至第 L−1 层尺寸，与第 L−1 层的融合结果F_{L-1}相加，得到第 L−1 层的重建结果；依此类推，直至重建出第 1 层图像，即为最终融合结果。

融合后的图像R_{fused}可能整体偏暗或偏亮，需要进行亮度调整以获得最佳的视觉表现。本文采用自适应亮度调整策略，根据图像的亮度分布动态调整亮度范围。

计算融合图像所有像素的亮度值（RGB 三通道均值），取亮度最高的 0.1%像素的均值作为参考最亮点：

$$V_{\max}=percentile(V(\mathbf{u}),99.9) \tag{3-51}$$

其中 $V(\mathbf{u})=(R^{r}_{fused}+R^{g}_{fused}+R^{b}_{fused})/3$。则亮度调整因子为：

$$\gamma=\min\left(\frac{1}{V_{\max}},3\right) \tag{3-52}$$

该因子保证最亮 0.1%像素映射至 1, 同时限制最大增益为 3 以避免过度增强噪声。最终输出图像为：

$$R_{final}(\mathbf{u})=\min(1,\gamma\cdot R_{fused}(\mathbf{u})) \tag{3-53}$$

3.6 实验结果与分析

3.6.1 实验设置与条件

数据采用的是第二章分焦平面偏振相机构建的真实水下偏振图像数据, 所有数据均包含同步采集的四角度强度图像 $I_{0^\circ},I_{45^\circ},I_{90^\circ},I_{135^\circ}$。

数据集包含两类，第一类为不同场景数据集，涵盖不同偏振特性的目标物体，用于无参考评价；第二类为不同浑浊度的数据集，每组均有对应的清晰图像作为真值，用于全参考评价；评价指标采用第二章详细阐述的指标体系，包括全参考指标（PSNR、SSIM）和无参考指标（UIQM、UCIQE），此处不再赘述。

为验证本文基于偏振先验的物理方法的优越性，选择代表性的物理方法 GDCP[63]、Color-lines[55]、MLLE[64]进行对比，其中 GDCP 是暗通道先验的推广形式，通过估计透射率和大气光实现去雾；Color-lines 先验方法基于清晰图像像素在 RGB 空间中形成颜色线的假设，通过拟合颜色线估计透射率。MLLE 是基于局部自适应对比度增强和最小色彩损失的水下图像增强方法。

3.6.2 不同偏振特性物体的恢复能力对比

水下场景中的目标物体由于材质和表面微观结构的差异，表现出各异的偏振特性。金属等光滑表面以镜面反射为主，具有较高的线偏振度（DoLP）；而岩石、布料等粗糙表面以漫反射为主，DoLP 较低；塑料、木质等材料则介于两者之间。为验证方法对不同偏振特性物体的恢复能力，本文选取第二类数据集中浑浊度均为 28.6 NTU 但包含五种典型材质的图像进行测试，包括：金属（高偏振特性）、塑料牛奶盒（中高偏振特性）、仿真礁石（中偏振特性）、布料（中低偏振特性）以及天然石材（低偏振特性）。图 3.8 展示了这五类物体的恢复结果对比。

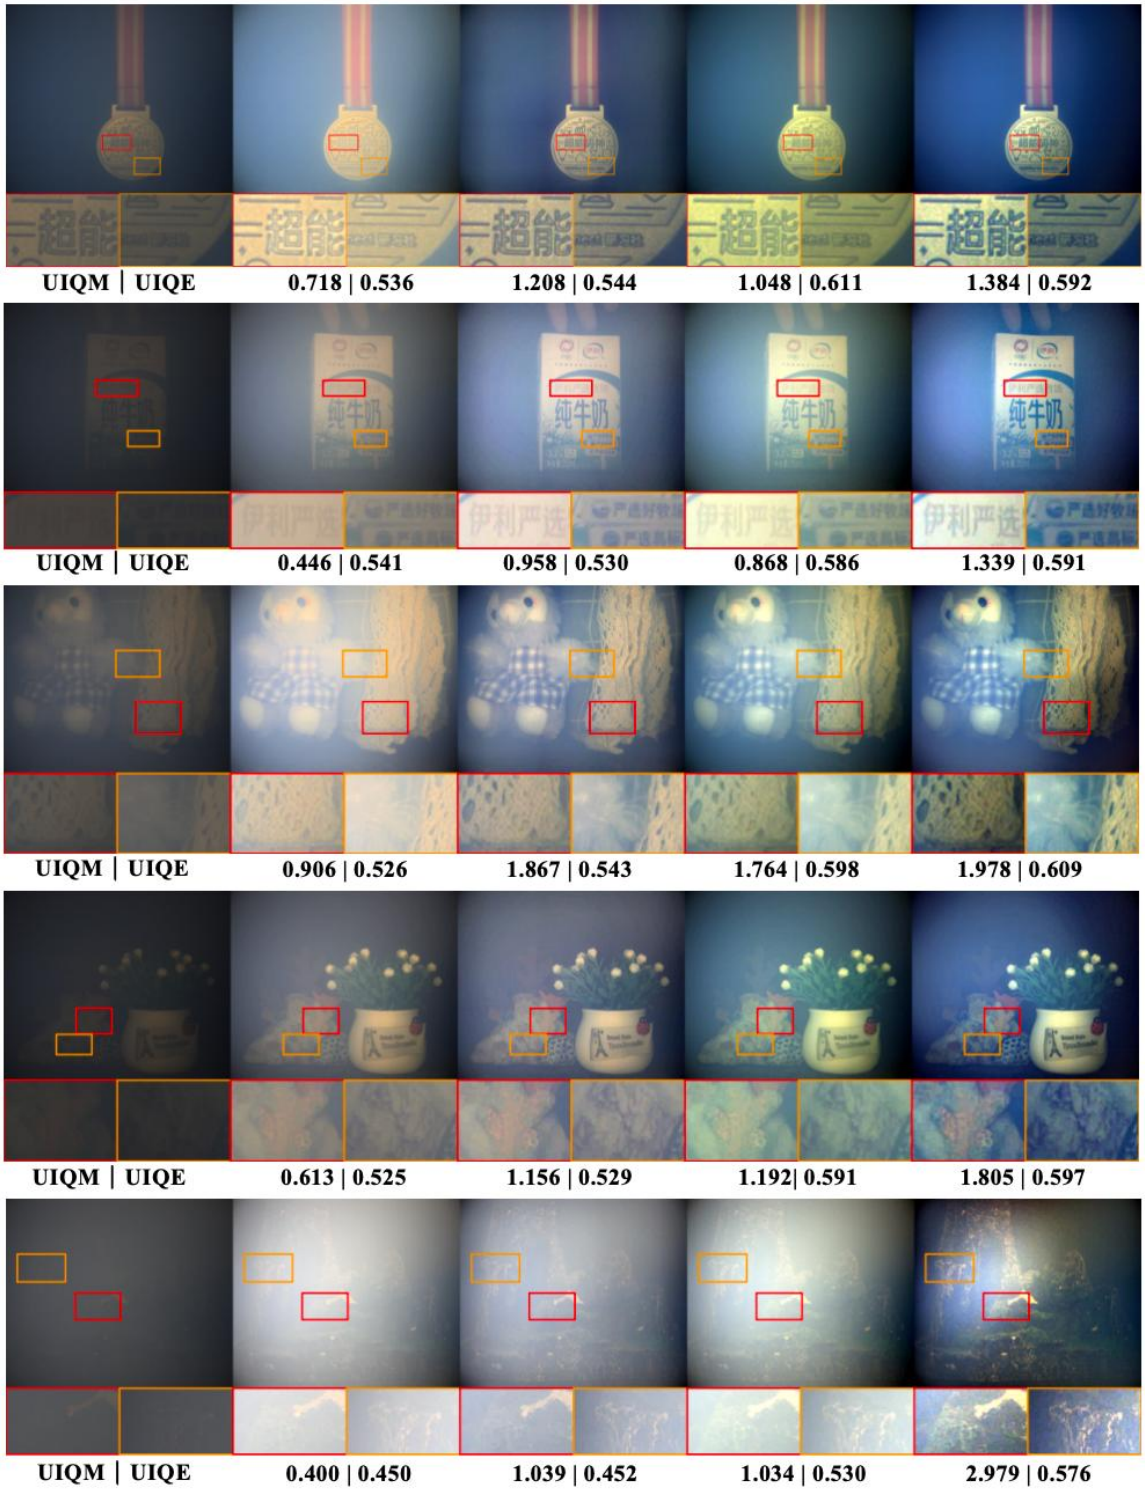


图 3.8 不同偏振特性物体的恢复

从图 3.8 可以直观看出，本文方法在所有材质上均取得了最佳的视觉效果。对

于高偏振特性的金属奖牌（第一行），本文方法成功恢复了金属表面的高光区域和真实色泽，奖牌上的纹理清晰可辨；对于中高偏振特性的塑料牛奶盒（第二行），盒上的文字边缘锐利，色彩饱和自然；对于中低偏振特性的布料（第三行），布料的纤维质感和图案色彩还原准确；对于中偏振特性的仿真礁石（第四行），礁石的立体感和纹理细节得到良好保持；对于低偏振特性的天然石材（第五行），石材的天然色泽和粗糙质感得以真实再现。

表 3.1 给出了不同方法的恢复的图像的 UIQM 和 UCIQE 平均值。本文方法在两个指标上均取得最高分，UIQM 达到 2.3821，UCIQE 达到 0.5954，显著优于对比的方法。

表 3.1 不同方法的图像恢复指标

Method	UIQM	UCIQE
GDCP	1.3191	0.5016
MLLE	2.3523	0.5199
Color-lines	2.1233	0.5905
ours	**2.3821**	**0.5954**

由此可见，通过对全偏振信息的充分利用，本文方法能够在不同材质上均取得优异表现。通过复平面偏振态 m 同时建模 DoLP 和 AoLP，偏振线先验能够准确刻画不同材质的本征偏振特征；消色差先验保证了背景光估计的准确性；而偏振衰减先验则有效描述了 DoLP 随透射率的线性变化规律。这些物理先验的共同作用，使得本文方法能够根据物体的偏振特性自适应调整恢复策略，在保留材质细节的同时实现准确的色彩还原。

3.6.3 不同浑浊度下的恢复性能对比

本节使用第二类数据集验证方法在不同浑浊度下的恢复能力，图 3.9 展示了 18.9 NTU，28.6 NTU，36.8NTU 和 43.6 NTU 四个不同浑浊度下的恢复结果对比。

GDCP 在低浑浊度下尚能恢复一定细节，但随着浑浊度增加，其暗通道假设被破坏，恢复图像出现明显伪影；MLLE 在高浑浊度下色彩恢复效果下降，且恢复图像对比度较低；Color-lines 方法在中等浑浊度下表现尚可，但在高浑浊度下颜色线假设失效，导致透射率严重低估，恢复图像出现大量噪声和细节丢失。

本文方法恢复的图像在色彩保真度和细节清晰度上均优于对比方法，尤其在 43.6 NTU 的高浑浊度下，GDCP 已无法辨识物体轮廓，MLLE 和 Color-lines 也出现大量细节丢失，而本文方法仍能恢复出物体的基本形状和颜色。

表 3.2 给出了四个浑浊度等级下各方法的 PSNR 和 SSIM 指标对比。可以看出，本文方法在所有浑浊度下均取得最优或次优的定量结果。

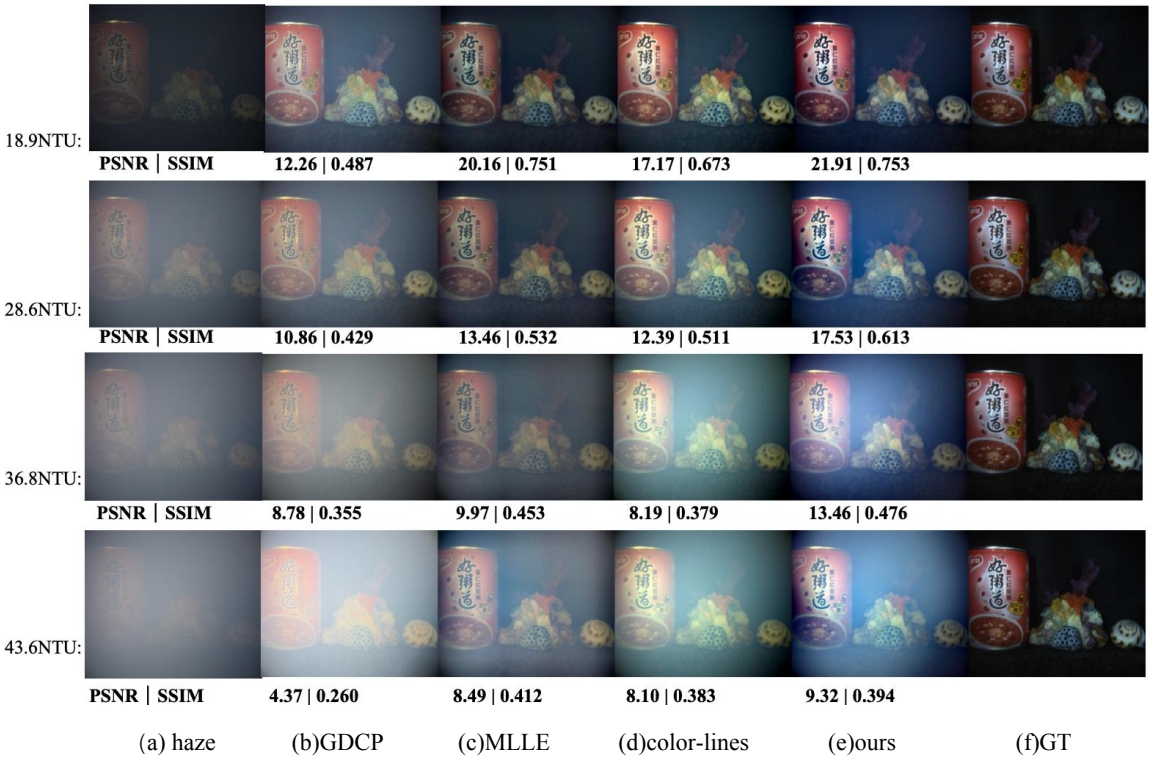


图 3.9 不同浑浊度的水下图像恢复

随着浑浊度增加，所有方法性能均下降，但本文的方法始终保持最优的效果。在 18.9 NTU 低浑浊度下，本文方法恢复图像的平均 PSNR 达到 22.25 dB，比第二名 MLLE 高出 2.08 dB；在 43.6 NTU 高浑浊度下，本文方法恢复图像的平均 PSNR 为 10.67 dB，仍比 MLLE 高 2.271 dB。这表明偏振先验能够有效约束参数估计，即使在严重散射环境下也能恢复出更接近真值的图像。

表 3.2 四个浑浊度等级下各方法的 PSNR 和 SSIM 指标

浑浊度(NTU)	PSNR(dB)↑				SSIM↑			
	GDCP	MLLE	c-line	ours	GDCP	MLLE	c-line	ours
18.9	12.90	20.17	17.35	**22.25**	0.5018	**0.7535**	0.6814	0.7512
28.6	11.07	13.20	13.01	**17.20**	0.4392	0.5464	0.5203	**0.6321**
36.8	8.771	9.861	8.203	**13.07**	0.3715	0.4606	0.3788	**0.4715**
43.6	4.510	8.399	8.105	**10.67**	0.2812	0.4138	0.3765	**0.3933**

3.6.4 消融实验与参数分析

为评估本方法中各组件的有效性，我们进行了一系列消融实验。各变体的性能通过 PSNR、SSIM 指标在 28.6 NTU 的水下偏振图像上进行评估，结果如表 3.3 所示，最优用红色+加粗表示，次优用蓝色+下划线表示。各消融组件的具体细节如下：

1. w/o PLC：不使用偏振线先验。
2. w/o PAP：不使用偏振消色差先验，改用传统天空区域选取法[69]实现背景光估计。
3. w/o WLS：跳过加权最小二乘正则化步骤，直接使用初始透射率恢复图像。
4. w/o Fusion：不使用多尺度融合，用加权平均融合（WAF）恢复图像。

表 3.3 消融实验的定量评估结果

Metric	w/o PLC	w/o PAP	w/o WLS	w/o Fusion	Ours
PSNR↑	12.87	16.59	13.10	16.79	**17.20**
SSIM↑	0.5301	0.5910	0.5189	0.5712	**0.6321**

表 3.3 展示了消融实验的定量评估结果。数据显示，我们的完整算法在 PSNR 和 SSIM 两项指标上均持续优于所有变体方案。

下面讨论不同偏振聚类数N_p对恢复质量和耗时的影响，图 3.10 和表 3.4 展示了相关结果。观察可知：

当N_p<10^3时，PSNR 随N_p增加而快速提升，表明足够的聚类数对捕捉偏振细节至关重要。

当N_p在 10^3 至 10^6之间时，PSNR 和 SSIM 稳定提升但幅度减缓，耗时基本保持不变。

当N_p>10^6后，耗时急剧增加而性能增益甚微，出现过拟合现象。

表 3.4 不同偏振聚类数N_p对恢复质量和耗时的影响

N_p	10	100	1000	10^4	10^5	10^6	10^7	10^8
$log_{10}N_p$	1	2	3	4	5	6	7	8
Time	5.202	5.432	5.464	5.467	5.669	6.192	15.819	181.765
PSNR↑	15.89	16.56	17.20	17.21	17.01	16.74	16.49	16.28
SSIM↑	0.5904	0.6210	0.6321	6.6323	0.6351	0.6392	0.6411	0.6419

综合考虑恢复质量和计算效率，本文选取N_p=1000 作为默认值。在该参数下，PSNR 达到 17.20 dB，耗时约 5.464 秒，取得了良好的平衡，后续可以通过神经网

络自监督训练的方式实现端到端的优化，取得更优的恢复速度。

3.7 本章小结

本章针对水下图像散射退化问题，构建了一个完整的基于偏振先验的物理去散射框架，实现了场景颜色与全偏振信息的高保真恢复。本章的主要工作与贡献可归纳如下：

首先，通过引入复平面偏振态的概念，将传统斯托克斯参数中的线偏振度（DoLP）与偏振角（AoLP）统一为复数表征，推导出了偏振退化线性叠加模型。该模型揭示了退化图像的偏振态是目标本征偏振态与背景散射光偏振态的线性组合，为后续的物理参数估计奠定了理论基础。

其次，深入挖掘并验证了水下偏振图像中的三个物理先验：偏振线先验揭示了同一聚类内像素的偏振态在复平面上共线的几何规律；偏振衰减先验量化了 DoLP 随透射率线性衰减的统计特性；偏振消色差先验则证明了消色差像素的 DoLP 在三通道上保持一致的物理性质。这些先验的建立为无需人工干预的参数估计提供了可靠依据。

在此基础上，本章设计了两套互补的参数估计与图像恢复方法：

1. 基于复平面偏振态的方法：通过角度聚类检测偏振线，利用偏振线约束估计偏振透射率，并通过加权最小二乘优化实现透射率正则化，最终恢复场景的完整偏振信息与强度图像。

2. 基于 DoLP 与消色差先验的方法：利用消色差先验鲁棒估计背景光参数，通过偏振衰减线估计偏振传输图，并引入增强型偏振去雾模型生成多组候选恢复图像。

为综合两种方法的优势，本章进一步引入多尺度拉普拉斯金字塔融合策略，根据亮度、色度和显著性权重对多组候选图像进行自适应融合，有效提升了恢复图像的视觉质量。

实验部分采用真实水下偏振图像数据集，从不同偏振特性物体和不同浑浊度两个维度对方法进行验证。结果表明，本章方法在所有测试场景下均取得了优于对比方法的恢复效果：在不同偏振特性物体的恢复中，本章方法成功保留了金属、塑料、布料、石材等多种材质的本征纹理和色彩特征，UIQM 和 UCIQE 指标均显著优于对比方法；在不同浑浊度序列中，本章方法的 PSNR 和 SSIM 指标始终保持领先，在高浑浊度下仍能保持物体的基本形状和颜色。消融实验验证了偏振线先验、消色差先验、正则化优化和多尺度融合各模块的必要性，参数分析则为聚类数的选择提供了依据。

综上所述，本章所提出的基于偏振先验的水下去散射方法，通过充分利用全偏振信息和物理先验约束，实现了从退化图像到清晰图像及其完整偏振信息的精确重建，为水下光学成像质量的提升提供了有效的物理解决方案。本章的研究成果也为后续结合深度学习的端到端优化奠定了坚实的理论基础和可靠的数据支撑。

第 4 章　物理先验引导的自监督水下图像恢复方法

4.1　引言

第 3 章构建了基于多偏振先验的物理去散射方法，通过复平面偏振态建模与几何特征约束（偏振线先验、消色差先验、偏振度衰减先验），实现了水下图像偏振信息与颜色信息的恢复。然而，该物理模型在实际工程应用中有一定的局限性：首先是计算耗时巨大，偏振透射率的估计高度依赖繁杂的聚类算法与加权最小二乘（WLS）迭代平滑，难以满足水下机器人等装备的实时感知需求；其次是参数鲁棒性不足，硬编码的聚类簇数、容差系数等超参数缺乏自适应调整能力，在面对水下复杂场景时容易发生估计偏差，从而引发全图的复原误差。

为了突破传统物理优化的计算瓶颈，引入前向推理极快的深度神经网络是必然趋势。但现有深度神经网络的方法依赖“清晰-浑浊”的图像对进行训练，在真实水下环境中，同步采集严格对齐的“清晰-浑浊”偏振图像对几乎是不可能的。若依赖人工合成数据，不可避免的域偏移又会严重削弱模型在真实水域的泛化能力。为了缺乏参考真值的困境，本章提出以物理先验指导网络进化，以数据驱动提升模型泛化性的解决思路。

本章设计了一种物理先验引导的自监督水下图像恢复网络。具体而言，本章在以下两个维度进行了创新：

1. 架构设计层面：构建了面向物理参数解耦的双分支网络，通过两个独立的子网络分别密集估计局部偏振透射率图和回归全局背景光参数，摒弃传统方法中繁杂的数值求解优化。

2. 自监督优化层面：将物理先验转化为网络可微的“无参考损失函数”。通过构建偏振线损失、偏振度衰减损失等，使网络在无需任何清晰标签的条件下，实现图像去散射。

本章的结构安排如下：4.2 节介绍了面向物理参数解耦的双分支自监督网络架构，利用 U-Net 的强空间建模能力逐像素精细估计透射率 t(x)，同时利用多层感知机的全局压缩能力回归背景光 A_{∞}；4.3 节阐述了如何将物理先验转化为驱动网络训练的无参考损失函数，通过联合偏振线约束损失L_{line}、偏振度衰减惩罚L_{DoP}等损失函数设计，实现无需参考图像的网络训练；4.4 节从定性视觉效果对比、定量评价指标分析展开了综合性的实验验证；4.5 节进行了核心损失函数的消融实验以及与先进方法的运行时间对比；4.6 节对本章的研究工作进行了总结。

4.2 双分支自监督网络架构

4.2.1 网络总体框架

本章提出的自监督去散射网络整体框架如图 4.1 所示。网络以分焦平面偏振相机同步捕获的四角度强度图像 $I_{0^\circ}, I_{45^\circ}, I_{90^\circ}, I_{135^\circ}$ 做为原始输入，利用斯托克斯（Stokes）矢量公式解算出每个像素的线偏振度图（DoLP）和偏振角图（AoLP）。随后，将这 4 张原始强度图与 DoLP、AoLP 在通道维度上进行级联，构建出高维特征张量 **X**。

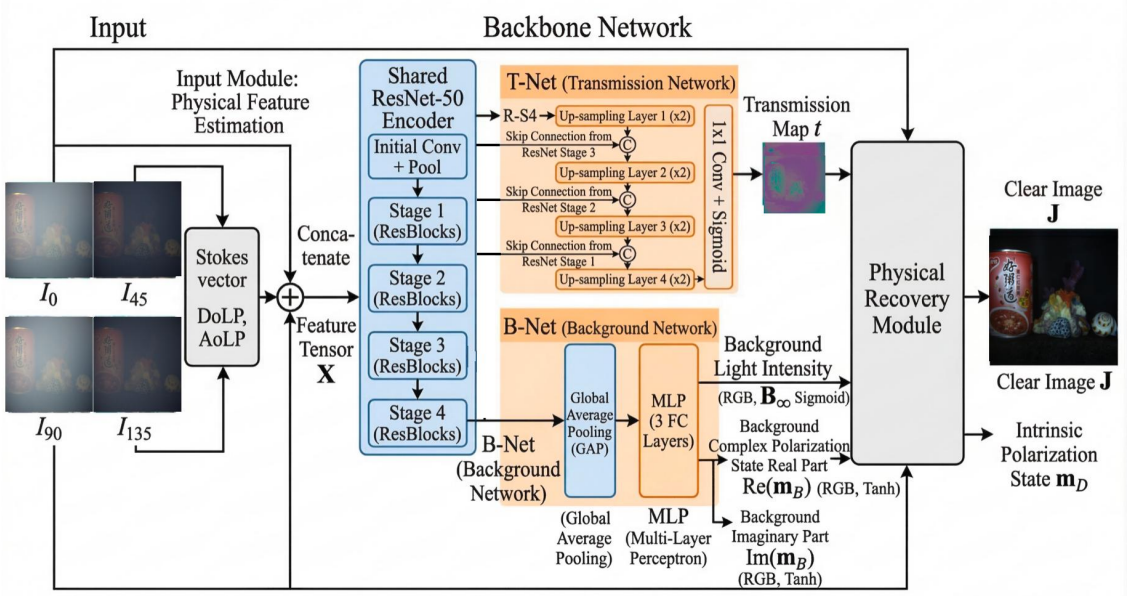


图 4.1 自监督去散射网络整体框架

输入模块旨在对原始四角度图像进行物理特征解算。根据斯托克斯（Stokes）参数的定义，前三个分量可由下式计算得到：

$$\begin{cases} S_0 = I_{0^\circ} + I_{90^\circ} = I_{45^\circ} + I_{135^\circ} \\ S_1 = I_{0^\circ} - I_{90^\circ} \\ S_2 = I_{45^\circ} - I_{135^\circ} \end{cases} \tag{4-1}$$

基于 Stokes 矢量，进一步可算出偏振度（DoLP）和偏振角（AoLP）：

$$\rho(x,y) = \frac{\sqrt{S_1^2(x,y) + S_2^2(x,y)}}{S_0(x,y)}, \quad \phi(x,y) = \frac{1}{2}\arctan\frac{S_2(x,y)}{S_1(x,y)} \tag{4-2}$$

将四角度原始强度图与计算得到的 DoLP、AoLP 在通道维度进行级联，构建为一个多通道的融合特征张量。该输入不仅包含了原始场景的辐射能量分布，还

显式地引入了偏振统计特征，这种物理特征的“前置注入”降低了网络在浅层特征提取时的学习门槛，也为后续网络的物理参数解耦提供了更多维度的特征。与仅依靠 RGB 强度的传统方法相比，偏振特征的先验使网络拥有了更优的感知复杂水体散射介质分布的能力。

在水下偏振退化模型中，恢复清晰图像及其本征偏振态依赖于对两类核心物理参数的精确估计：一类是刻画场景局部景深与结构变化的透射率图（Transmission Map, t）；另一类是反映全局水体光学属性的背景散射光参数（包含背景光强 B_∞ 与背景复偏振态 $\mathbf{m}_B$）。

其中，透射率图是局部高频突变，而大气光相关参数是全局低频一致，鉴于这两类参数在空间分布上的本质物理差异，但它们又共同受制于底层的水下光学散射规律，本章设计了一种“同源特征提取、异构参数解耦”的双分支自监督网络架构。网络整体由多偏振特征输入构建、基于 ResNet-50 的共享特征编码器、透射率估计解码分支（T-Net）、全局背景光回归分支（B-Net）以及无参数可微物理反演模块组成。整个网络的参数更新由多物理先验联合损失函数端到端驱动，无需依赖任何成对的清晰图像标签。

4.2.2 共享特征编码器

由于透射率图 t 与背景光参数（A_∞,$\mathbf{m}_B$）的退化均源于相同的水体悬浮颗粒散射，它们在特征空间中存在紧密的耦合关系。为此，本网络采用 ResNet-50 作为共享的特征提取主干网络，ResNet-50 的网络结构如图 4.2 所示。

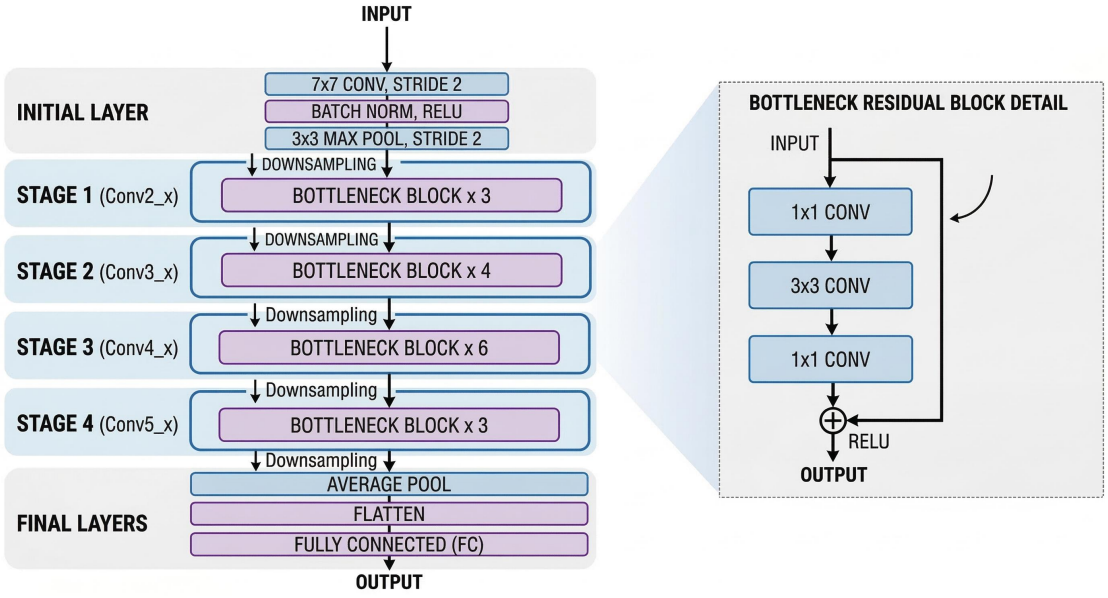


图 4.2 ResNet-50 网络结构

输入高维张量 **X** 进入 ResNet-50 编码器后，依次经过 4 个核心下采样阶段（Stage 1 ~ Stage 4）。每个阶段由多个堆叠的瓶颈残差块（Bottleneck Residual Blocks）组成。得益于残差学习机制，网络在加深的同时有效避免了梯度消失与特征退化。随着分辨率的逐级下采样，特征图的感受野不断扩大，通道数依次倍增，从而高效地提取出从浅层边缘纹理到深层水体浑浊度语义的丰富多尺度共享特征。

4.2.3 局部透射率估计子网络

透射率 t 本质上反映了场景到相机的空间相对距离。由于水下地形与目标物体结构的复杂性，透射率的估计是一个高度位置敏感（Position-sensitive）的密集预测任务。

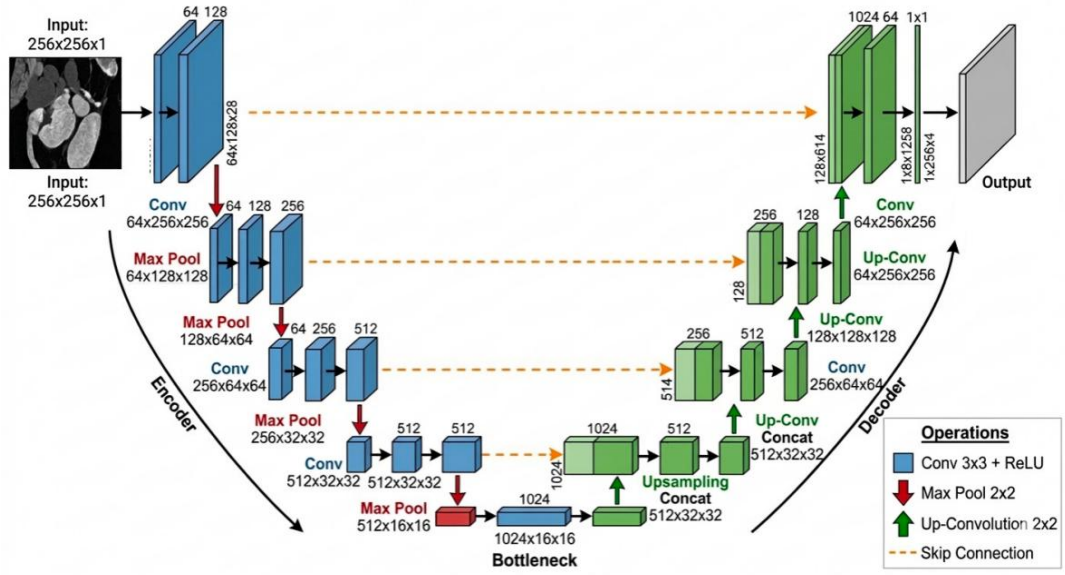


图 4.3 U-Net 编码器与解码器网络结构

为此，本章的透射率估计分支（T-Net）采用了经典的 U-Net 解码器架构，与 ResNet-50 编码器共同构成特征金字塔，架构见图 4.4：

1. 上采样与跳跃连接：T-Net 接收 ResNet-50 最深层（Stage 4）的特征图，通过 4 个上采样层（转置卷积）逐步恢复特征图的空间尺寸。为防止下采样过程中高频边缘信息的丢失，网络在解码器的每一层均引入了跳跃连接（Skip Connections），将 ResNet-50 对应层级的多尺度特征进行通道级联，从而完美兼顾了全局景深趋势与局部物体边缘。

2. 物理边界约束输出：网络的最后一层使用 1×1 卷积将特征通道数压缩至单通道，并强制通过 Sigmoid 激活函数。这一设计将网络输出严格截断至 (0,1) 区

间，从数学层面完美契合了透射率 $t \in (0,1)$ 的物理定义，避免了复原计算中因透射率越界引发的像素溢出。

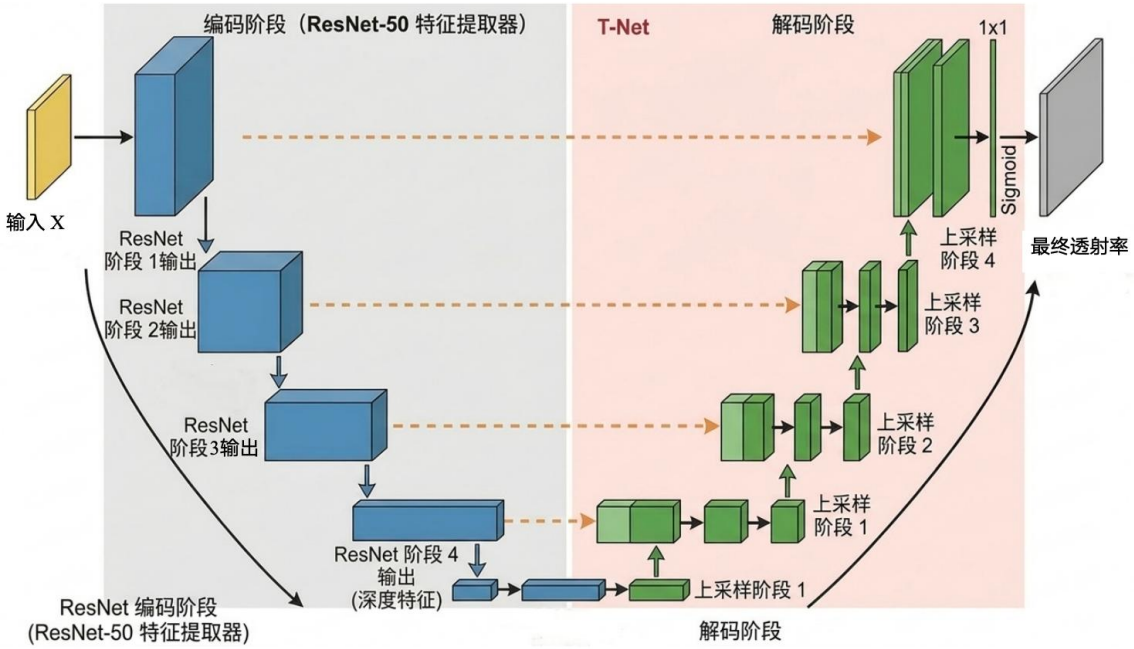


图 4.4　T-Net 的编码器与解码器网络结构

4.2.4　背景光估计与物理反演模块

与局部异质的透射率不同，全局背景光强 $\mathbf{B}_\infty$ 与复偏振态 $\mathbf{m}_B$ 仅由整体水域的散射粒子浓度与照明条件决定，在同一单目成像视场内可近似视为空间均匀的全局常数。因此，背景光参数的估计本质上是一个全局统计信息的回归任务。

B-Net 分支直接从 ResNet-50 的最深层（Stage 4）引出，其具体设计如下：

1. 全局信息聚合：对深层特征图首先执行全局平均池化 (GAP, Global Average Pooling) 。GAP 消除了空间维度（$H \times W \to 1 \times 1$），强制网络融合全图感受野，提取出最具代表性的环境光学向量。

2. 多层感知机映射：GAP 输出的特征向量随后被送入由三个全连接层组成的多层感知机（MLP）中进行非线性回归，最终映射至一个 9 维的参数空间。

3. 分支激活与分离输出：这 9 维向量被物理切分为三个部分：

背景光强 $\mathbf{B}_\infty$：占用 3 维（对应 RGB 三通道），通过 Sigmoid 函数激活至 (0,1) 区间（假定输入图像已归一化）。

复偏振态实部 $R(\mathbf{m}_B)$：占用 3 维（RGB），因其物理取值范围跨越正负，采用 Tanh 函数激活至 $(-1,1)$ 区间。

复偏振态虚部 $I(\mathbf{m}_B)$：占用 3 维（RGB），同样采用 Tanh 函数激活至 (−1,1) 区间。

在 T-Net 密集输出局部透射率图 t、B-Net 回归全局背景参数 $\mathbf{B}_\infty$ 和 $\mathbf{m}_B$ 之后，若让网络直接通过卷积生成最终的清晰图像，将极大地破坏物理模型的可解释性，并引入不可控的生成伪影。因此，本文在双分支网络的末端构建了物理反演模块。利用水下成像公式实现清晰图像的恢复。

依据物理关联公式 4-3 将光强透射率 t 动态转化为偏振透射率 r；

$$r(\mathbf{u})=1-\frac{(1-t(\mathbf{u}))\mathbf{B}_\infty}{I(\mathbf{u})} \tag{4-3}$$

随后，结合预测的$\mathbf{m}_B$ 和观测复偏振态 $\mathbf{m}_I$，依据代数反演公式解算出目标的本征复偏振态 $\mathbf{m}_D$。

这一模块构成了参数预测与 4.3 节无参考先验损失之间的连接桥梁，确保了由物理约束产生的误差梯度能够精确地反向传播至 T-Net、B-Net 以及 ResNet-50 共享编码器的所有卷积权重中，实现了闭环自监督训练。

4.3 多物理先验联合损失函数

本节将偏振线先验、偏振衰减先验、消色差先验等转化为可微分的损失函数。这些物理损失函数在训练阶段充当“虚拟教师”，引导网络在完全没有成对清晰标签的条件下，解耦并精准估计水下散射参数。

根据水下偏振退化模型，观测强度 $I=S_0/2$ 与复平面观测偏振态 $\mathbf{m}_I$ 的退化过程可统一表示为：

$$\mathbf{m}_I(\mathbf{u})=\mathbf{m}_D(\mathbf{u})r(\mathbf{u})+\mathbf{m}_B(1-r(\mathbf{u})) \tag{4-4}$$

其中，$\mathbf{u}=(x,y)$ 为像素空间坐标。偏振透射率 $r(\mathbf{u})$ 是连接强度域透射率 $t(\mathbf{u})$ 与偏振特征域的物理桥梁，其数学定义严格为：

$$r(\mathbf{u})=1-\frac{(1-t(\mathbf{u}))\mathbf{B}_\infty}{I(\mathbf{u})} \tag{4-5}$$

在网络前向传播中，基于预测出的 $r(\mathbf{u})$ 和 $\mathbf{m}_B$，可直接通过物理退化模型的逆过程，动态解算出场景本征复偏振态 $\mathbf{m}_D(\mathbf{u})$ 以及场景本征偏振度 $\mathbf{P}_D(\mathbf{u})$：

$$\mathbf{m}_D(\mathbf{u})=\frac{\mathbf{m}_I(\mathbf{u})-\mathbf{m}_B(1-r(\mathbf{u}))}{r(\mathbf{u})+\epsilon} \tag{4-6}$$

$$\mathbf{P}_D(\mathbf{u})=\frac{\mathbf{P}(\mathbf{u})-\mathbf{P}_A(1-r(\mathbf{u}))}{r(\mathbf{u})+\epsilon} \tag{4-7}$$

其中，$\mathbf{P}(\mathbf{u})$ 为观测偏振度，$\mathbf{P}_A=|\mathbf{m}_B|$ 为背景光偏振度，ϵ 为防止除零溢出的小量常数。

1. 消色差先验损失

水下背景散射光（即无穷远处的环境光）主要由水体中悬浮颗粒的米氏散射引起，其在视觉上通常呈现出灰白色。偏振消色差先验指出，当光强表现为消色差特性时，其对应的线偏振度（DoLP）在 RGB 三个颜色通道上也必然保持高度一致。为迫使网络预测的 $\mathbf{m}_B$ 遵循这一自然物理规律，本文设计了消色差一致性损失：

$$L_{color}=\frac{1}{3}\left(|P_A^r-P_A^g|+|P_A^g-P_A^b|+|P_A^b-P_A^r|\right) \tag{4-8}$$

作为独立于局部像素的全局约束项，该损失直接为 $\mathbf{m}_B$ 的优化提供了明确的梯度下降方向，有效防止了网络在自监督盲搜阶段产生严重的偏色退化。

2. 偏振度衰减先验联合损失（L_{DoP}）

偏振衰减先验表明，对于具有相同本征材质的物体，由于所处景深不同，其观测到的偏振度会在三维 DoLP 空间中沿射线向背景偏振度 $\mathbf{P}_A$ 线性衰减。本模块将其转化为网络约束，主要包含簇内一致性与物理尺度正则化两部分。

在单位球面上均匀采样 K=1000 个方向中心，定义偏移向量 $\mathbf{d}(\mathbf{u})=\mathbf{P}(\mathbf{u})-\mathbf{P}_A$，利用 KD-tree 将像素按 $\hat{\mathbf{d}}(\mathbf{u})$ 的方向划分为 K 个衰减聚类簇 Ω_k。在同一簇 Ω_k 内，依据公式 (4-4) 动态反演出的场景本征偏振度 $\mathbf{P}_D(\mathbf{u})$ 理论上应保持恒定。本文以簇内距离背景光最远点（即受散射影响最小的像素）反演出的 $\mathbf{P}_D^{\max,k}$ 为参考基准，使簇内所有像素对其进行对齐；同时，为防止网络只预测极小透射率，对最远点施加带有边界裕度的尺度正则化。

将本征偏振度重构一致性与物理尺度正则化合并，构建偏振度衰减先验联合损失 L_{DoP}：

$$L_{DoP}=\frac{1}{K}\sum_{k=1}^{K}\left[\underbrace{\frac{1}{|\Omega_k|}\sum_{\mathbf{u}\in\Omega_k}\left\|\mathbf{P}_D(\mathbf{u})-\mathbf{P}_D^{\max,k}\right\|_1}_{\text{本征偏振度重构一致性项}}+\underbrace{\max\left(0,0.3-r(\mathbf{u}_k^{\max})\right)^2}_{\text{物理尺度边界正则项}}\right] \tag{4-9}$$

其中，一致性项通过直接对偏振度 $\mathbf{P}_D$ 施加约束锁定了透射率的相对比例；而正则项确保了最远点偏振特征的物理可靠性，且仅当最远点偏振透射率过度退化（r<0.3）时才触发惩罚，该裕度机制极大提升了网络在不同浑浊度水质下的泛化能力。

3. 偏振线先验联合损失（L_{line}）

偏振线先验表明原本属于同一本征偏振态的像素，由于受到不同程度的散射，会呈线性蜕化分布。通过估计透射率，同一线性聚类内点可反演得到的原本复偏振态 $\mathbf{m}_D(\mathbf{u})$ ，同一聚类内的点汇聚于同一点。

利用复数辐角差 $\theta(\mathbf{u})=arg(\mathbf{m}_I(\mathbf{u})-\mathbf{m}_B)$将像素聚类为 K=1000 条偏振线 Φ_k。依据公式 (4-6) 动态反演出每条线内的复偏振态。以线上距离背景光最远点反演的 $\mathbf{m}_D^{\max,k}$ 为参考基准，使得同一偏振线上所有像素的 $\mathbf{m}_D(\mathbf{u})$ 向其对齐，并同样符合最远点尺度约束。

将簇内复偏振态重构一致性与物理尺度正则化合并，构建偏振线先验联合损失 L_{line}：

$$L_{line}=\frac{1}{K}\sum_{k=1}^{K}\left[\underbrace{\frac{1}{|\Phi_k|}\sum_{\mathbf{u}\in\Phi_k}\left\|\mathbf{m}_D(\mathbf{u})-\mathbf{m}_D^{\max,k}\right\|_1}_{\text{复偏振态重构一致性项}}+\underbrace{\max(0,0.3-r(\mathbf{u}_k^{\max}))^2}_{\text{物理尺度边界正则项}}\right] \tag{4-10}$$

该公式方括号内的前一项在复平面幅值与相位的双重维度上，引导透射率 t 和大气光参数的估计；后一项与衰减先验类似，作为底层的物理边界兜底，防止模型估计退化。

4. 边缘感知空间平滑损失 (L_{smooth})

透射率 $t(\mathbf{u})$ 物理上代表连续的场景景深，应在物体表面保持平滑，仅在物理边缘发生突变。本文引入基于原图强度的全变分正则化：

$$L_{smooth}=\frac{1}{N}\sum_{\mathbf{u}}\left(|\nabla_x t(\mathbf{u})|e^{-\alpha|\nabla_x I(\mathbf{u})|}+|\nabla_y t(\mathbf{u})|e^{-\alpha|\nabla_y I(\mathbf{u})|}\right) \tag{4-11}$$

该项有效抑制了透射率局部密集估计所产生的噪声，消除了复原图像中的光晕伪影。

为赋予网络在不同场景下自适应调整物理约束强度的能力，在总损失函数中将上述各项先验损失进行解耦加权。最终自监督网络的总体联合优化目标定义为：

$$L_{total}=\lambda_{color}L_{color}+\lambda_{DoP}L_{DoP}+\lambda_{line}L_{line}+\lambda_{smooth}L_{smooth} \tag{4-12}$$

在该多任务优化框架中，$\mathscr{L}_{\text{ach}}$ 直接约束全局变量 $\mathbf{m}_B$，而 $\mathscr{L}_{\text{smooth}}$专注于平滑局部变量 t。驱动网络进行物理推演的核心力量来自于偏振衰减先验联合损失 $\mathscr{L}_{\text{atten}}$ 与偏振线先验联合损失 $\mathscr{L}_{\text{line}}$。由于偏振透射率 r 的计算 (式 4-5) 深度耦合了局部光强透射率 t 与全局背景光强 $\mathbf{B}_\infty$，网络在反向传播时无法独立操纵单一变量。为了最小化各项一致性损失，网络被迫不断协调并同步更新 t 和 $\mathbf{B}_\infty$，使其共同满足水下偏振退化规律，从而在没有成对标签的条件下，完美实现物理自洽与高质量图像的复原重建。

4.4 实验结果与分析

4.4.1 实验设置与条件

数据采用的是第二章分焦平面偏振相机构建的真实水下偏振图像数据，按照10:1 的比例划分为训练集和测试集，所有数据均包含同步采集的四角度强度图像$I_{0^\circ},I_{45^\circ},I_{90^\circ},I_{135^\circ}$。

我们在 NVIDIA RTX2080Ti GPU 上使用 Pytorch 实现了我们的框架。所有卷积层的核大小为 5×5。B-net 网络中的上采样和下采样倍数均为 2。我们采用 Adam 优化器，学习率为10^{-3}，最大训练轮数为 200 轮。

本章的实验平台与环境配置如表 4.1 所示，所有的深度神经网络模型均基于 PyTorch 深度学习框架构建，我们使用的 GPU 为 NVIDIA GeForce RTX 3090，含有 24GB 显存。在网络训练阶段，模型采用纯自监督模式进行端到端训练，无需清晰图像作为监督真值。

优化器选用动量自适应的 Adam 算法，动量参数设为 β_1=0.9,β_2=0.999。初始学习率设定 1.0×10^{-3}，最大训练轮数设定为 200，并采用固定步长衰减策略。总损失函数中的权重超参数设定为 λ_{color}=1.0, λ_{line}=2.0, λ_{DoP}=2.0, λ_{smooth}=0.5。

表 4.1 实验硬件与软件配置

类别	配置详情
硬件配置	操作系统：Ubuntu 22.04.5 LTS CPU：Intel(R) Xeon(R) Silver 4210R CPU @ 2.40GHz GPU：NVIDIA GeForce RTX 3090
软件配置	算法框架：PyTorch 2.9.1 with CUDA CUDA 版本：12.8
编程语言	Python 3.10.12

为验证所提方法的有效性与优越性，我们在自建的模拟水下偏振图像数据集和真实水下及雾天数据集上进行了全面的实验评估。

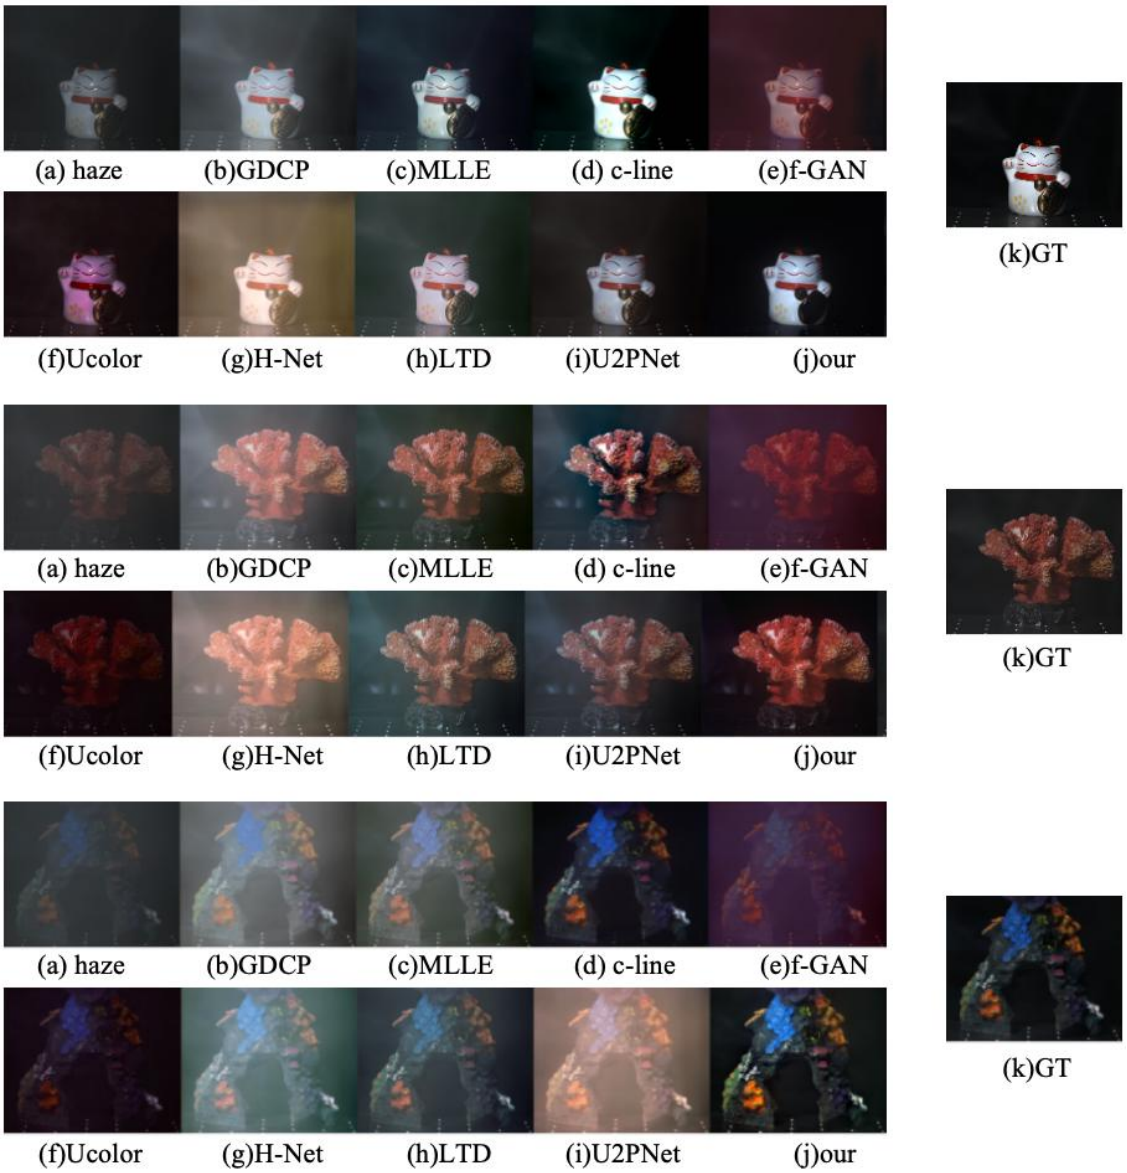
我们将提出的方法与八种方法进行比较，这些方法分为两组：三种基于物理模型/对比度增强的方法，分别是 GDCP [63]、Color-lines [55] 和 MLLE [64]，以及五种基于深度学习的方法，分别是 FUnIE-GAN [65]、Ucolor [66]，HCLR-Net [67]和 LTD[29]、U2PNet[35]）。

由于使用的水下偏振图像大部分没有参考图像，我们选择了 2 种无参考质量指标度量：水下彩色图像质量评价 UCIQE 和 UIQM ，对于所有这些指标，分数越

高，表示水下图像效果越好。

4.4.2 模拟数据集的评估与比较

首先进行定性比较的评估，在本文中，我们将不同方法分为三组进行视觉比较。第一组为有参考图像的低浑浊度场景，结果如图 4.5 所示；第二组为同一场景下浊度逐渐增加的情况（有参考图像），结果如图 4.6 所示；第三组为高浊度水平下的图像恢复结果（无参考图像），结果如图 4.7 所示。



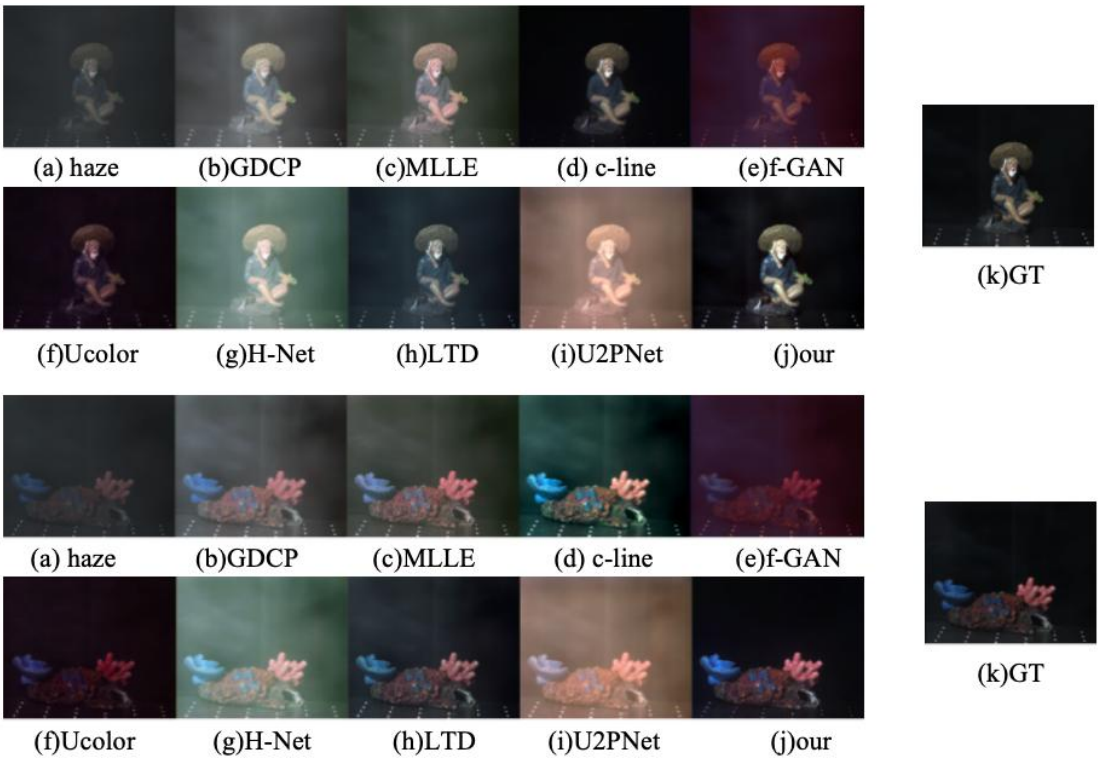


图 4.5 不同方法在低浑浊度场景的恢复对比

图 4.5 展示了第一组定性比较结果，即在低浑浊度场景下包含不同材质与表面特性目标（如陶瓷招财猫、复杂纹理的珊瑚、人偶饰品等）的图像恢复效果。图中 (a) 为原始浑浊图像，(k) 为场景的参考真值（Ground Truth），(j) 为本文提出的方法。

从视觉恢复效果来看，各种方法表现出了显著的差异：

对于基于物理模型与对比度增强的方法：GDCP (b) 和 MLLE (c) 虽然在一定程度上提升了图像的可见度，剥离了部分浅层雾感，但去散射极其不彻底，图像整体依然被一层灰白色的残留散射光笼罩，对比度偏低。Color-lines (d) 方法虽然显著提高了局部对比度，但由于其颜色线假设在水下环境的局限性，导致恢复结果出现了色彩偏移（例如在第 5 行中出现了不自然的青绿色雾气）。

对于基于深度学习的方法: FUnIE-GAN (e) 和 Ucolor (f) 出现了灾难性的色彩失真现象，整个画面呈现出严重的紫红色调，且 Ucolor 在暗部区域出现了严重的细节丢失与死黑现象。H-Net (g) 去散射能力有限，图像依然残留着明显的黄色雾化效应；LTD (h) 同样未能有效去除散射背景，且整体色调偏向青灰色。值得注意的是, 同为基于偏振的深度学习代表性方法 U2PNet (i)其恢复结果存在明显的全局色偏（整体泛现橙粉色的暖色调），未能准确还原物体的真实本征色彩。

相比于上述基线模型，本文方法（j）取得了最佳的视觉恢复效果。得益于严密的物理先验约束与无监督架构的联合驱动，本文方法不仅彻底消除了水下后向散射引起的雾化效应，极大提升了图像对比度，而且在色彩保真度上表现极为优异。无论是招财猫的高光表面（第 1 行）、珊瑚的复杂粗糙纹理（第 2 行），还是人偶草帽的编织细节（第 4 行），本文方法都实现了高锐度、高保真的重建。其最终的恢复色彩与光影分布极其自然，与参考真值（ (k) 列）高度一致，未产生任何局部伪影或全局色偏。



图 4.6 不同方法对于不同浑浊度场景的恢复对比

图 4-6 展示了第二组定性比较结果。该组实验在同一水下场景（包含红色易拉罐、珊瑚模型与贝壳）中，记录了水体浑浊度由浅入深（从上至下）的动态退化过程与各算法的恢复表现。图中 (a) 为不同浑浊度下的原始退化图像，(k) 为清晰的参考真值（Ground Truth），(j) 为本文提出方法的恢复结果。

随着水体浊度的增加，散射效应越来越明显，图像对比度逐渐降低、细节信息模糊。因此，该实验能够更直观地评估不同方法在不同散射强度下的鲁棒性与稳定性。

从图 4-6 可知，在水下散射模型的参数估计中，许多方法难以适应真实浑浊度的动态变化。传统的 GDCP (b) 和 MLLE (c) 在低浑浊度下尚有一定效果，但在中高浑浊度下去散射极不彻底，画面被浓重的灰白雾感所笼罩。在深度学习方法中，Ucolor (f)存在明显的雾浓度（Haze）估计错误问题，不仅未能有效剥离散射层，反而因局部特征的过度提取导致画面出现了不自然的雾感和暗部。此外，LTD (h)由于其网络模型高度依赖于合成的图像进行训练，在面对真实水域复杂的散射介质时，产生了严重的“域偏移”问题。这种对合成数据的过拟合导致 LTD 在真实高浑浊场景中出现了明显的参数估计错误，其恢复图像残留着明显的浑浊雾感。

部分方法存在色彩的估计错误，Color-lines (d) 由于颜色线先验在浓雾下鲁棒性较差，色彩恢复性能下降；FUnIE-GAN (e) 将原本的场景渲染成了极不真实的紫红色；同为基于偏振的无监督图像恢复方法，U2PNet (i) 对全局背景光偏振态的解耦仍不够精确，这导致 U2PNet 的恢复结果虽然提升了对比度，但不可避免地出现了全局的色彩偏移，并在易拉罐边缘等高频纹理处伴生了结构性伪影，未能实现高保真的视觉重建。

相比之下，本文方法（j）无论是面对轻度散射（第 1 行），还是目标轮廓已极度模糊的重度浑浊（第 4 行）的情况，均表现出更加稳定的恢复效果。随着浊度逐渐增加，本文方法仍能够有效抑制散射带来的雾化效应，并在保持图像整体亮度的同时恢复较为自然的颜色分布，未引入任何偏色与伪影，在视觉观感与物理特征上均更加接近参考图像。该结果表明，通过在恢复过程中引入偏振相关先验约束，能够有效提升网络对水下散射退化的建模能力，从而在复杂水下环境中实现更加稳定和准确的图像恢复。

图 4.7 展示了不同方法在高浑浊度水下场景中的图像恢复效果，该实验能够更充分地检验不同方法在极端散射条件下的恢复能力。

为了更直观地比较不同方法的细节恢复能力，图中使用红色和橙色矩形框标注了多个关键区域，并在下方给出了对应的局部放大结果。从这些细节区域可以观察到，不同方法在结构细节与颜色恢复方面存在明显差异。例如，在贝壳纹理、

珊瑚结构以及背景文字等区域，部分方法存在明显的模糊现象或颜色失真，而本文方法能够较好地恢复物体的边缘结构和纹理细节。同时，在高浑浊度环境下，本文方法能够有效抑制散射光带来的亮度漂移，使得局部区域的对比度更加自然稳定。

综合来看，在高浊度复杂水体环境下，本文方法能够在抑制散射雾化、保持自然颜色以及恢复细节结构等方面取得更加稳定和优越的视觉效果，表明所提出的偏振先验引导自监督网络在复杂水下成像环境中具有良好的鲁棒性和泛化能力。





图 4.7 不同方法在高浑浊度场景的恢复对比

为了全面且客观地评估不同方法在真实复杂水下场景中的泛化能力与恢复性能，本文选取了 860 幅包含不同目标物体、处于不同浑浊度下的无参考水下彩色图像进行定量测试。评价指标选用了两种无参考水下图像质量评价标准：水下彩色图像质量评价（UCIQE）和水下图像质量度量（UIQM）。表 4.2 展示了各对比方法在这 860 幅图像上的 UIQM 和 UCIQE 平均测试结果。

UIQM 是一种综合度量，由色彩度 (UICM)、清晰度 (UISM) 和对比度 (UIConM) 三个分量加权组合而成。从表 4.2 可以看出，基于生成对抗网络的 FUnIE-GAN 取得了最高的 UIQM 得分（2.9436），本文方法位列第二（2.3931）。值得注意的是，FUnIE-GAN 作为数据驱动的生成式模型，其生成器在对抗训练过程中可能倾向于通过放大色彩饱和度与局部对比度来适应判别器的评估标准。这种不受底层物理退化规律约束的处理方式，在一定程度上迎合了 UIQM 的计算逻辑，从而提升了其色彩度与对比度得分。然而，该模型在其他指标上的表现值得关注——其 UCIQE 得分仅为 0.4752，在所有对比方法中相对较低。结合前文定性对比结果（如图 4.7 所示），FUnIE-GAN 在部分场景中出现了较为明显的色彩偏移现象，这表明单一指标的优异表现可能难以全面反映模型的整体恢复效果。

UCIQE 指标通过线性组合图像的色度、饱和度和对比度来量化水下图像的恢复质量，对色彩畸变具有较强的敏感性。从表 4.2 可见，本文方法取得了最高的 UCIQE 得分（0.5966），优于传统物理方法与现有深度学习方法。这一结果一定程度上验证了本章方法设计的有效性：消色差先验有助于对全局背景光偏振态进行合理评估，偏振相关的衰减先验则能够实现对局部透射率的物理约束。基于这些设计，本文方法在有效剥离后向散射、提升图像对比度的同时，较好地保留了物体的色彩与细节信息。

表 4.2 各方法的 UIQM，UCIQE 均值

Method	UIQM	UCIQE
GDCP	1.3191	0.5016
MLLE	2.3523	0.5199
Color-lines	2.1233	0.5905
FUnIE-GAN	**2.9436**	0.4752
Ucolor	2.1397	0.5454
HCLR-Net12	1.5753	0.5091
LTD	1.8855	0.5257
U2PNet	2.0111	0.5606
our	2.3931	**0.5966**

与同样基于偏振先验的 U2PNet（UIQM 2.0111，UCIQE 0.5606）相比，本文方法在两项指标上均有所提升。这表明，本文提出的“同源特征提取、异构参数解耦”双分支网络架构，在无需参考真值标签的条件下，能够通过多偏振先验联合损失函数的引导，在一定程度上平衡图像对比度增强与色彩保真之间的关系。客观

指标结果与前文的主观定性评价吻合，从不同角度印证了本文方法在复杂水下环境中的可行性与鲁棒性。

4.4.3 真实数据集的评估与比较

真实水下偏振数据[35]使用的是公开数据集，采集自中国深圳附近海域，对象主要包括珊瑚、水草和沙子，如图 4.8 所示。由于数据是单色图像，在算法处理过程中，我们将单通道图像复制为三通道作为输入，并在输出后将三通道图像转换回灰度图像。这些方法是为彩色图像设计的，我们在此操作中力求尽可能公平。MLLE[64] 等方法不适用于这类图像，因此我们在图 4.9 中展示了部分方法的比较结果。

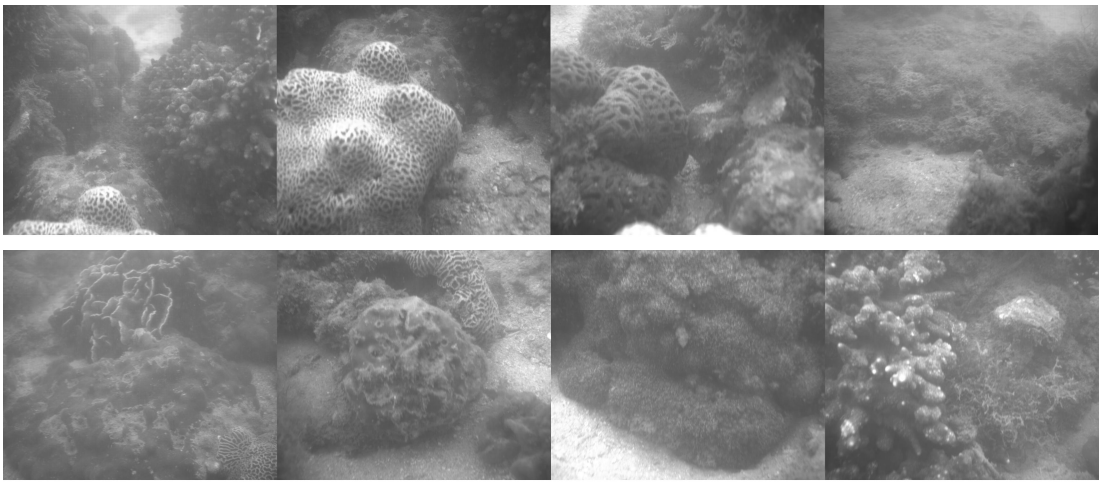
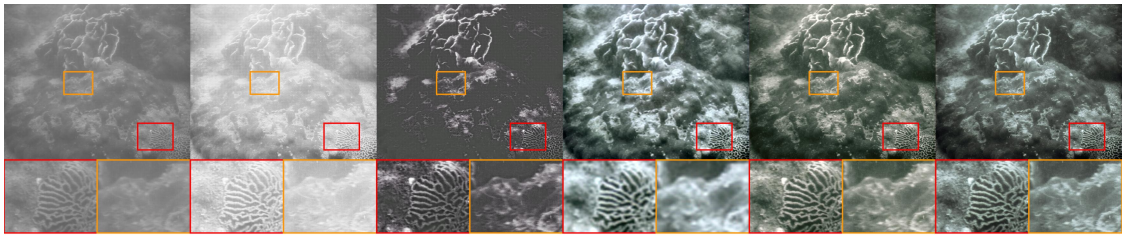


图 4.8 真实水下偏振数据集

图 4-9 清晰地表明，GDCP [63]方法在减轻散射影响方面效果有限，另一方面，Color-lines[55]的方法往往引入更显著的失真。相比之下，HCLR-Net[67]、U2PNet[35]和本文方法在增强图像对比度方面表现出实质性改进。与本文方法相比，其他方法在散射去除方面表现欠佳，尤其是在远处区域，以及细节恢复上。总的来说，我们的方法可以极大地减少散射的影响，对于近处物体，如珊瑚、沙子等，我们提出的方法可以明显提高其对比度。对于远处物体，如石头、沙子等，我们提出的方法可以校正其亮度以减少散射的影响。



(a) haze (b)GDCP (d) c-line (g)H-Net (i)U2PNet (j)our

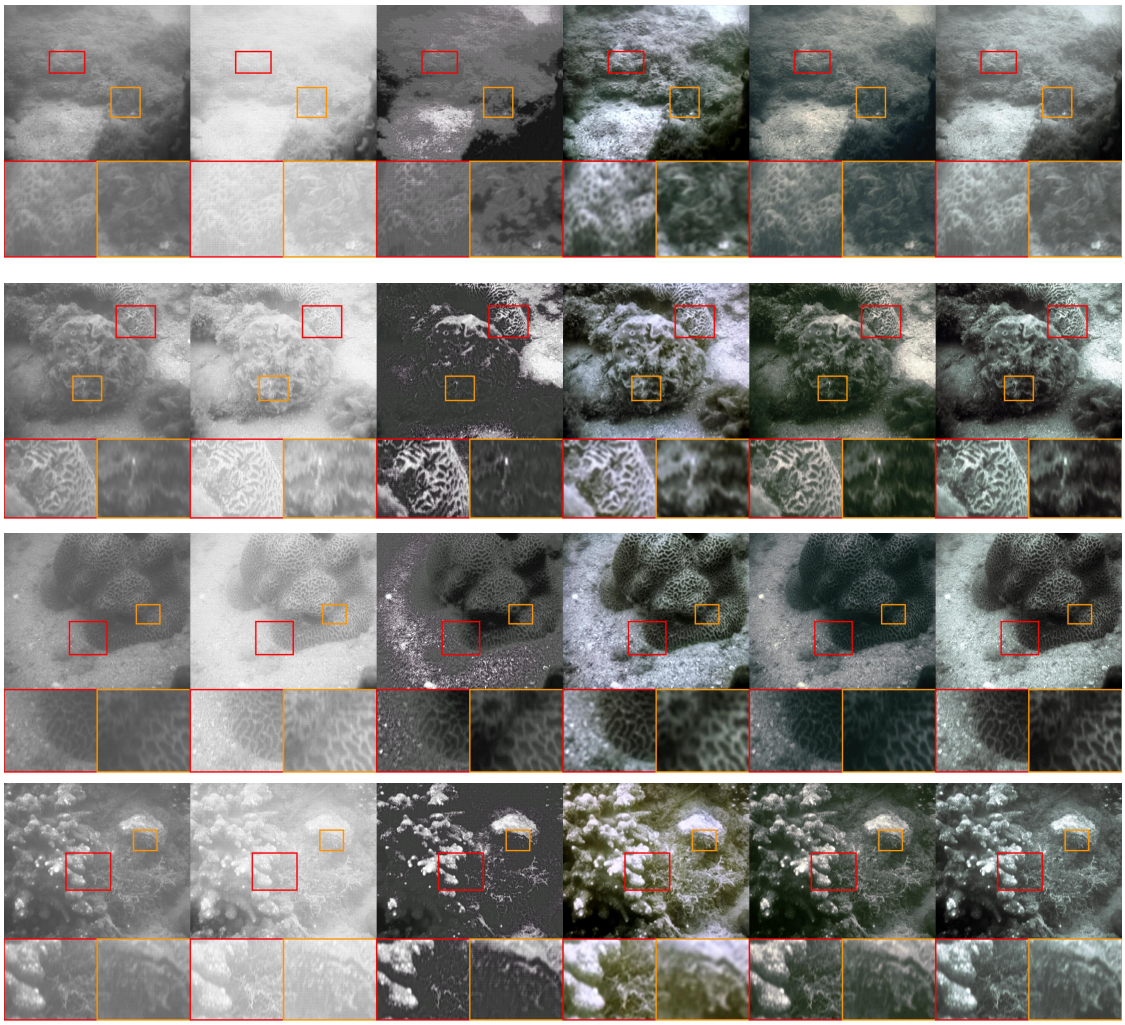
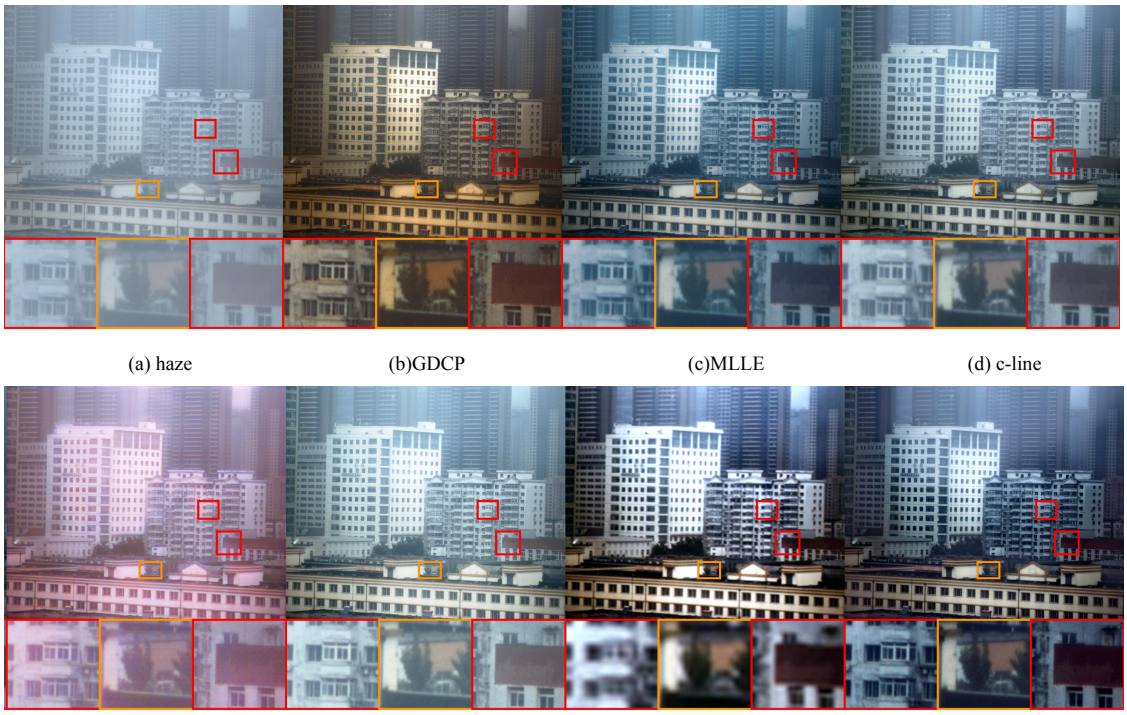


图 4.9 不同方法的恢复情况

本文提出的方法也适用于雾霾和沙尘暴中的图像恢复，本文在未进行任何针对性重新训练的条件下，直接将该模型应用于大气雾霾图像的去雾测试。为了证明我们方法的泛化能力，我们将我们提出的方法与 GDCP [63]、MLLE [64]、Color-lines [55]、FUnIE-GAN[66]、HCLR-Net [67]、U2PNet [35]，进行了比较。如图 4-10 所示中，我们提出的方法可以以更少的失真提高可见度。

从局部放大图（红框与橙框）可以直观地看到，本文方法不仅剥离了厚重的雾霾，恢复了极其锐利的建筑窗格与屋顶物理边缘，而且还原了场景的真实自然色彩（如纯净的白色楼体与红棕色屋檐），未引入任何色彩畸变或对比度溢出，验证了本章网络架构与多偏振物理先验的跨域泛化能力。



(a) haze (b)GDCP (c)MLLE (d) c-line

(e) f-Gan (f)H-Net (g)U2PNet (h) our

图 4.10 雾霾场景去雾效果

4.5 消融实验及运行时间分析

4.5.1 消融实验

我们进行了消融研究以验证损失函数的有效性，我们通过组合不同的损失函数重新训练以验证各个损失函数的效果。表 4.3 展示了损失函数消融实验的结果，实验的最优结果加粗表示。表格显示，L_{DoP} 和 L_{line} 对图像恢复结果有显著影响，而 L_{color} 和 L_{smooth}的影响较小。

当移除 L_{color} 时，网络失去了对全局背景光偏振态的消色差约束，虽然图像对比度有所提升，但画面会出现部分色偏。L_{line} 约束了复平面上的相位与幅值对齐。移除该项后，网络对复偏振态的解耦能力下降，导致在复原图像中，目标物体的物理边缘(尤其是不同材质交界处)出现了结构性模糊与偏振高频细节的丢失。L_{DoP}是引导网络感知相对景深的核心，消融该先验后，网络倾向于预测一个平滑但缺乏深浅梯度的透射率图，图像远景区域的易残留大量的灰白雾霾。

表 4.3 损失函数消融实验的定量比较

Method	UIQM	UCIQE
w/o L_{color}	1.983	0.591
w/o L_{DoP}	1.713	0.576
w/o L_{line}	1.499	0.565
w/o L_{smooth}	2.019	0.594
ours	**2.393**	**0.597**

4.5.2 运行时间分析

为了进一步评估不同方法在实际应用中的可行性, 本文对各类算法的运行时间进行了统计比较。所有方法均在操作系统为 Ubuntu 22.04.5 LTS，CPU 为 Intel(R) Xeon(R) Silver 4210R CPU @ 2.40GHz, GPU 为 NVIDIA GeForce RTX 3090 的实验环境下进行测试，所有方法测试的图像的分辨率均为 2044×2048 像素，表 4.4 记录了处理单幅图像所需的平均时间。

表 4.4 不同方法的计算时间比较

Method	Runtime
GDCP	0.39
Color-lines	104.3
MLLE	2.4
F-GAN	0.67
Ucolor	0.89
H-Net	0.35
LTD	0.62
U2PNet	1.1
ours	0.59

从表中可以看出，基于传统物理模型的方法整体运行时间较长。例如，Color-lines 方法由于需要进行复杂的像素聚类与迭代优化, 运行时间高达 104.3 s；MLLE 方法也需要进行多步特征计算和全局优化, 耗时约 2.4 s。相比之下, GDCP 由于主要依赖简单统计与滤波操作，其运行时间相对较短，为 0.39 s，但该方法在

复杂水下场景中的恢复效果较为有限。

基于深度学习的方法在运行效率方面具有明显优势。由于神经网络在推理阶段只需进行一次前向传播，大多数方法的运行时间均在 1 s 内。例如，FUnIE-GAN 的运行时间约为 0.67 s，Ucolor 约为 0.89 s，U2PNet 约为 1.1 s，表现出较高的处理效率。这些方法避免了传统物理方法中复杂的参数估计和迭代优化过程，因此在实时应用场景中具有更好的潜力。

在第三章中提出的基于物理先验的去散射方法需要进行偏振透射率估计、像素聚类以及加权最小二乘平滑等多步骤优化，其整体运行时间约为 5.46 s。虽然该方法能够取得较好的恢复效果，但复杂的优化过程导致其难以满足应用需求。

相比之下，本章提出的物理先验引导自监督网络方法将传统物理求解过程转化为深度网络的前向推理过程。通过引入共享特征编码器以及双分支结构（T-Net 与 B-Net），网络能够在一次前向传播中同时完成透射率图与背景光参数的估计，从而避免了传统方法中繁杂的聚类与迭代优化步骤。根据实验测试结果，本文方法在 GPU 推理环境下处理单幅图像的平均时间约为 0.6 s 左右。

与第三章的物理优化方法相比，本文方法的运行时间减少了约 9 倍，显著提升了计算效率。同时，与现有深度学习方法相比，本文方法在保持较高恢复质量的同时，其运行时间也处于同一数量级范围内。这表明，通过将偏振物理先验与深度网络结构相结合，可以在保证恢复效果的同时，大幅提升算法的运行效率，使其更具备在水下机器人视觉感知等低时延应用场景中的应用潜力。

4.6 本章小结

针对第 3 章纯物理优化方法计算耗时大、超参数鲁棒性不足，以及现有深度学习方法依赖成对“清晰-浑浊”真值标签且易产生域偏移等问题，本章提出了一种物理先验引导的自监督水下图像恢复网络。

为突破传统物理数值求解的计算瓶颈，本章设计了由 ResNet-50 共享编码器、透射率估计解码分支（T-Net）和全局背景光回归分支（B-Net）组成的深度神经网络。该架构较好地契合了水下物理参数的空间分布特性，通过一次前向推理即可同时完成局部透射率图的密集预测与全局背景光参数的非线性回归，并在末端通过无参数物理反演模块实现图像的重建。同时，本章将水下偏振物理规律转化为网络可微的无参考损失函数，通过联合消色差先验损失、偏振度衰减先验损失、偏振线先验损失以及边缘感知空间平滑损失，在完全不依赖清晰参考图像的条件下，实现了符合物理先验规律的图像清晰化。

在模拟水下数据集、真实单色偏振水下数据集以及跨域大气雾霾数据集上的

综合实验表明：本章方法在抑制散射雾化、还原本征色彩以及恢复高频结构纹理方面均取得了较好的视觉效果。在客观评价上，本章方法取得了较高的 UCIQE 得分和具有竞争力的 UIQM 得分。此外，消融实验验证了各项物理先验的有效性；运行时间分析表明，本章方法单图处理时间约为 0.6 秒，较第 3 章的物理优化方法提升约 9 倍，算法计算效率得到显著提升，与现有深度学习方法运行时间处于同一数量级范围内，展现出在实际工程装备中部署的潜力。

第 5 章 总结与展望

5.1 论文工作总结

本文围绕基于偏振成像的水下图像去散射技术开展研究，针对现有方法对全偏振信息利用不充分、参数估计依赖人工干预、深度学习模型缺乏成对数据等核心问题，从偏振物理机理出发，构建了一套从数据基础构建、物理先验挖掘到自监督网络学习的完整技术体系。本文的主要工作总结如下：

1. 构建了目前最大的水下偏振彩色图像数据集：从偏振成像的基本原理出发，搭建了主动偏振照明与分焦平面偏振相机相结合的采集平台，并基于米氏散射理论论证了脱脂牛奶模拟水下悬浮颗粒散射特性的物理可行性。数据集主要分为两类：一是不同浑浊度下的相同场景数据集（6 个浊度等级，含真值），用于算法定量评估；二是相同浊度下的不同目标物体数据集，涵盖金属、塑料、木质、纸质等多种典型材质，共计 7680 张偏振图像。该数据集为偏振物理规律的验证、传统算法的评估以及深度学习模型的训练提供了坚实的数据支撑。

2. 提出了融合多偏振先验的水下图像去散射物理方法：针对现有方法对全偏振信息利用不充分的问题，引入复平面偏振态统一表征方法，推导出偏振退化线性叠加模型。在此基础上，深入挖掘并验证了偏振线先验、偏振度衰减先验和偏振消色差先验三个核心物理规律。基于这些先验，分别设计了基于偏振线先验和基于 DoLP 衰减与消色差先验的两套图像恢复方法，并通过多尺度拉普拉斯金字塔融合策略综合两者优势。该方法在不同偏振特性物体和不同浑浊度场景下均取得了优于对比方法的恢复效果，UIQM 和 UCIQE 指标分别达到 2.3821 和 0.5954，实现了场景颜色信息与全偏振信息的高保真恢复。

3. 设计了物理先验引导的自监督水下图像恢复网络：针对传统物理优化方法计算耗时长、参数鲁棒性不足的问题，提出“同源特征提取、异构参数解耦”的双分支网络架构，通过共享编码器、透射率估计子网络和背景光子网络，并行完成局部透射率图与全局背景光参数的高效估计。将挖掘得到的偏振物理先验转化为了可微分的无参考损失函数，包括消色差先验损失、偏振度衰减先验损失、偏振线先验损失和边缘感知空间平滑损失，实现零标签条件下的端到端自监督训练。实验结果表明，该方法在 UCIQE 指标上取得最高得分（0.5966），UIQM 指标位列第二（2.3931），单图处理时间约 0.6 秒，较传统物理优化方法提升约 9 倍，在保证恢复质量的同时显著提升了计算效率。

本文的主要创新点总结如下：

提出了物理先验引导的自监督水下图像恢复网络，实现了零标签条件下的高效训练。针对传统偏振去散射方法对全偏振信息利用不充分、参数估计依赖人工干预、深度学习模型缺乏成对数据等核心难题，本文首次将偏振物理先验与自监督学习框架深度融合，构建了一套无需成对标签、完全数据自驱动的端到端训练范式。

在具体实现上，本文深入挖掘了水下偏振退化的底层物理机理，将偏振线先验、偏振度衰减先验和偏振消色差先验等核心物理规律创新性地转化为可微分的无参考损失函数，使得物理知识能够直接参与网络的反向传播过程，突破了传统方法中物理模型与数据驱动的局限。在此基础上，本文设计了双分支网络架构，通过共享编码器提取公共特征，同时利用透射率估计子网络和背景光子网络分别拟合透射率图与背景光参数，实现了对物理模型中不同类别参数的高效解耦估计。实验结果表明，该方法在 UCIQE，UIQM 指标上表现优异，单图处理时间在最优数量级内，在零标签条件下同时保证了恢复质量与计算效率，为深度学习在偏振去散射领域的实际应用提供了新的技术路径。

5.2 未来展望

本文在基于偏振成像的水下去散射技术领域取得了阶段性成果，但仍存在若干值得进一步探索的方向。未来的工作将主要从以下几个方面展开：

1. 引入对比学习提升特征判别能力：当前自监督网络主要依赖物理损失函数的数值约束，隐空间特征的类间区分度仍有提升空间。对比学习能够学习更具判别性的特征表示，主动靠近清晰图像正样本、远离浑浊图像负样本。未来可考虑将对比学习引入自监督框架，通过无配对的清晰-浑浊图像对的正负样本，引导网络学习水下图像退化与复原的深层特征差异，有望进一步突破模型在极端恶劣环境下的鲁棒性上限。

2. 探索更多偏振物理规律并丰富数据集：本文已验证了偏振线、偏振度衰减和消色差三个核心先验的有效性，水下环境中仍可能存在其他有待挖掘的偏振物理规律。未来可进一步拓展偏振物理机理的研究深度，并将这些规律融入模型设计。同时，当前数据集主要基于实验室模拟环境构建，未来可引入真实海域采集的水下偏振图像，涵盖更多复杂场景，如浑浊流、生物发光、人工光源干扰等，进一步提升模型的泛化能力和实际应用价值。

3. 优化网络结构，设计更高实时性的水下图像恢复网络：本文提出的自监督网络已实现约 0.6 秒的单图处理速度，较传统物理优化方法提升约 9 倍，但面向水

下机器人、实时探测等对帧率要求较高的应用场景仍有一定距离。未来可从以下方面进一步优化网络结构：一是探索轻量化卷积设计，如深度可分离卷积、分组卷积等，降低参数量和计算复杂度，同时保持恢复质量不下降；二是引入知识蒸馏技术，以本文网络为教师网络，训练更轻量的学生网络，实现精度与速度的更好平衡；三是研究基于 Transformer 的轻量级架构或动态推理机制，根据图像内容自适应调整计算量。通过这些优化，有望为水下设备的实时视觉感知提供更高效的技术方案。

参考文献

[1] Satat G, Heshmat B, Raviv D, et al. All photons imaging through volumetric scattering[J]. Scientific reports, 2016, 6(1): 1-8.

[2] He D M, Seet G G L. Divergent-beam lidar imaging in turbid water[J]. Optics and lasers in engineering, 2004, 41(1): 217-231.

[3] Bonin-Font F, Oliver G, Wirth S, et al. Visual sensing for autonomous underwater exploration and intervention tasks[J]. Ocean Engineering, 2015, 93: 25-44.

[4] Bonin F, Burguera A, Oliver G. Imaging systems for advanced underwater vehicles[J]. Journal of Maritime Research, 2011, 8(1): 65-86.

[5] Walraven R. Polarization Imagery[J]. Optical Engineering, International Society for Optics and Photonics, 1981, 20(1): 200114.

[6] Schechner Y Y, Karpel N. Clear underwater vision[C]. Computer Vision and Pattern Recognition, 2004. CVPR 2004. Proceedings of the 2004 IEEE Computer Society Conference on. IEEE, 2004.

[7] Schechner Y Y, Karpel N. Recovery of underwater visibility and structure by polarization analysis[J]. IEEE Journal of Oceanic Engineering, 2005, 30(3): 570-587.

[8] Liu F, Cao L, Shao X, et al. Polarimetric dehazing utilizing spatial frequency segregation ofimages[J]. Applied optics,2015,54(27):8116-8122.

[9] Liang J, Ren L, Ju H, et al. Polarimetric dehazing method for dense haze removal based on distribution analysis of angle of polarization[J]. Optics express,2015,23(20):26146-26157.

[10] Liang J, Zhang W, Ren L, et al. Polarimetric dehazing method for visibility improvement based on visible and infrared image fusion[J]. Applied optics,2016,55(29):8221-8226.

[11] Treibitz T, Schechner Y Y. Active polarization descattering [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence,2008,31(3):385-399.

[12] Shen L, Zhao Y, Peng Q, et al. An iterative image dehazing method with polarization[J]. IEEE Transactions on Multimedia.2018,21(5):1093-1107.

[13] Tyo J S, Rowe M P, Pugh E N, et al. Target detection in optically scattering media by polarization-difference imaging[J]. Applied Optics, 1996, 35(11): 1855–1870.

[14] Shen L, Reda M, Zhang X, et al. Polarization-Driven Solution for Mitigating Scattering and Uneven Illumination in Underwater Imagery[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024.

[15] Huang B, Liu T, Hu H, et al. Underwater image recovery considering polarization effects of objects[J]. Optics express, 2016, 24(9): 9826-9838.

[16] Hu H, Zhao L, Huang B, et al. Enhancing visibility of polarimetric underwater image by transmittance correction[J]. IEEE Photonics Journal, 2017, 9(3): 1-10.

[17] Liang Z, Zhao C, Wang Y, et al. Adaptive underwater image recovery using polarimetric imaging[C]. Tenth International Conference on Graphics and Image Processing (ICGIP 2018). International Society for Optics and Photonics, 2019, 11069: 110692L.

[18] Li Y, Zhang J, Chen Y, et al. Underwater image restoration via spatially adaptive polarization imaging and color correction[J]. Knowledge-Based Systems, 2024, 305: 112651.

[19] Liang J, Ren L, Qu E, Hu B, Wang Y. Method for enhancing visibility of hazy imagesbased on polarimetric imaging. Photon Res 2014;2:38–44. https://doi.org/10.1364/prj.2.000038.

[20] Yang L, Liang J, Zhang W, et al. Underwater polarimetric imaging for visibility enhancement utilizing active unpolarized illumination[J]. Optics Communications, 2019, 438: 96-101.

[21] Zhang X, Song M, Fan Z, et al. Reconstruction algorithm of haze image based on blind separation model of polarized orthogonal airlight[J]. Optics Express, 2022, 30(23): 42097-42113.

[22] Deng J, Zhu J, Li H, et al. Real-time underwater polarization imaging without relying on background[J]. Optics and Lasers in Engineering, 2023, 169: 107721.

[23] Su Y, Zhang Z, Lu Y, et al. Underwater descattering with polarization line constraint[J]. Optics and Lasers in Engineering, 2024, 179: 108265.

[24] Wei Y, Han P, Liu F, et al. Polarization descattering imaging: a solution for nonuniform polarization characteristics of a target surface[J]. Chinese Optics Letters, 2021, 19(11): 111101.

[25] Wei Y, Han P, Liu F, et al. Estimation and removal of backscattered light with nonuniform polarization information in underwater environments[J]. Optics Express, 2022, 30(22): 40208-40220.

[26] Hu H, Zhang Y, Li X, et al. Polarimetric underwater image recovery via deep learning[J]. Optics and Lasers in Engineering, 2020, 133: 106152.

[27] Zhang R, Gui X, Cheng H, et al. Underwater image recovery utilizing polarimetric imaging based on neural networks[J]. Applied Optics, 2021, 60(27): 8419-8425.

[28] Ding X, Wang Y, Fu X. Multi-polarization fusion generative adversarial networks for clear underwater imaging[J]. Optics and Lasers in Engineering, 2022, 152: 106971.

[29] Zhou C, Teng M, Han Y, et al. Learning to dehaze with polarization[J]. Advances in neural information processing systems, 2021, 34: 11487-11500.

[30] Ren Q, Xiang Y, Wang G, et al. The underwater polarization dehazing imaging

with a lightweight convolutional neural network[J]. Optik, 2022, 251: 168381.

[31] Zhu Y, Zeng T, Liu K, et al. Full scene underwater imaging with polarization and an untrained network[J]. Optics Express, 2021, 29(25): 41865-41881.

[32] Yu C, Chang Y, Li Y, et al. Unsupervised image deraining: Optimization model driven deep cnn[C]//Proceedings of the 29th ACM International Conference on Multimedia. 2021: 2634-2642.

[33] Li B, Gou Y, Gu S, et al. You only look yourself: Unsupervised and untrained single image dehazing neural network[J]. International Journal of Computer Vision, 2021, 129(5): 1754-1767.

[34] Fu Z, Lin H, Yang Y, et al. Unsupervised underwater image restoration: From a homology perspective[C]//Proceedings of the AAAI conference on artificial intelligence. 2022, 36(1): 643-651.

[35] Shen L, Xia H, Zhang X, et al. U2PNet: An Unsupervised Underwater Image-Restoration Network Using Polarization[J]. IEEE Transactions on Cybernetics, 2024.

[36] Liang J, Ren L, Qu E, et al. Method for enhancing visibility of hazy images based on polarimetric imaging[J]. Photonics Research, 2014, 2(1): 38-44.

[37] Yang L, Liang J, Zhang W, et al. Underwater polarimetric imaging for visibility enhancement utilizing active unpolarized illumination[J]. Optics Communications, 2019, 438: 96-101.

[38] Li X, Han Y, Wang H, et al. Polarimetric imaging through scattering media: A review[J]. Frontiers in physics, 2022, 10: 815296.

[39] Guan J, Ren W, Cheng Y. Stokes vector based interpolation method to improve the efficiency of bio-inspired polarization-difference imaging in turbid media[J]. Journal of Physics D: Applied Physics, 2018, 51(14): 145402.

[40] Yang Z, Hao C, Lu Y, et al. A novel dehazing approach: Recovery of color and polarization information using polarized characteristics[J]. IEEE Transactions on Multimedia, 2025.

[41] Zhu Y, Zeng T, Liu K, et al. Full scene underwater imaging with polarization and an untrained network[J]. Optics Express, 2021, 29(25): 41865-41881.

[42] 胡浩丰,费筱茼,申凌皓,等.基于偏振成像的水下非均匀光照图像恢复[J/OL].光学学报,1-20[2024-12-02].

[43] 胡浩丰,黄一钊,朱震,等.基于深度学习复杂环境的偏振成像技术研究进展[J].红外与激光工程,2024,53(03):9-26.

[44] 齐鹏飞.基于偏振模型的水下图像复原方法研究[D].天津大学,2021.DOI:10.27356/d.cnki.gtjdu.2021.004020.

[45] 张燕彬.基于深度学习的水下灰度偏振图像复原方法的研究[D].天津大学,2021.DOI:10.27356/d.cnki.gtjdu.2021.000648.

[46] 梁政.基于物理模型的水下光学图像清晰化方法研究[D].大连海事大学,2021.DOI:10.26989/d.cnki.gdlhu.2021.000143.

[47] Dubreuil M, Delrot P, Leonard I, et al. Exploring underwater target detection by imaging polarimetry and correlation techniques[J]. Applied Optics, 2013, 52(5): 997-1005.

[48] Piederrière Y, Boulvert F, Cariou J, et al. Backscattered speckle size as a function of polarization: influence of particle-size and-concentration[J]. Optics Express, 2005, 13(13): 5030-5039.

[49] Myre E, Shaw R. The turbidity tube: simple and accurate measurement of turbidity in the field[D]. Michigan Technological University, 2006.

[50] Liu F, Han P, Wei Y, et al. Deeply seeing through highly turbid water by active polarization imaging[J]. Optics Letters, 2018, 43(20): 4903-4906.

[51] Stramski D, Boss E, Bogucki D, et al. The role of seawater constituents in light backscattering in the ocean[J]. Progress in Oceanography, 2004, 61(1): 27-56.

[52] Piederrière Y, Boulvert F, Cariou J, et al. Backscattered speckle size as a function of polarization: influence of particle-size and-concentration[J]. Optics Express, 2005, 13(13): 5030-5039.

[53] Yang M, Sowmya A. An underwater color image quality evaluation metric[J]. IEEE transactions on image processing, 2015, 24(12): 6062-6071.

[54] Panetta K, Gao C, Agaian S. Human-visual-system-inspired underwater image quality measures[J]. IEEE journal of oceanic engineering, 2015, 41(3): 541-551.

[55] Berman D, Avidan S. Non-local image dehazing[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 1674-1682.

[56] Fattal R. Dehazing using color-lines[J]. ACM transactions on graphics (TOG), 2014, 34(1): 1-14.

[57] Farbman Z, Fattal R, Lischinski D, et al. Edge-preserving decompositions for multi-scale tone and detail manipulation[J]. ACM transactions on graphics (TOG), 2008, 27(3): 1-10.

[58] Akkaynak D, Treibitz T. A revised underwater image formation model[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6723-6732.

[59] Foster D H. Color constancy[J]. Vision research, 2011, 51(7): 674-700.

[60] Heusel M, Ramsauer H, Unterthiner T, et al. Gans trained by a two time-scale update rule converge to a local nash equilibrium[J]. Advances in neural information processing systems, 2017, 30.

[61] Mittal A, Soundararajan R, Bovik A C. Making a “completely blind” image quality analyzer[J]. IEEE Signal processing letters, 2012, 20(3): 209-212.

[62] Venkatanath N, Praneeth D, Sumohana S C, et al. Blind image quality evaluation

using perception based features[C]//2015 twenty first national conference on communications (NCC). IEEE, 2015: 1-6.

[63] Peng Y T, Cao K, Cosman P C. Generalization of the dark channel prior for single image restoration[J]. IEEE Transactions on Image Processing, 2018, 27(6): 2856-2868.

[64] Zhang W, Zhuang P, Sun H H, et al. Underwater image enhancement via minimal color loss and locally adaptive contrast enhancement[J]. IEEE transactions on image processing, 2022, 31: 3997-4010.

[65] Islam M J, Xia Y, Sattar J. Fast underwater image enhancement for improved visual perception[J]. IEEE robotics and automation letters, 2020, 5(2): 3227-3234.

[66] Li C, Anwar S, Hou J, et al. Underwater image enhancement via medium transmission-guided multi-color space embedding[J]. IEEE Transactions on Image Processing, 2021, 30: 4985-5000.

[67] Zhou J, Sun J, Li C, et al. HCLR-Net: Hybrid contrastive learning regularization with locally randomized perturbation for underwater image enhancement[J]. International Journal of Computer Vision, 2024, 132(10): 4132-4156.

[68] Shwartz S, Namer E, Schechner Y Y. Blind haze separation[C]//2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06). IEEE, 2006, 2: 1984-1991.

[69] Ling P, Chen H, Tan X, et al. Single image dehazing using saturation line prior[J]. IEEE Transactions on Image Processing, 2023, 32: 3238-3253.

[70] Ono T, Kondo Y, Sun L, et al. Degree-of-linear-polarization-based color constancy[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 19740-19749.

[71] 胡浩丰,李天赐,申凌皓.散射介质中偏振图像模拟方法及应用[J].陕西师范大学学报(自然科学版),2024,52(06):1-11.DOI:10.15983/j.cnki.jsnu.2024327.

[72] 刘贺东,韩宜霖,李校博,等.基于深度神经网络的水下图像偏振信息复原方法[J].光学学报,2024,44(12):61-70.

[73] Wan Z, Liang J, Li K, et al. Underwater polarization de-scattering method using residual dense block and depth-wise convolution[J]. Optics Express, 2025, 33(12): 24662-24677.

[74] 唐文娟,戴群.红外图像去雾领域研究方法综述[J].红外与激光工程,2024,53(02):214-224.

[75] 蔡雅新,徐晶,朱嘉悦,等.基于偏振成像的水下图像去模糊方法综述[J].光散射学报,2025,37(04):534-548.DOI:10.13883/j.issn1004-5929.202504003.

[76] 岳成海,徐会希,吕凤天,等.基于光照补偿与金字塔融合的水下图像增强方法[J].水下无人系统学报,2025,33(01):46-55.

[77] Zhu Y Q, Wang X, Zhu Z Z. Underwater polarization de-scattering imaging independent of target-free region[J]. Acta Phys. Sin, 2025, 74(4): 044201.

[78] 王佳节,万敏杰,张晓杰,等.利用偏振图像加权融合及 CLAHE 算法的水下成像方法[J].飞控与探测,2023,6(01): 86-94.DOI:10.20249 /j.cnki. 2096-5974. 2023.01.011.

[79] Chen J, Bai Y, Zhai J, et al. Robust single-shot spectral-polarization ghost imaging to underwater scattering environments[J]. Optics Express, 2025, 33(24): 50854-50870.

[80] Li H, Zhu J, Deng J, et al. Underwater active polarization descattering based on a single polarized image[J]. Optics Express, 2023, 31(13): 21988-22000.

[81] 卜祥涛,宋亚芳,王晓宇,等.面向多模式图像的改进暗通道先验去雾增强[J].光学精密工程,2025,33(13):2124-2135.

[82] 张振楷,张浩,信恒府,等.基于改进 LU2Net 的浑浊水偏振图像增强[J/OL].电子测量技术,1-13[2026-03-24].

[83] Li Y, Sun X, Zhang J, et al. Underwater polarization de-scattering method with dynamic contrast constraint and adaptive genetic algorithm[J]. Optics & Laser Technology, 2025, 183: 112375.

[84] 徐万春,张焱,张景华,等.基于梯度引导偏振度估算的图像去雾[J].电子学报,2024,52(06):2011-2024.

[85] 许馨月,霍冠英,孔伟丰,等.基于多通道偏振与双分支 Transformer 的水下图像复原[J/OL].河海大学学报(自然科学版),1-19[2026-03-24].

[86] Wang Y, Ma Y, Chen Y, et al. Underwater polarization image enhancement based on low-rank polarization tensor model[J]. Optics and Lasers in Engineering, 2025, 194: 109157.

[87] Ju G, Zhang J, Fu X. Polarization-Guided Domain-Adaptive Network for Underwater Image Enhancement[C]//2025 10th International Conference on Automation, Control and Robotics Engineering (CACRE). IEEE, 2025: 231-235.

[88] Li K, Liang J, Wan Z, et al. Sfp-underwater: Attention-based shape from polarization for underwater scattering environments[J]. Optics & Laser Technology, 2025, 192: 113545.

[89] Li Y, Chen Y, Zhang J, et al. A robust underwater polarization image recovery based on angle of polarization with low-rank and sparse decomposition[J]. Optics & Laser Technology, 2025, 181: 111669.

[90] Ding X, Wang J, Wang Y, et al. Transformer-based underwater polarization descattering in natural illumination[J]. Optics and Lasers in Engineering, 2025, 187: 108865.

[91] Zhao Y, He W, Ren H, et al. Polarization descattering imaging through turbid water without prior knowledge[J]. Optics and Lasers in Engineering, 2022, 148: 106777.

[92] Guo E, Jiang J, Shi Y, et al. Unsupervised underwater imaging based on polarization and binocular depth estimation[J]. Optics Express, 2024, 32(6):

9904-9919.

[93] Cai C, Qiang F, Fu-Cheng B, et al. Joint polarization detection and degradation mechanisms for underwater image enhancement[J]. Applied Optics, 2023, 62(24): 6389-6400.

[94] Lin B, Chen W, Fan X, et al. Transformer-based improved U-net for high-performance underwater polarization imaging[J]. Optics & Laser Technology, 2025, 181: 111664.

[95] Li H, Zhu J, Deng J, et al. Visibility enhancement of underwater images based on polarization common-mode rejection of a highly polarized target signal[J]. Optics Express, 2022, 30(24): 43973-43986.

致　谢

时光荏苒，不知不觉学生生涯的最后一段旅程也要结束了，回首我十九年的求学之路，感慨万千。从村里的小学，到县里的初中，到市里最好的高中，到西交大的校园，再到年少常听爷爷奶奶念叨的清华。这一路上，我很庆幸我迈过了很多大大小小的坎，并在许多“关键”的节点幸运地往上迈了一步。

在清华的三年，快乐、充实，却也短暂。首先，我要感谢我的导师周倩老师，成为周老师的学生是我读研期间时常感觉幸运的一件事。在科研的道路上，周老师总是不厌其烦地为我提出关键建议，从组会上的思路点拨，到最终答辩材料的一次次审阅与打磨，帮助我不断提升进步。在日常生活中，周老师总是面带微笑，温柔而细心，每次与她交流，都让我感受到满满的温暖和能量。我还要感谢倪凯老师的悉心指导，倪老师看待问题的视角总是非常清晰，对于科研中的难点和瓶颈，他总能敏锐地指出关键所在，每次与倪老师交流，都让我深受启发。

同时，感谢陈红旭、李世豪、田梓涵师兄和李智琪师姐等对我科研课题的帮助；感谢同门张阔、梓璇、揆智等对我的帮助与照顾。也感谢心语、由佳、心怡等陪我走过这段旅程的朋友，祝我们前程似锦，未来在各自的领域闪闪发光。

感谢我的父母对我无条件的支持和付出，我们的家庭虽然普通，物质生活算不上富裕，但你们十分注重我和弟弟在教育方面的培养，并时刻教导我们成为一个脚踏实地、有责任有担当、待人真诚的人。真的非常感谢你们，没有你们，我一定无法成为如今的自己。

感谢我读研三年学术与生活的同行者闫金博，我们会一起在图书馆的二楼、银茶、能环楼看论文，跑实验；也会一起在周末出逃，去呼吸不同城市甚至是不同国家的风。我时常会焦虑一些选择是否会是未来的最优解，也常常缺少些勇气，你总能兜住我的情绪，帮我理性客观的分析，并且在适当的节点鼓励我勇敢往前，很幸运在读研的开始便遇见了你。

最后，依旧以我喜欢的一段话结尾：我从来不是一个聪明的人，但还是想在万千学子中不掉队。学路漫漫，一直匍匐摸索的黑暗道路上，竟也有一丝光明，三两陪伴，不妄这一段苦涩的日子。

行文至此，意味着我的学生时代即将结束，虽有不舍，但更多的是对未来的憧憬。愿我们步入职场后，依然能不断打怪升级，眼里有光，保持少年心气。

声　明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果，不包含涉及国家秘密的内容。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签　名：_____日　期：_____

个人简历、在学期间完成的相关学术成果

个人简历

2001 年 10 月 13 日出生于福建省闽侯县。

2019 年 9 月考入西安交通大学电信学部信息工程专业，2023 年 7 月本科毕业并获得工学学士学位。

2023 年 9 月免试进入清华大学深圳国际研究生院攻读电子信息专业硕士至今。

在学期间完成的相关学术成果

无。

指导教师评语

水下视觉感知在海洋资源勘探、生态监测等领域具有重要应用价值，但水体散射导致图像质量严重退化。偏振成像技术通过提供超越光强度的额外物理维度，为目标信号与散射介质的解耦提供了新思路。林滢舒同学的硕士学位论文围绕基于偏振成像的水下去散射技术开展系统研究，具有较强的理论意义与工程应用价值。论文主要完成以下几项工作：

1. 构建了大规模水下偏振图像数据集：搭建了主动偏振成像采集平台，构建了覆盖 6 个典型浑浊度等级、包含多种材质特征的偏振图像数据集，总规模达 7000+张，为算法验证与模型训练提供了坚实的数据支撑。

2. 提出了融合多偏振先验的去散射物理方法：在复平面上重构了偏振退化模型，挖掘并验证了偏振线、偏振度衰减和消色差三个核心物理先验，通过多尺度融合策略实现了场景颜色与偏振信息的高保真恢复，UIQM 和 UCIQE 指标分别达到 2.3821 和 0.5954。

3. 设计了物理先验引导的自监督去散射网络：提出“同源提取、异构解耦”的双分支网络架构，将物理先验转化为可微无参考损失函数，在零标签条件下实现自监督训练。单图处理时间约 0.6 秒，较传统方法提速 9 倍，该方法在 UCIQE 指标上取得最高得分（0.5966），UIQM 指标位列第二（2.3931）。

论文思路清晰，结构完整，理论分析与实验验证紧密结合，数据详实可靠。林滢舒同学在硕士期间表现出扎实的理论基础和较强的科研能力，能够独立开展研究工作并提出创新性解决方案。论文工作表明该生掌握了本学科扎实的基础知识，具有解决工程实际问题的能力，达到了电子信息硕士研究生的培养要求，同意安排答辩。

答辩委员会决议书